DIŞ KAPAK

T.C.

BURDUR MEHMET AKİF ERSOY ÜNİVERSİTESİ

FEN BİLİMLERİ ENSTİTÜSÜ

BİLGİSAYAR MÜHENDİSLİĞİ ANABİLİM DALI

YÜKSEK LİSANS

SÜT SIĞIRCILIĞINDA YAPILANDIRILMIŞ ÇİFTLİK VERİLERİ İLE BİLİMSEL BİLGİNİN ENTEGRASYONU İÇİN RAG TABANLI SOHBET ASİSTANI

SERENAY ÇELİKKAYA

Danışman: Prof. Dr. İSMAİL KIRBAŞ

BURDUR, 2026

ETİK KURALLARA UYGUNLUK BEYANI

SÜT SIĞIRCILIĞINDA YAPILANDIRILMIŞ ÇİFTLİK VERİLERİ İLE BİLİMSEL BİLGİNİN ENTEGRASYONU İÇİN RAG TABANLI SOHBET ASİSTANI

Kendi çalışmam olduğunu,

Sunduğum tüm sonuç, doküman, bilgi ve belgeleri bizzat ve bu tez çalışması kapsamında elde ettiğimi,

Bu tez çalışmasıyla elde edilmeyen bütün bilgi ve yorumlara atıf yaptığımı ve bunları kaynaklar listesinde usulüne uygun olarak verdiğimi,

Kullandığım verilerde değişiklik yapmadığımı,

Tez çalışması ve yazımı sırasında patent ve telif haklarını ihlal edici bir davranışımın olmadığını,

Bu tezin herhangi bir bölümünü bu üniversite veya diğer bir üniversitede başka bir tez çalışması içinde sunmadığımı,

Bu tezin planlanmasından yazımına kadar bütün safhalarda bilimsel etik kurallarına uygun olarak davrandığımı,

bildirir, aksinin ortaya çıkması durumunda her türlü yasal sonucu kabul edeceğimi beyan ederim.

Serenay ÇELİKKAYA

Ekim 2026

ÖNSÖZ

Bu araştırma için beni yönlendiren, karşılaştığım zorlukları bilgi ve tecrübesi ile aşmamda yardımcı olan değerli Danışman Hocam Prof. Dr. İsmail KIRBAŞ'a teşekkürlerimi sunarım. Deneylerimi yapmam için laboratuvarlarını bana açan ve araştırmalarımda hiçbir yardımı esirgemeyen değerli hocama teşekkür ederim.

Araştırmalarım sırasında yardımlarını gördüğüm Milli Savunma Bakanlığındaki çalışma arkadaşlarıma teşekkür ederim.

Eğitim hayatımın her aşamasında beni her anlamda destekleyen aileme sonsuz sevgi ve saygılarımı sunarım.

Ekim, 2026

Serenay ÇELİKKAYA

İÇİNDEKİLER

ÖNSÖZ....ii

ÖZET....v

ABSTRACT....vii

1. GİRİŞ....1

1.1. Problem Durumu....3

1.2. Araştırmanın Amacı ve Önemi....5

1.3. Araştırmanın Kapsamı ve Sınırlılıkları....7

1.4. Tezin Organizasyonu....9

2. KAVRAMSAL ÇERÇEVE VE LİTERATÜR TARAMASI....12

2.1. Hayvancılıkta Dijitalleşme ve Bilgiye Erişim....12

2.2. Doğal Dil İşleme (NLP) ve Büyük Dil Modelleri....16

2.3. Yapay Zekâ Destekli Sohbet Robotları....18

2.4. Retrieval-Augmented Generation (RAG)....22

2.5. LangChain ve RAG Tabanlı Sistemler....27

2.6. Veri Tabanları ve Yapay Zekâ Entegrasyonu....30

2.7. Tarım ve Hayvancılık Alanında Yapılan Çalışmalar.....34
3. MATERYAL VE YÖNTEM.....40
3.1. Araştırmanın Yöntemi ve Sistem Tasarımı.....40
3.2. Veri Kaynaklarının Hazırlanması.....42
3.3. Sohbet Robotunun Sistem Mimarisi.....46
3.4. LangChain ve RAG Altyapısının Geliştirilmesi.....49
3.5. Büyük Dil Modeli Entegrasyonu.....52
3.6. SQL ve Veri Tabanı Entegrasyonu.....54
3.7. Kullanıcı Arayüzünün Geliştirilmesi.....56
3.8. Deneysel Tasarım ve Değerlendirme Protokolü.....61
4. BULGULAR.....68
4.1. Geliştirilen Sohbet Robotuna İlişkin Bulgular.....68
4.2. Soru-Cevap Testlerinden Elde Edilen Bulgular.....71
4.3. Sistem Performans Sonuçları.....74
4.4. RAG Destekli Sistemin Değerlendirilmesi.....79
5. SONUÇ VE ÖNERİLER.....82
5.1. Bulguların Tartışılması.....82
5.2. Araştırmanın Sınırlılıkları.....86
5.3. Sonuç ve Öneriler.....87
KAYNAKLAR.....90
EKLER.....105

ÇİZELGELER DİZİNİ

Tablo 3.1. Bilgi tabanı corpus manifestosu (16 PDF).....43
Tablo 3.2 Tekrarlanabilir deney yapılandırması.....50
Tablo 4.9. Kaynak parçasına göre 15 RAG yanıtının kodu.....63
Tablo 4.10. Veteriner hekim kör puanlama formunun 15 RAG yanıtı.....65
Tablo 4.1. Sorgu Türlerine Göre Yönlendirme Sonuçları.....72
Tablo 4.2 Sorgu yönlendirme performansı.....72
Tablo 4.3 Son Test Kümesine Ait Sorgu Yönlendirme Karmaşıklık Matrisi.....73
Tablo 4.4. Pilot Değerlendirmede Sorgu Türlerine Göre Ortalama Yanıt Süreleri.....73

Tablo 4.5. Bilgi Erişim Yöntemlerinin Performans Karşılaştırması.....iv

Tablo 4.6. Pilot Test Kümesinde RRF Ağırlıklarının Performansa Etkisi.....77

Tablo 4.7. RAG Yanıt Üretim Kalitesine İlişkin Otomatik Değerlendirme Sonuçları (n=33).....78

Tablo 4.8. SQL ve HYBRID Kanallarının Uçtan Uca Değerlendirme Sonuçları.....78

Tablo 5.1. Şekil 4.1–4.4'te gözlenen tutarsızlıklar ve ilgili nicel bulgular.....86

ŞEKİLLER DİZİNİ

Şekil 3.1. Yapay Zekâ Destekli Çiftlik Asistanı Sistem Mimarisi.....49

Şekil 3.2 Kullanıcı Giriş Ekranı.....57

Şekil 3.3. Çiftlik Asistanı Kullanıcı Arayüzü.....58

Şekil 4.1. SQL Tabanlı Kullanıcı Sorgusu ve Sistem Yanıtı.....68

Şekil 4.2. Hibrit Kullanıcı Sorgusu ve Sistem Yanıtı.....69

Şekil 4.3. Çiftlik Verilerine İlişkin Detaylı Verim Analizi Ekranı.....70

Şekil 4.4. ABC Sürü Dağılımı ve Kritik Değerlendirme Ekranı.....71

ÖZET

Yüksek Lisans Tezi

SÜT SIĞIRCILIĞINDA YAPILANDIRILMIŞ ÇİFTLİK VERİLERİ İLE BİLİMSEL BİLGİNİN ENTEGRASYONU İÇİN RAG TABANLI SOHBET ASİSTANI

Serenay ÇELİKKAYA

Burdur Mehmet Akif Ersoy Üniversitesi

Fen Bilimleri Enstitüsü

Bilgisayar Mühendisliği Anabilim Dalı

Danışman: Prof. Dr. İsmail KIRBAŞ

Ekim, 2026

Bu çalışmanın amacı, süt sığırcılığı işletmelerinde bilimsel bilgiye erişimi kolaylaştırmak ve çiftlik kayıtlarının doğal dil aracılığıyla sorgulanmasını sağlamak üzere yapay zekâ destekli bir sohbet robotu prototipi geliştirmek ve sistemin performansını değerlendirmektir. Bu kapsamda büyük dil modeli, Geri Getirme Destekli Üretim (Retrieval-Augmented Generation, RAG) yaklaşımı ve ilişkisel veri tabanı teknolojileri bütünleşik bir mimaride bir araya getirilmiştir. Üretim katmanında atıf doğruluğu 0,303, atıf tamlığı 0,1364 ve desteksiz iddia oranı 0,8636'dır. SQL doğal dil yanıt tutarlılığı 17/24 (0,708), HYBRID uçtan uca oran 11/16 (0,6875) bulunmuştur. Bu değerler yönlendirme başarısının yanıt güvenilirliği anlamına gelmediğini gösterir.

Geliştirilen sistem, kullanıcı sorgularını içeriklerine göre RAG, SQL, HYBRID ve CHAT olmak üzere dört farklı işlem kanalına yönlendirmektedir. Bilimsel bilgi tabanı, hayvan sağlığı, besleme, süt kalitesi, üreme ve çiftlik yönetimiyle ilişkili 16 PDF belgeden oluşturulmuştur. Toplam 748 sayfalık dokümanlar, 1.833 metin parçasına ayrılarak bilgi erişim altyapısına aktarılmıştır. Anlamsal bilgi erişiminde BGE-M3 gömme modeli ve FAISS, sözcüksel erişimde BM25 algoritması kullanılmış; sonuçların birleştirilmesinde ağırlıklı Reciprocal Rank Fusion (RRF) yöntemi uygulanmıştır. Yapılandırılmış veri sorgulamaları için PostgreSQL veri tabanından yararlanılmış ve gerçek işletme verileri yerine sentetik çiftlik kayıtları kullanılmıştır. Doğal dilde yanıt üretimi Mistral büyük dil modeli aracılığıyla gerçekleştirilmiştir.

Sistemin sorgu yönlendirme performansı ilk aşamada 100 soruluk pilot test kümesinde değerlendirilmiş ve %97 doğruluk elde edilmiştir. Ardından 33 RAG, 24 SQL, 16 HYBRID ve 16 CHAT sorusundan oluşan 89 soruluk son test kümesinde yönlendirme doğruluğu %100, Macro-F1 değeri ise 1,00 olarak hesaplanmıştır. Bilgi erişim performansının 33 RAG sorusu üzerinden değerlendirildiği karşılaştırmada BGE-M3 + FAISS yöntemi P@5 için 0,90, R@5 için 0,71, MRR için 0,91 ve nDCG@5 için 0,92 değerlerine ulaşmıştır. Hibrit RRF yöntemi BM25'ten daha yüksek performans göstermesine rağmen bu test kümesinde yalnızca anlamsal erişime dayanan yöntemin bir miktar gerisinde kalmıştır.

Sonuç olarak geliştirilen prototip, bilimsel dokümanlardan bilgi erişimini ve sentetik çiftlik kayıtlarının doğal dilde sorgulanmasını tek bir sohbet arayüzünde birleştiren bir yapı sunmaktadır. Bununla birlikte, yüksek sorgu yönlendirme ve bilgi erişim performansı, üretilen yanıtların aynı düzeyde doğru ve değerlendirmelerinde hatalar gözlenmiş; RAG tabanlı yanıt

üretiminde ise kaynaklara bağlılık ve atıf doğruluğu açısından sınırlılıklar belirlenmiştir. Bu bulgular, sistemin gerçek işletme koşullarında kullanılmasından önce yanıt doğruluğunun, kaynak güvenilirliğinin ve farklı veri kümelerindeki performansının geliştirilmesi gerektiğini göstermektedir.

güvenilir olduğu anlamına gelmemekt SQL ve HYBRID kanallarını uçtan uca
Anahtar kelimeler: Yapay Zekâ, Süt Sığırcılığı, Sohbet Robotu, Büyük Dil Modelleri, RAG, LangChain, Hibrit Bilgi Erişimi.

ABSTRACT

M.Sc. Thesis
A RAG-Based Chat Assistant for Integrating Structured Farm Records and Scientific Knowledge in Dairy Cattle Farming
Author Serenay ÇELİKKAYA
Burdur Mehmet Akif Ersoy University
Graduate School of Natural and Applied Sciences Department of Computer Engineering
Supervisor: Prof. Dr. İsmail KIRBAŞ
October, 2026

The aim of this study is to develop and evaluate an artificial intelligence-supported chatbot prototype that facilitates access to scientific information and enables natural language queries of farm records in dairy cattle farming. To achieve this objective, a large language model, Retrieval-Augmented Generation (RAG), and relational database technologies were integrated into a unified system architecture.

The developed system routes user queries into four processing channels: RAG, SQL, HYBRID, and CHAT. The scientific knowledge base was constructed from 16 PDF documents covering animal health, nutrition, milk quality, reproduction, and farm management. These documents, comprising 748 pages, were divided into 1,833 text chunks and incorporated into the retrieval infrastructure. Semantic retrieval was performed using the BGE-M3 embedding model and FAISS, while lexical retrieval was conducted using the BM25 algorithm. The results were combined through a weighted Reciprocal Rank Fusion (RRF) method. PostgreSQL was used for structured data queries, with synthetic farm records employed instead of actual commercial farm data. Natural language responses were generated using the Mistral large language model.

The query-routing performance of the system was initially evaluated on a pilot dataset containing 100 questions, achieving an accuracy of 97%. Subsequently, a final test dataset consisting of 89 questions, including 33 RAG, 24 SQL, 16 HYBRID, and 16 CHAT queries, yielded a routing accuracy of 100% and a Macro-F1 score of 1.00. Retrieval performance was evaluated using 33 RAG questions. The BGE-M3 + FAISS approach achieved a P@5 of 0.90, R@5 of 0.71, MRR of 0.91, and nDCG@5 of 0.92. Although the hybrid RRF approach outperformed BM25, it performed slightly below the standalone semantic retrieval method on the evaluated dataset.

In conclusion, the developed prototype provides an integrated conversational interface that combines scientific document retrieval with natural language querying of synthetic farm records. However, high query-routing and information retrieval performance does not necessarily imply an equivalent level of accuracy and reliability in the generated responses. Errors were observed in the end-to-end evaluations of the SQL and HYBRID channels, while limitations related to source faithfulness and citation accuracy were identified in RAG-based response generation. These findings indicate that response accuracy, source reliability, and performance across diverse datasets should be further improved before the system is deployed in real-world farming environments.

Keywords: Artificial Intelligence, Dairy Cattle Farming, Chatbot, Large Language Models, Retrieval-Augmented Generation, LangChain, Hybrid Information Retrieval.

1. GİRİŞ

Dijital teknolojilerdeki hızlı gelişmeler, hayvancılık da dahil olmak üzere birçok sektörde üretim ve yönetim süreçlerini dönüştürüyor. Hayvan izleme, üretim kayıtlarının tutulması, sağlık verilerinin analizi ve çiftlik yönetimi gibi geleneksel yöntemler, sensörlerin, Nesnelerin İnterneti'nin (IoT), veri tabanlarının ve yapay zekâ (YZ) uygulamalarının yaygın kullanımıyla giderek daha fazla veri odaklı hale geliyor. Bu dönüşüm, hayvan sağlığı ve refahının izlenmesinden üretim verimliliğinin artırılmasına kadar birçok alanda yeni uygulamaların geliştirilmesini sağlıyor. Hayvancılıkta YZ uygulamaları, özellikle hayvan sağlığı ve davranışının izlenmesi, üretim süreçlerinin otomasyonu ve kaynak kullanımının optimize edilmesi açısından önemli bir potansiyele sahip (Melak vd., 2024).

Çiftliklerde dijitalleşme ile üretilen sürekli artan veri hacmi, yalnızca yeterli veri depolamasını değil, aynı zamanda kullanıcılar tarafından erişilebilir ve anlaşılabilir verileri de gerektiriyor. Çiftlik kayıtları, hayvanlar hakkında bilgiler, sağım verileri, üretim ölçütleri ve çeşitli sağlık göstergelerini içerebilir. Ayrıca, üreme, hayvan sağlığı, besleme, üreme yönetimi ve süt kalitesi gibi konularda bilimsel ve teknik bilgilerin dahil edilmesi çok önemlidir. Sonuç olarak, sektör spesifik, yapılandırılmış verilerin bilimsel bilgi kaynaklarıyla birlikte kullanılabilmesi, hayvancılıkta dijital sistemlerin geliştirilmesi için merkezi öneme sahiptir. Doğal dil işleme alanındaki gelişmeler de kullanıcıların bilgi sistemleriyle etkileşim biçimini temelden değiştirmiştir. Özellikle, büyük dil modellerinin geliştirilmesi, kullanıcıların teknik uzmanlığa ihtiyaç duymadan günlük dilde sorular sorabileceği ve doğal dilde yanıt alabileceği sistemler tasarlamayı mümkün kılmaktadır. Büyük veri kümeleri üzerinde eğitilebilme ve doğal dildeki talimatları işleyebilme yetenekleri sayesinde, bu büyük dil modelleri soru cevaplama, bilgi çıkarma ve metin üretme gibi çeşitli görevler için kullanılabilir (Brown vd., 2020). Bununla birlikte, bu modellerin yalnızca eğitim sırasında öğrenilen bilgilere dayanması, özellikle güncel, konu spesifik veya sektör spesifik veriler gerektiren uygulamalar için önemli bir sınırlama oluşturmaktadır. Geri Getirme Destekli Üretim (RAG), bu sınırlamanın üstesinden gelmek için geliştirilen bir yaklaşımdır. RAG, harici bilgi kaynaklarından içerik entegre ederek büyük dil

modelinin yanıt oluşturma sürecini destekler ve böylece modelin belirli bir bilgi tabanına erişmesini sağlar (Lewis vd., 2020). Bu yaklaşım, özellikle konuya özgü bilimsel belgeler kullanarak soruları yanıtlayan sistemler için önemlidir. Kullanıcının sorgusuna ilişkin bilgi tabanından ilgili bilgileri önce belirleyip ardından büyük dil modeline bağlam olarak sağlayarak, evrensel bir dil modeli konuya özgü bilgi kaynaklarıyla birlikte kullanılabilir. Bununla birlikte, bilimsel belgeler tek başına hayvancılıkta tüm bilgi ihtiyaçlarını karşılamak için yeterli değildir. Bir kullanıcı belirli bir hayvanın süt verimi hakkında bir soru sorarsa (bu da geçmiş veriler veya diğer sayısal çiftlik kayıtları gerektirir), yapılandırılmış veritabanlarına erişim gereklidir. Bu bağlamda, doğal dil işleme (NLP) teknolojilerini ilişkisel veritabanlarıyla birleştirmek, SQL gibi teknik sorgu dilleri hakkında bilgi gerektirmeden çiftlik verilerine erişim için yeni olanaklar açar. Sonuç olarak, doğal dilde formüle edilmiş bir soru, içeriğine bağlı olarak, bilimsel bir bilgi kaynağına, bir çiftlik veritabanına veya her ikisine de yönlendirilebilir.

Bu çalışma, yukarıda belirtilen gereksinimleri dikkate alarak, süt çiftlikleri için yapay zekâ destekli bir sohbet robotunun geliştirilmesine odaklanmaktadır. Geliştirilen sistem, doğal dil işleme, büyük dil modelleri, Geri Getirme Destekli Üretim (RAG) ve ilişkisel veritabanı teknolojilerini birleşik bir yapı içinde entegre etmektedir. Kullanıcı sorgularını içeriklerine göre farklı işleme akışlarına yönlendirir: çiftlik verileriyle ilgili sorgular bir SQL veritabanı aracılığıyla, bilimsel bilgilerle ilgili sorgular bir RAG altyapısı aracılığıyla ve her iki kaynağı da gerektiren sorgular hibrit bir yapı aracılığıyla işlenir. Amaç, kullanıcıların tek bir sohbet arayüzü üzerinden hem çiftliğe özgü verilere hem de sistemin bilimsel bilgi kaynaklarına erişmelerini sağlamaktır. Bu çalışmanın bir parçası olarak, süt çiftçiliği üzerine bilimsel belgeleri derleyen bir bilgi tabanı oluşturuldu, çiftliğe özgü yapılandırılmış verileri yönetmek için ilişkisel bir veritabanı kullanıldı ve bu kaynaklar ile büyük bir dil modeli arasındaki etkileşimi kolaylaştırmak için bir sistem mimarisi geliştirildi. Amaç, tek bir uygulama içinde çeşitli bilgi ihtiyaçlarını karşılamaktı. Bu, bilimsel bilgileri almak için anlamsal ve sözcüksel arama

yöntemlerinin birleştirilmesi ve tarımsal verilerle ilgili sorgular için veritabanı tabanlı bir yapının uygulanmasıyla gerçekleştirildi. Bu nedenle, araştırma sadece genel bilgi sağlayan bir chatbot geliştirmekle sınırlı kalmadı; doğal dil işleme kullanarak hayvancılık sektöründe çiftliğe özgü yapılandırılmış verileri bilimsel bilgi kaynaklarına bağlayan entegre bir sistem oluşturmayı hedefledi. Sistemin farklı sorgu türlerini uygun işleme akışlarına yönlendirme yeteneği ve yanıt üretme performansı değerlendirildi. Elde edilen sonuçlara dayanarak, sistemin mevcut çalışması, potansiyel iyileştirme alanları ve hayvancılık sektöründeki diğer yapay zekâ uygulamalarına aktarılabilecek işlevler analiz edildi.

1.1. Problem Durumu

Hayvancılık sektöründe dijital teknolojilerin giderek daha fazla kullanılması, üretim süreçleri sonucunda ortaya çıkan verilerin çeşitlenmesine ve bu verilerin yönetilmesine yönelik yeni gereksinimlerin doğmasına yol açmıştır. Örneğin süt hayvancılığında; bireysel hayvanlara, süt verimine, sağım süreçlerine ve sürü yönetimine ilişkin veriler, işletme faaliyetlerinin değerlendirilmesinde kritik bir rol oynar. Ancak, çiftçilik uygulamalarına dair bilimsel ve teknik bilgiler genellikle çeşitli belge ve kaynaklara dağılmış durumdadır. Yapılandırılmış çiftlik kayıtlarının ve yapılandırılmamış bilimsel içeriklerin ayrı ortamlarda saklanması, bu bilgilere bütünleşik bir şekilde erişilmesini zorlaştırmaktadır. Geleneksel veritabanı sistemleri, yapılandırılmış verilerin depolanması ve sorgulanması için verimli çözümler sunsa da, bunların kullanımı genellikle belirli bir düzeyde teknik uzmanlık gerektirir. Benzer şekilde, bilimsel belgelerden belirli bilgileri elde etmek; ilgili kaynakların incelenmesini ve uygun içeriğin tespit edilmesini zorunlu kılar. Bu durum, farklı teknik bilgi düzeylerine sahip kullanıcıların, çiftlik kayıtlarını ve bilimsel bilgileri bir arada değerlendirmelerini güçleştirmektedir. Doğal Dil İşleme (NLP) ve Büyük Dil Modelleri (LLM'ler), doğal dille ifade edilen kullanıcı sorgularının işlenmesi ve yanıtlanması konusunda önemli bir potansiyel sunar. Bununla birlikte, LLM'ler yanıtlarını yalnızca önceden var olan bilgilerine dayanarak oluşturduklarından; güncellik, doğrulanabilirlik ve alana özgü

bilgilerin ele alınması konularında birtakım sınırlamalarla karşılaşırlar. Bu sınırlamaları hafifletmek amacıyla geliştirilen "Geri Getirme Destekli Üretim" (Retrieval-Augmented Generation, RAG) yaklaşımı, yanıt oluşturma sürecinde ilgili bilgi kaynaklarından içeriklerin dahil edilmesine olanak tanır (Lewis ve diğerleri, 2020).

Hayvancılık sektöründe, yapay zekâ tabanlı bir sohbet robotunun (chatbot) soruları yalnızca bilimsel belgelere dayanarak yanıtlaması yeterli değildir. Bazı kullanıcılar çiftlik operasyonlarına ilişkin nicel verilere erişmek isterken, diğerleri bilimsel açıklamalar talep etmekte; bazı sorgular ise her iki bilgi türünün birlikte değerlendirilmesini gerektirmektedir. Ayrıca, kullanıcılardan gelen genel sohbet içerikli girdilerin de uygun şekilde ele alınması gerekir. Dolayısıyla, farklı sorgu türlerini birbirinden ayırt edebilen ve her birini ilgili bilgi işleme kanalına yönlendirebilen bütünleşik bir sistem mimarisine ihtiyaç duyulmaktadır. Bu araştırmada ele alınan temel zorluk; süt hayvancılığına ilişkin yapılandırılmış çiftlik verilerinin ve bilimsel bilgi kaynaklarının, doğal dil tabanlı tek bir sistemde birleştirilmesidir. Bu amaçla; SQL, RAG (Geri Getirme Destekli Üretim), HYBRID (Hibrit) ve CHAT (Sohbet) olmak üzere dört farklı sorgu işleme kanalına sahip bir sohbet robotu geliştirilmiştir. Sistemde kullanılan çiftlik verileri, gerçek bir ticari işletmeden elde edilmemiş; aksine, prototipin geliştirilmesi ve değerlendirilmesi amacıyla sentetik olarak oluşturulmuştur. Bununla birlikte, böyle bir sistemin varlığı ve çalışır durumda olması, üretilen yanıtların her zaman doğru ve güvenilir olacağını garanti etmez. Değerlendirme için temel ölçütler arasında; sorguların uygun işleme kanalına yönlendirilmesi, bilgi tabanından ilgili bilimsel içeriğin getirilmesi, SQL sorgularından doğru sonuçların elde edilmesi ve büyük dil modeli tarafından üretilen yanıtların doğrulanabilir kaynaklara dayandırılması yer alır. Dolayısıyla, geliştirilen sistemin başarısı yalnızca yönlendirme mekanizmasının genel doğruluğuyla değil; aynı zamanda bilgiye erişim ve yanıtların oluşturulma süreçlerini kapsayan kriterlerle değerlendirilmelidir. Bu bağlamda temel araştırma hedefi, hayvancılık alanındaki yapılandırılmış ve yapılandırılmamış bilgi kaynaklarını entegre eden, yapay zekâ tabanlı bir sohbet robotunun (chatbot) geliştirilmesi ve sistemin çeşitli bileşenlerinin deneysel olarak değerlendirilmesidir. Bu temel mesele doğrultusunda, aşağıdaki araştırma soruları ele alınmıştır:

RQ1. Geliştirilen sohbet robotu, kullanıcı sorgularını uygun işleme kanallarına yönlendirebilmektedir?

(SQL, RAG, HYBRID veya CHAT) ne ölçüde doğru bir şekilde

RQ2. RAG tabanlı bir bilgi getirme sürecinde; BM25, BGE-M3 ve FAISS temelli anlamsal (semantic) arama ve hibrit arama yöntemlerinin performansları nasıl farklılık göstermektedir?

RQ3. Anlamsal ve sözcüksel (lexical) arama sonuçla farklı ağırlıklandırma birleştirilmesi, hibrit aramanın performa nasıl etkilemektedir?

RQ4. Geliştirilen sistem, sentetik tarımsal kayıtlara yönelik doğal dildeki sorguları SQL kullanarak ne ölçüde başarılı bir şekilde işleyebilmektedir? RQ5. RAG tabanlı sistem tarafından sağlanan yanıtlar; kaynak uygunluğu, alıntıların dahil edilmesi ve desteklenmeyen iddiaların üretilmesi açılarından nasıl bir performans sergilemektedir?

Bu araştırma, yalnızca sohbet robotuna (chatbot) dair ayrıntılı bir teknik çalışma yürütmeyi değil; aynı zamanda çeşitli sorgu işleme ve bilgi getirme bileşenlerinin performansını ve yanıt oluşturma sürecinin sınırlılıklarını değerlendirmeyi de amaçlamaktadır.

1.2. Araştırmanın Amacı ve Önemi

Bu araştırmanın temel amacı, süt çiftliği kullanıcılarının doğal dilde hem çiftliğe özgü yapılandırılmış verilere hem de hayvancılıkla ilgili bilimsel bilgi kaynaklarına erişmelerini sağlayan yapay zekâ destekli bir sohbet robotu geliştirmektir. Bunu başarmak için, büyük bir dil modeli, Geri Getirme Destekli Üretim (RAG) yaklaşımı ve ilişkisel veritabanı teknolojileri birleşik bir sistem mimarisine entegre edilmiştir. Geliştirilen sistem, kullanıcıların karmaşık teknik sorgular formüle etmek veya bireysel bilimsel belgeleri manuel olarak aramak zorunda kalmadan doğal dilde sorular sormasına olanak tanır. Kullanıcı sorgularının içeriğine bağlı olarak uygun işlem yolunun belirlenmesi, sistemin temel bir işlevidir. Bu nedenle, sistem çiftlik verileriyle ilgili soruları SQL aracılığıyla, bilimsel bilgi gerektirenleri RAG aracılığıyla, her iki kaynak türünü de gerektirenleri hibrit bir yaklaşımla ve harici kaynak

gerektirmeyen genel mesajları standart bir sohbet kanalı aracılığıyla ele alır. Bir diğer araştırma amacı ise, büyük dil modeliyle birlikte hayvancılıkla ilgili bilimsel belgelerin kullanımına olanak sağlayan özel bir bilgi tabanı oluşturmaktır. RAG Geri Getirme Destekli Üretim (Retrieval-Augmented Generation) , üretken modelin harici bilgi kaynaklarından içerik kullanmasını sağlar (Lewis vd., 2020). Bu çalışma, süt ürünleri sektörüne ilişkin bilimsel belgeleri kullanıcı sorgularına göre erişilebilir hale getirmeyi ve bu içeriği bu yaklaşımı kullanarak dil modelinin yanıt üretme sürecine entegre etmeyi amaçlamaktadır. Tanımlanan sistem, sekiz tematik kategoriye ayrılmış 16 PDF belgesinden oluşan bir bilimsel bilgi tabanına dayanmaktadır.

Bu çalışmanın temel bir yönü, bilimsel bilgilere erişim ve sektöre özgü veri alma süreçlerinin tek bir sistem içinde entegre edilmesidir. Belirli bir hayvanın üretim göstergeleri hakkında bilgi arayan bir kullanıcının, hayvan sağlığı hakkında bilimsel açıklamalar isteyen bir kullanıcıdan farklı kaynaklara erişmesi gerekir. Geliştirilen sistem, bu iki bilgi türü arasında ayrım yapmayı ve gerektiğinde hibrit bir sorgu yapısında bunların birleşik kullanımına izin vermeyi amaçlamaktadır. Bu bağlamda, çalışma genel amaçlı bir soru-cevap sohbet robotu geliştirmekle sınırlı değildir; kullanıcının sorgusunun niteliğine bağlı olarak çeşitli bilgi kaynaklarından yararlanabilen özel bir uygulama oluşturmayı amaçlamaktadır. Bu araştırma, prototipin bir parçası olarak oluşturulan sentetik tarım verilerinin doğal dil kullanılarak sorgulanmasına olanak tanıması bakımından önemlidir. Amaç, kullanıcıların ilişkisel bir veritabanında depolanan hayvanlar ve üretime ilişkin verileri doğal dille sorgulayabilmelerini sağlamaktır; bu sayede, veritabanı sorgu dillerine dair teknik bilgiye ihtiyaç duyulmaksızın kayıtlı verilere erişim mümkün hale gelir. Bu amaçla, sistem yapılandırılmış verileri (çiftlik bilgileri, kullanıcı verileri, hayvan verileri, sağım verileri, uyarılar ve günlük özetler gibi) veritabanında depolar ve chatbot'un etkileşim kurabileceği bir yapı oluşturur. Bu çalışmanın pratik bir katkısı, RAG çerçevesinde anlamsal ve sözcüksel arama yöntemlerinin birleşik kullanımında yatmaktadır. Bilimsel belgelerden bilgi çıkarırken, sistem anlamsal aramayı (BGE-M3 ve FAISS tabanlı) ve sözcüksel

aramayı (BM25 tabanlı) birleşik bir yapıya entegre eder. Amaç, yalnızca anahtar kelime eşleştirmesi veya anlamsal benzerlikle sınırlı kalmadan, kullanıcının sorgusuna uygun içeriği belirlemektir. Geliştirilen sistemde bu iki yöntemi birleştiren hibrit bir bilgi alma mekanizması uygulandı.

Bu araştırmanın bir diğer amacı, geliştirilen sistemin performansını deneysel olarak değerlendirmektir. Bu bağlamda çalışma; kullanıcı sorgularının SQL, RAG, HYBRID ve CHAT işleme kanallarına yönlendirilmesindeki başarıyı, çeşitli bilgi erişim yöntemlerinin performansını ve yanıt oluşturma sürecinde sistemin karşılaştığı sınırlılıkla incelemiştir. Bilgi erişim performansını değerlendirmek için Precision@K, Recall@K, MRR ve nDCG gibi metriklerden yararlanılmıştır. Böylece çalışma, işlevsel bir prototip geliştirmenin ötesine geçerek, sistemin çeşitli bileşenlerini ölçülebilir göstergelerle değerlendirmiştir. Bu yönüyle araştırma, hayvancılık alanında yapılandırılmış verileri bilimsel bilgi kaynaklarıyla bütünleştiren yapay zekâ sistemlerinin geliştirilmesine dair uygulamalı bir örnek sunmaktadır.

1.3. Araştırmanın Kapsamı ve Sınırlılıkları

Bu araştırma, süt çiftçiliği için yapay zekâ tabanlı bir sohbet robotunun tasarımına, uygulanmasına ve performans değerlendirmesine odaklanmaktadır. Çalışma, doğal dil işleme (NLP), büyük dil modelleri (LLM), “Geri Getirme Destekli Üretim (RAG)” ve ilişkisel veritabanı teknolojilerini birleşik bir sistem mimarisine entegre etmektedir. Araştırmanın konusu süt çiftçiliği ile sınırlıdır; hem bilimsel bilgi tabanı hem de çiftlik verileri buna göre yapılandırılmıştır. Araştırma için kullanılan bilimsel bilgi tabanı, süt ve hayvancılık çiftçiliği üzerine 16 PDF belgesinden oluşmaktadır. Bu belgeler sekiz konu kategorisine ayrılmış ve işleme sonrasında toplam 1.833 metin parçası elde edilmiştir. Sonuç olarak, RAG bileşeni aracılığıyla erişilebilen bilimsel bilgiler, sistemde depolanan belgelerin kapsamı ve içeriğiyle sınırlıdır. Sistem, bilgi tabanında yer almayan veya belgelerde yetersiz bir şekilde ele alınan konular hakkında eşdeğer bilgi sağlayamaz. Çalışmanın veri seti, geliştirilen prototip içinde oluşturulan çiftlik ve hayvan kayıtlarıyla sınırlıdır.

Bu kayıtlar, gerçek bir süt çiftliğinden elde edilmiş veriler olmayıp sistemin geliştirilmesi ve değerlendirilmesi amacıyla sentetik olarak oluşturulmuştur.

Sistem, çiftlik ve kullanıcı bilgileri, hayvan verileri, sağım kayıtları, uyarılar ve günlük özetler gibi yapılandırılmış verileri sorgulamak üzere tasarlanmıştır. Bu nedenle, çalışma gerçek süt çiftliklerinde bulunan tüm veri kümelerini veya iş süreçlerini kapsama amacını taşımamaktadır. Geliştirilen yapı, çeşitli veri kaynaklarının dil tabanlı bir sisteme nasıl entegre edilebileceğini göstermeyi amaçlayan bir prototiptir. Sistemin performansı, geliştirme aşamasında kullanılan bir ön değerlendirme veri kümesi ve ayrı bir nihai test veri kümesiyle değerlendirilmiştir. Ön değerlendirme; 50 RAG sorgusu, 30 SQL sorgusu ve 20 HİBRİT (HYBRID) sorgudan oluşan 100 sorguluk bir veri kümesiyle gerçekleştirilmiştir. Bu aşamadan elde edilen sonuçlar, sistemdeki iyileştirmelere yön vermiş ve bilgi getirme (information retrieval) yaklaşımının yapılandırılmasına katkıda bulunmuştur. Nihai değerlendirme için ise 33 RAG, 24 SQL, 16 HİBRİT ve 16 SOHBET (CHAT) sorgusundan oluşan 89 sorguluk ayrı bir test kümesi hazırlanmıştır. Sorgu yönlendirme (query routing) performansı bu dört kategori genelinde incelenmiş; ancak yönlendirme doğruluğunun, sistem tarafından üretilen yanıtların doğruluğunu doğrudan yansıtmadığı gözlemlenmiştir. RAG bileşeninin bilgi getirme performansı değerlendirilirken; anlamsal arama (semantic search) ve (BM25, BGE-M3 ve FAISS temelli) hibrit bilgi getirme yöntemleri karşılaştırılmıştır. Bu karşılaştırmada Precision@5, Recall@5, Ortalama Ters Sıralama (MRR) ve Normalleştirilmiş İndirgenmiş Kümülatif Kazanç (nDCG@5) gibi metrikler kullanılmıştır. Bununla birlikte, bilgi getirme aşamasında ilgili belgelerin başarılı bir şekilde bulunması, büyük dil modeli tarafından üretilen nihai yanıtların her zaman doğru olacağını ve kaynak materyalle tutarlı kalacağını garanti etmez.

Bu çalışmanın temel bir kısıtlılığı, SQL ve HİBRİT kanallarına yönelik uçtan uca değerlendirmelerin sınırlı büyüklükteki test kümeleriyle yapılmış olmasıdır. SQL kanalı için, referans sorguların çalıştırılabilirliği ile doğal dildeki sorgu yanıtlarının değerler ve varlıklar açısından tutarlılığı ayrı

metrikler olarak ele alınmıştır. HİBRİT kanalında ise yapılandırılmış tarımsal veriler ile bilimsel bilgileri birleştiren yanıtların kalitesi değerlendirilmiştir. Ancak bu metrikler, sistemin gerçek dünya tarım ortamlarındaki genel doğruluğunu tam olarak ortaya koymamaktadır. RAG tarafından üretilen yanıtlarda alıntı doğruluğu, desteklenmeyen iddiaların oranı ve otomatik değerlendirme puanları incelenmiş olsa da, bu bulgular bağımsız alan uzmanları tarafından yapılacak kapsamlı bir doğrulamanın yerini tutmaz. Ayrıca, yalnızca Büyük Dil Modeli'ne dayalı bir sistem ile entegre RAG'ye sahip sistem arasında kapsamlı, kontrollü bir karşılaştırma yapılmamıştır. Bu nedenle, RAG kullanımının yanıtların doğruluğunu artırıp artırmadığı veya Büyük Dil Modeli'nin tek başına kullanımına kıyasla alakasız bilgi üretimini azaltıp azaltmadığı konusunda nicel sonuçlar çıkarılamamıştır. Bu karşılaştırmalar, geliştirilen sistemin gelecekteki çalışmalarında ele alınabilecek değerlendirme yaklaşımlarını temsil etmektedir.

Çalışmanın bir diğer sınırlaması ise, geliştirilen sistemin hayvan hastalıklarının klinik teşhisini yapmak veya veteriner değerlendirmesinin yerini almak üzere tasarlanmamış olmasıdır. Sistem, bilgi tabanındaki bilimsel içeriğe ve veritabanındaki sentetik çiftlik kayıtlarına erişimi kolaylaştıran bir bilgi destek aracı olarak tasarlanmıştır. Sistem tarafından sağlanan hayvan sağlığı sonuçlarının profesyonel veteriner değerlendirmesinin yerine kullanılması bu çalışmanın konusu olmamıştır.

Son olarak, çalışma geliştirilen sistemin teknik işleyişi, sorgu yönlendirme performansı, bilgi erişim bileşenleri ve sınırlı test kümeleri üzerinden gerçekleştirilen uçtan uca yanıt değerlendirmeleriyle sınırlıdır.

Gerçek tarımsal koşullar altında uzun vadeli kullanım, farklı büyüklükteki çiftliklerde pratik uygulama, hayvancılıkla uğraşan çiftçilerin deneyimleri ve sistem kullanımının çiftlik performansı, hayvan sağlığı veya süt üretimi üzerindeki uzun vadeli etkileri bu çalışmada değerlendirilmemiştir.

1.4. Tezin Organizasyonu

Bu tez, araştırma amacına ulaşmak için birbirini tamamlayan beş ana bölümden oluşmaktadır. Bu bölümler, araştırma probleminin

formülasyonundan ve geliştirilen sistemin teknik tasarımından elde edilen sonuçların analizine kadar uzanan genel bir yapının parçasıdır.

Birinci bölüm, araştırmanın genel çerçevesini sunmaktadır. Araştırma problemini özetler, çalışmanın amacını ve önemini tanımlar, araştırmanın kapsamını ve sınırlamalarını belirtir ve tezin genel yapısını sunar.

İkinci bölüm, çalışmanın teorik ve kavramsal temelini oluşturan literatürü inceler. Dijital dönüşüm ve hayvancılıkta yapay zekânın uygulamalarıyla başlayan analiz, doğal dil işleme, büyük dil modelleri (LLM'ler) ve sohbet robotlarını ele almaktadır. Ardından, geri getirme destekli üretim (RAG), LangChain, gömme modelleri, vektör veritabanları ve ilişkisel veritabanı entegrasyonu kavramlarını açıklar. Ayrıca, hayvancılık sektöründe yapay zekâ tabanlı sohbet robotlarının kullanımına ilişkin çalışmaları değerlendirir ve araştırmanın altında yatan teknolojik ve akademik çerçeveyi tanımlar.

Üçüncü bölüm, araştırma materyallerini ve yöntemlerini sunmaktadır. Bu bölümde, yapay zekâ tabanlı tarım asistanının tasarımı, veri kaynaklarının hazırlanması ve chatbot sistem mimarisi ayrıntılı olarak ele alınmaktadır. Ayrıca, LangChain ve RAG altyapısının geliştirilmesi, büyük dil modelinin sisteme entegrasyonu, SQL ve veritabanı bağlantısı ve kullanıcı arayüzünün oluşturulması da açıklanmaktadır. Son olarak, bölüm test yaklaşımını ve sistemi değerlendirmek için kullanılan performans göstergelerini açıklamaktadır.

Dördüncü bölüm, geliştirilen yapay zekâ tabanlı sohbet robotuna yönelik deneysel değerlendirmenin uygulanışını ve sonuçlarını sunmaktadır. Sistemin SQL, RAG, hibrit (HYBRID) ve sohbet (CHAT) sorgularına ilişkin işleme çerçevesi incelenmekte; geliştirme aşamasında kullanılan ön değerlendirme veri kümesinden ve nihai test veri kümesinden elde edilen sonuçlar ayrı ayrı analiz edilmektedir. Sorgu yönlendirme performansı ve yanıt sürelerine ilişkin bulguların yanı sıra, BM25, BGE-M3 ve FAISS temelli anlamsal arama yöntemlerinin ve hibrit bilgi getirme yöntemlerinin performansları karşılaştırılmaktadır. Ayrıca, sistemin yanıt oluşturma değerlendirmelere yer

verilmektedir. Beşinci ve son bölümde ise elde edilen sonuçlar araştırma soruları bağlamında değerlendirilmekte, geliştirilen sistemin teknik katkıları ve kısıtları tartışılmakta ve gelecekteki araştırmalara yönelik öneriler sunulmaktadır.

sürecine uygulanan metrikler açıklanmakta ve devam eden deneysel

2. KAVRAMSAL ÇERÇEVE VE LİTERATÜR TARAMASI

2.1. Hayvancılıkta Dijitalleşme ve Bilgiye Erişim

Hayvancılıkta dijitalleşme ve yapay zekânın (YZ) kullanımı, sürdürülebilir üretim, artan verimlilik ve iyileştirilmiş hayvan refahı gibi önemli fırsatlar sunarak derin değişikliklere yol açmaktadır. YZ uygulamaları, çeşitli hayvancılık fonksiyonlarını otomatikleştirerek ve sektörün operasyonel verimliliğini artırarak veri odaklı karar vermeyi desteklemektedir. YZ, özellikle hayvan sağlığı ve refahının izlenmesinde önemli bir rol oynamaktadır. Sensörler ve veri analiz modelleri, hayvan davranışının, sağlık durumunun, üremenin ve stres seviyelerinin gerçek zamanlı olarak izlenmesini sağlayarak erken müdahaleye olanak tanır. YZ tabanlı sistemler, örneğin hayvan tanımlama, cinsiyet belirleme, aşılama takibi ve mera değerlendirmesinde kullanılmaktadır. Ayrıca, sağım gibi süreçler dronlar ve robotlar tarafından otomatikleştirilerek insan hatası en aza indirilebilir. Bu gelişmeler aynı zamanda karbon ayak izini azaltmaya ve kaynak kullanımını optimize etmeye de katkıda bulunmaktadır (Melak vd., 2024).

Dijitalleşme sadece hayvan yönetimini değil, altyapıyı ve iş organizasyonunu da dönüştürmektedir. YZ'nin modern entegrasyonu, çiftlikleri "YZ'ye hazır" hale gerektirmektedir. Ağ kapsamı, veri sistemi uyumluluğu, siber güvenlik önlemleri ve dijital beceriler gerektiren yeni rollerin yaratılması bu dönüşümün temellerini oluşturmaktadır. Sürekli çalışan eğitimi ve veri odaklı karar alma süreçlerine uyum, hayati önem taşımaktadır. Ayrıca, dijital platformlar aracılığıyla araştırmacılar, danışmanlar ve tedarikçilerle devam eden iş birliği, yeniliklerin yaygınlaştırılmasını sağlamaktadır (Rosati, 2026).

getirmek için altyapı ve organizasyon yapılarda önemli ayarlamalar el

Hayvancılıkta dijitalleşme, mera yönetimi ve hayvan izleme gibi alanlarda hassas kontrol sağlamak için akıllı sensörler, yapay zekâ algoritmaları ve Nesnelerin İnterneti (IoT) cihazlarını kullanmaktadır. Örneğin, yapay zekâ destekli analitikler sayesinde mera alanlarının gerçek zamanlı izlenmesi ve sürdürülebilir otlatma yönetimi mümkün hale gelmektedir.

Bununla birlikte, doğrulanabilir referans verilerinin eksikliği ve model kalibrasyonu için sınırlı veri çeşitliliği gibi zorluklar devam etmektedir. Sonuç olarak, bu alandaki tüm paydaşlar arasında sürekli yazılım geliştirme ve iş birliği çok önemlidir (Bretas vd., 2023).

Yapay zekâ ayrıca iklim değişikliğinin hayvancılık üzerindeki olumsuz etkilerini azaltmak için önemli bir araç olarak da hizmet vermektedir. Makine öğrenimi, sinir ağları ve derin öğrenme gibi gelişmiş algoritmalar, özellikle geviş getiren hayvanlarda ısı stresini yönetmek, hayvan davranışlarını, fizyolojisini ve sağlık göstergelerini izlemek ve böylece üretim kayıplarını en aza indirmek için kullanılmaktadır. Yapay zekâ tabanlı erken uyarı sistemleri, çiftçilerin hastalık dinamiklerini tahmin etmelerini ve iklimle ilgili risklere hazırlanmalarını sağlar. Bu, hayvancılıkta sürdürülebilir, iklim dostu uygulamaların yaygın olarak benimsenmesini teşvik eder (Rebez vd., 2024).

Yapay zekânın etik ve sorumlu kullanımı, bu sektörde dijital dönüşümün yaygın olarak uygulanması için de çok önemlidir. Çiftçilerin gizliliğini korumak, yapay zekâ sistemlerinin şeffaflığını sağlamak ve hesap verebilirlik ve sürdürülebilirlik ilkelerine bağlı kalmak esastır. Aynı zamanda, kötü tasarlanmış yapay zekâ sistemleri hayvan refahını tehlikeye atabilirken, yetersiz teknolojik altyapı etik ve operasyonel riskler oluşturabilir. Bu nedenle, tarım teknolojisi sağlayıcıları ve politika yapıcılar, bu etik soruları proaktif olarak ele almak için kapsamlı stratejiler geliştirmelidir (Dara vd., 2022).

Hayvancılıkta Endüstri 4.0 teknolojilerinin –yapay zekâ, blok zinciri, robotik, Nesnelerin İnterneti (IoT) ve diğer dijital yeniliklerle birlikte– kullanımı, üretim süreçlerini optimize eder. Bu teknolojiler hayvan refahını, verimliliği ve şeffaflığı artırır. Dijital beceriler ve veriye dayalı karar verme, çiftliklerin küresel pazardaki rekabet gücünü güçlendirir. Bununla birlikte, maliyetler, altyapı gereksinimleri ve veri gizliliği endişeleri gibi engellerin aşılması gerekmektedir (Pletsch vd., 2024).

Özetle, yapay zekâ ve dijitalleşme, hayvancılıkta sürdürülebilirliği, verimliliği ve hayvan refahını iyileştirmek için güçlü araçlar sunmaktadır. Bununla birlikte, bu teknolojilerin etkili ve etik bir şekilde uygulanması,

altyapı ve iş gücü dönüşümünden veri yönetimine ve siber güvenliğe kadar uzanan çok boyutlu stratejilerin geliştirilmesini gerektirmektedir. Bu kapsamlı yaklaşım, hayvancılıkta dijitalleşmenin potansiyel faydalarını en üst düzeye çıkarır ve sektörü sürdürülebilir bir geleceğe hazırlar (Melak vd., 2024; Rebez vd., 2024; Rosati, 2026).

Dijitalleşme sürecinde hayvancılık sektörünün karşılaştığı başlıca zorluklar siber güvenlik, altyapı eksiklikleri, insan faktörleri ve yasal çerçevelerle ilgilidir. Dijital teknolojilerin, büyük verinin, Nesnelerin İnterneti'nin (IoT) ve yapay zekânın hızlı entegrasyonu çiftlik yönetimine önemli ölçüde katkıda bulunurken, bu dönüşüm aynı zamanda önemli riskler ve zorluklar da içermektedir.

Hayvancılığın dijitalleşmesiyle ilgili kritik konulardan biri siber güvenlik açığıdır. Dijitalleşme, sektörü siber saldırılara karşı daha savunmasız hale getirmektedir. Fidye yazılımı, kötü amaçlı yazılım ve devlet destekli siber saldırılar gibi tehditler, çiftlik operasyonlarını aksatabilir, hayvan sağlığı ve refahını tehlikeye atabilir ve gıda güvenliğini tehdit edebilir. Örneğin, sağım süreçlerini, yem formülasyonunu ve iklimlendirme sistemlerini hedef alan saldırılar, önemli üretim kayıplarına yol açmakta ve sektördeki güveni zedelemektedir (Neethirajan, 2025).

Ayrıca, siber güvenlik açıkları, veri bütünlüğü ve korumasıyla ilgili sorunları gündeme getirmektedir. Kişisel verilerin ve tarımsal bilgilerin korunması ve çiftçilerin veri gizliliği hakkının sağlanması büyük bir zorluktur. Bu bağlamda, bir güvenlik kültürünün teşvik edilmesi, personel farkındalığının ve eğitiminin güçlendirilmesi, teknolojik altyapının sağlamlaştırılması ve veri yönetimi politikalarının uygulanması şarttır (Akter vd., 2022; Neethirajan, 2025).

Yapay zekâ destekli hayvancılık dönüşümü için gerekli altyapının eksikliği de büyük bir engeldir. Sensör sistemlerinin optimize edilmesi, veri sistemleri arasında birlikte çalışabilirliğin sağlanması ve sağlam bir teknolojik altyapı ve gerçek zamanlı izleme yeteneklerinin oluşturulması çok önemlidir.

Ayrıca, kırsal alanlarda yeterli internet erişimi ve gerekli teknik ekipmanın sağlanması önemli bir zorluk teşkil etmektedir (Rosati, 2026).

Yapay zekâ ve otomasyon teknolojilerinin yüksek maliyeti, bu yatırımları küçük ve orta ölçekli çiftlikler için zorlaştırmaktadır. Dahası, sistem geliştirme ve entegrasyonla ilgili zorluklar, kullanıcıların teknolojiyi benimsemesini geciktirebilir (Melak vd., 2024).

Dijitalleşme sadece teknolojik uyarlamaları değil, aynı zamanda organizasyonel ve kültürel değişiklikleri de gerektirir. Dijital saha operatörleri ve yapay zekâ sistem yöneticileri gibi yeni rollerin ortaya çıkması ve sürekli eğitim programlarının uygulanması şarttır. Ancak, çalışanların bu geçişe uyum sağlamalarına ve dijital becerilerini geliştirmelerine yardımcı olmak zor olmaktadır. Dahası, farkındalık eksikliği ve yetersiz güvenlik önlemleri siber riskleri artırmaktadır (Akter vd., 2022; Rosati, 2026). Dijitalleşmeden kaynaklanan yasal düzenlemelere uyum da bir zorluk teşkil etmektedir. Veri koruma, yapay zekâ etiği ve siber güvenlik ile ilgili düzenlemeler hızla geliştiğinden, tarım işletmeleri için tam uyumluluğun sağlanması karmaşık bir süreçtir. Yasal çerçeveler, en son teknolojik ve etik standartlarla uyumlu olmalıdır; Bunu yapmamak yasal risklere ve yaptırımlara yol açabilir (Dara vd., 2022; Zubaedah vd., 2024).

Hayvancılığın dijitalleşmesi, çeşitli teknik, ekonomik, insani ve yasal zorluklarla karşı karşıyadır. Özellikle siber güvenlik açıkları, kritik sistemleri tehlikeye atabileceği, üretim süreçlerini aksatabileceği ve hayvan refahını olumsuz etkileyebileceği için önemli riskler oluşturmaktadır. Ayrıca, internet erişim sorunları, yetersiz sensör sistemleri ve yetersiz teknolojik altyapı, yeni teknolojilerin çiftliklere entegrasyonunu engellemektedir. Yüksek teknoloji ve yatırım maliyetleri de küçük çiftliklerin dijital dönüşüme katılımını sınırlayabilir. Teknolojik altyapıya ek olarak, insan faktörü de çok önemli bir rol oynamaktadır: dijital beceri eksikliği ve çalışan eğitimindeki boşluklar, teknolojilerin etkin kullanımını ve bir güvenlik kültürünün oluşturulmasını engellemektedir. Dahası, hızla değişen düzenlemeler ve etik gereklilikler, şirketler için yasal uyumluluğu zorlaştırmaktadır. Bu sorunları ele almak için,

güçlendirilmiş siber güvenlik, teknolojik altyapıya yapılan yatırımın artırılması, düzenli çalışan eğitimi ve yasal uyumluluk için etkili mekanizmaların oluşturulmasını kapsayan bütüncül bir yaklaşıma ihtiyaç vardır

2.2. Doğal Dil İşleme (NLP) ve Büyük Dil Modelleri

Büyük dil modelleri (LLM'ler), yapay zekâ ve dil teknolojilerinde önemli ilerlemeleri temsil etmektedir. Bu iki kavram birbirini tamamlar ve metinleri anlama, oluşturma, özetleme ve çevirmenin yanı sıra çeşitli dil ile ilgili uygulamalar için güçlü çözümler sunar.

Doğal Dil İşleme (NLP), bilgisayarların insan dilini anlamasını, yorumlamasını yapılandırılmamış metin verilerinden anlam çıkarma, bilgi alma, duygu analizi ve metin düzeltme gibi işlevleri içerir. Son yıllarda NLP, biyomedikal literatürün otomatik işlenmesi gibi kritik tıp alanlarında da başarıyla uygulanmıştır. Özellikle, nadir hastalıkları tanımlama ve fenotipleri çıkarma amacıyla elektronik sağlık kayıtlarındaki serbest metin verilerinin analizine dayalı uygulamalar, NLP yöntemlerine olan klinik ilgiyi artırmıştır. Bununla birlikte, veri kıtlığı, model genellemesi ve şeffaflık konularında zorluklar devam etmektedir (Kim vd., 2026; Usuyama vd., 2025) Büyük dil modelleri (LLM'ler), çok geniş metin veri kümeleri üzerinde eğitilen ve çeşitli doğal dil işleme (NLP) görevlerinde kullanılan derin öğrenme modelleridir. Özellikle Transformer mimarisine dayanan modeller; metin üretme, özetleme, çeviri ve soru-cevaplama gibi uygulamalarda önemli ilerlemeler sağlamıştır. GPT, LLaMA ve PaLM gibi modeller üretken dil modelleme yaklaşımlarına örnek teşkil ederken; BERT gibi modeller daha çok bağlamsal metin temsilleri oluşturmak ve dil anlama görevleri için kullanılmaktadır. Ancak, büyük dil modelleri tarafından üretilen yanıtlar her zaman doğru veya doğrulanabilir olmayabilir. Bu nedenle, özellikle alana özgü uygulamalarda, model çıktılarını güvenilir bilgi kaynaklarıyla desteklemek büyük önem taşır. Transformer tabanlı büyük dil modelleri (LLM'ler), doğal dil işlemede (NLP) —özellikle metin üretme, makine çevirisi ve özetleme gibi karmaşık görevlerde— kayda değer iyileştirmeler sağlamış; böylece daha doğal ve verimli bir insan-makine etkileşiminin önünü açmıştır. Üretken yapay zekâ ve LLM

teknolojileri, NLP'yi yeni bir seviyeye taşıyarak daha akıllı ve ölçeklenebilir çözümlerin geliştirilmesine olanak tanımıştır (Yadav, 2024). LLM'ler, özellikle doğal dilde eş anlamlı kelimelerin tespit edilmesi gibi akademik özgünlük ve bilimsel titizlik açısından kritik öneme sahip görevlerde yüksek bir başarı oranı sergilemektedir. Örneğin, LLM tabanlı yöntemler, intihal içeren Urduca cümlelerde eş anlamlı kelimelerin belirlenmesinde %92 ile %98 arasında değişen F1 skorlarıyla mükemmel sonuçlar elde etmiş olup, bu oran önceki yöntemlere kıyasla önemli bir gelişmeyi temsil etmektedir (Iqbal ve diğerleri, 2025).

ve üretmesini sağlamak için geliştirilen tüm yöntemleri kapsar. NLP,

Dil modelleri, özellikle doğal dildeki eş anlamlı kelimeleri belirleme gibi akademik özgünlük ve bilimsel titizlik için kritik öneme sahip görevlerde yüksek başarı oranı sergilemektedir. Görsel ve metinsel verileri birleştiren çok modlu modeller sayesinde, doğal dil işleme (NLP) ve dil modelleri yalnızca metinsel verilere değil, radyoloji gibi alanlara da uygulanabilir hale gelmiştir. Bu çok modlu dil modelleri (MLLM'ler), klinik raporlar ve görüntü tabanlı soru-cevap sistemleri oluşturma gibi görevlerde kullanılarak sağlık hizmetlerinin verimliliğini artırmaktadır. Bununla birlikte, veri gizliliği, önyargı ve yanlış yorumlama (modelin yanlış bilgi üretmesi) gibi sorunlar bu uygulamalar için önemli zorluklar oluşturmaktadır (Yi vd., 2025). Etik kaygılar, yüksek hesaplama maliyetleri, modellerin genelleme ve akıl yürütme yeteneklerindeki sınırlamalar ve yanıltıcı bilgi üretimi, dil modellerinin kullanımıyla ilgili zorluklar arasındadır. Yeni öğrenme yöntemleri, model entegrasyonu ve açıklanabilir yapay zekâdaki gelecekteki gelişmeler, Büyük Dil Modellerinin (LLM'ler) sürdürülebilir, adil, şeffaf olmasını ve minimum düzeyde önyargı sergilemesini sağlamayı amaçlamaktadır (B vd., 2024; "Büyük Dil Modelleri: Gelişmeler, Zorluklar ve Gelecek Yönelimler", 2025).

Hayvancılık sektöründe, Doğal Dil İşleme (NLP) ve LLM'ler aşağıdaki alanlarda dolaylı faydalar sağlayabilir:

Veri Analizi ve Raporlama: Hayvancılık, veteriner kayıtları, hastalık raporları ve yem tüketimi ve üretimiyle ilgili veriler gibi büyük ve genellikle yapılandırılmamış veri kümeleri üretir. NLP teknikleri, bu metinsel verilerin otomatik olarak işlenmesini, yapılandırılmasını ve analizini sağlar. Bu, hayvan sağlığını izlemek ve üretimi optimize etmek için karar destek sistemlerinin geliştirilmesini kolaylaştırır.

NLP bu metinsel verilerin otomatik olarak işlenmesini, teknikleri yapılandırılmasını ve analizini sağlar. Bilgi Çıkarma ve Tanı Desteği: Klinik metinlerden hastalık fenotiplerinin ve tedavi yanıtlarının çıkarılması, nadir hayvan hastalıklarının teşhisinde çok önemli olabilir. İnsan tıbbında bu amaçla LLM'ler kullanılmaktadır. Benzer yaklaşımlar hayvancılıkta da uygulanabilir (Chen vd., 2025; Usuyama vd., 2025).

Eğitim ve bilgi: Yapay zekâ destekli sohbet robotları veya sanal eğitmenler, çiftçilere sağlık, beslenme ve hayvan bakımı gibi konularda tavsiye ve destek sağlayabilir. Eğitim materyalleri otomatik olarak kişiselleştirilebilir ve güncellenebilir (Lee, 2024). • Çok modlu veri entegrasyonu: Görsel (örneğin, hayvan fotoğrafları, ultrason görüntüleri) ve metinsel verileri eş zamanlı olarak işleyen çok modlu sistemler, hastalık teşhisi ve sağlık durumu değerlendirmesi için daha kapsamlı çözümlerin geliştirilmesini sağlar (Yi vd., 2025).

Yapay zekâ destekli yönetim: Üretim, yem, sağlık izleme ve pazar bilgileri gibi çok çeşitli veri kaynakları, LLM ve Doğal Dil İşleme (NLP) tabanlı sistemler kullanılarak entegre edilebilir ve analiz edilebilir. Bu, daha hızlı ve daha doğru yönetim kararlarının alınmasını kolaylaştırır (Linkon vd., 2024; Ramdurai, 2025). Özetle, NLP ve LLM teknolojileri, veterinerlik hizmetleri, üretim yönetimi, otomatik raporlama ve eğitim de dahil olmak üzere birçok alanda hayvancılıkta operasyonel süreçleri optimize edebilir ve karar verme kalitesini artırabilir. Bununla birlikte, bu alandaki pratik uygulamalar ve araştırmalar sınırlı kalmaktadır; özel veri kümeleri, sektöre özgü uyarlamalar ve hayvancılığa özgü etik sorunların dikkate alınmasını gerektirmektedir.

2.3. Yapay Zekâ Destekli Sohbet Robotları

Yapay zekâ tabanlı sohbet robotları, kullanıcıların metin veya konuşma yoluyla insan benzeri konuşmalara çok benzeyen şekillerde etkileşim kurmalarını sağlamak için doğal dil işleme (NLP) ve yapay zekâyı birleştiren sistemlerdir. Eğitim, sağlık ve müşteri hizmetleri gibi alanlarda yaygın olarak kullanılan bu sistemler, bilgiye erişimi, problem çözmeyi ve hatta duygusal desteği kolaylaştırır. Örneğin, sağlık alanında, epilepsi hastalarına destek veren EpiloBot gibi sohbet robotları, yalnızca tıbbi soruları yanıtlamakla kalmaz, aynı zamanda etkileşimleri kullanıcının duygusal durumuna ve öğrenme sürecine göre uyarlayarak psikolojik ve duygusal destek de sunar. Analizler, bu sohbet robotlarının proaktif öğrenmeyi teşvik eden etkileşimler sırasında olumlu duyguları artırdığını, içsel sorularla birlikte duygusal yoğunluğun azaldığını göstermektedir. Dahası, daha iyi hasta bakımı için, sohbet robotlarının tıbbi tavsiyeyi psikolojik destekle birleştiren dengeli, empatik yanıtlar üretmesi çok önemlidir (Watanuki vd., 2025). Sohbet robotunun benimsenmesi, eğitim yazınındaki bibliyometrik dağılım ve sağlık alanında kullanıcı özelliklerine göre değişen kabul yolları ayrı çalışmalarda incelenmiştir (Le, 2023; Lin ve Yu, 2023; Liu, Ho ve Wu, 2026).

Eğitimde, yapay zekâ tabanlı sohbet robotları öğrencilere ve öğretmenlere kişiselleştirilmiş, erişilebilir ve etkileşimli öğrenme deneyimleri sunar. Bu chatbotlar, dil öğreniminden karar verme becerilerinin geliştirilmesine kadar çok çeşitli uygulamalarda kullanılmakta ve gerçek zamanlı iletişim ve uyarlanabilir içerik yoluyla eğitim süreçlerini desteklemektedir. Bununla birlikte, bu alanda etik hususlar ve güvenlik sorunları da dikkate alınmalıdır (Abdallah vd., 2024; Dolianiti vd., 2020; Ramana vd., 2024).

Chatbot tasarımı, doğal dil anlama (NLU), karar mantığı, bilgi tabanları ve makine öğrenme yöntemlerine dayanmaktadır; tüm bu bileşenler, bağlam duyarlı ve doğal yanıtlar üretmek için birlikte çalışır. Bu, kullanıcı sorgularına hızlı ve doğru yanıtlar verilmesini sağlar ve 7/24 kullanılabilirlik ve insan kaynaklarında tasarruf gibi avantajlar sunar (Borah vd., 2019; Meshram vd., 2021).

Psikolojik ve manevi destek sunan yapay zekâ tabanlı chatbotlar, kullanıcılara kişiselleştirilmiş, empatik etkileşimler sağlayarak kişisel bilgilerin

paylaşımında güveni artırır. Bununla birlikte, yanlış bilgilendirme, veri gizliliği endişeleri ve bağımlılık riski gibi zorluklar da sunmaktadırlar. Sonuç olarak, algoritmik etki değerlendirmeleri ve etik hususlar, chatbot'ların güvenli ve etkili kullanımı için elzemdir (Kneese vd., 2025).

Yapay zekâ destekli robotlar, hayvancılıkta önemli bir değişim aracı haline gelmiş, verimliliğin ve sürdürülebilirliğin artmasına ve hayvan refahının iyileştirilmesine katkıda bulunmuştur. Bu teknolojinin hayvancılıkta uygulanması, hayvan sağlığı izleme, davranış analizi, yem optimizasyonu, üretim süreci otomasyonu ve kaynak azaltımı gibi önemli alanlarda umut verici sonuçlar vermektedir.

Hayvancılıkta otomasyon sistemlerinin benimsenmesi, özellikle yapay zekâ (YZ) ve robotik entegrasyonu yoluyla ilerleme kaydediyor. Bu sistemler, sensörler ve görüntü işleme teknolojileri kullanarak hayvanların faaliyetlerini, barınma koşullarını, sağlıklarını ve davranışlarını sürekli olarak izliyor. Bu, hastalıkların erken teşhisini, stresli durumların belirlenmesini ve hayvan refahının iyileştirilmesini sağlıyor. YZ destekli veri analizi yetenekleri, toplanan bilgileri işleyerek çiftçilere karar verme için doğru ve zamanında öneriler sunuyor. Dahası, YZ özellikli robotlar, otomatik yemleme, temizlik ve sağım gibi rutin işler için manuel iş gücüne olan ihtiyacı azaltarak işçilik maliyetlerini düşürüyor ve operasyonel verimliliği artırıyor (Melak vd., 2024).

Dronlar, robotlar ve YZ algoritmalarıyla desteklenen süreç otomasyonu ve izleme sistemleri, hayvancılıkta yaygınlaşarak daha sürdürülebilir ve çevre dostu üretim yöntemlerini teşvik ediyor. Örneğin, hayvanların aşılanması, cinsiyetinin belirlenmesi ve tanımlanması için otomatik sistemler, üretim sırasında insan hatasını en aza indirerek kalite standartlarını yükseltiyor. Birlikte ele alındığında, bu teknolojiler -karbon ayak izinin azaltılmasıyla birlikte- gıda kaynaklarının verimli yönetimi ve hayvancılıkta sürdürülebilirlik hedeflerine ulaşmada çok önemli bir rol oynamaktadır (Melak vd., 2024).

Ayrıca, Nesnelerin İnterneti (IoT) tabanlı ve yapay zekâ ile birleştirilmiş robotik sistemler, hayvancılıkta ve daha geniş tarım sektöründe çevresel ve biyometrik verilerin (sıcaklık, nem, hareket, biyometrik göstergeler vb.) gerçek

zamanlı olarak toplanmasını ve analizini mümkün kılmaktadır. Bu veriler yapay zekâ algoritmaları tarafından işlenir ve anormallik tespiti, hastalık risklerinin erken teşhisi ve üretim optimizasyonu için kullanılır. Bu, hayvancılıkta kaynak israfını azaltırken, üretim kalitesini ve hayvan sağlığını korur. Robot destekli otomasyon sistemleri, hayvan davranışlarının uzaktan izlenmesini ve kontrolünü sağlar. Bu teknolojiler, özellikle süt çiftlikleri gibi büyük ölçekli işletmelerde giderek daha yaygın hale gelmektedir (R&C, 2024; Vitale vd., 2025).

Yapay zekâ ve robotik uygulamalarının hayvancılık sektörüne bir diğer önemli katkısı ise sürdürülebilirlik hedeflerini desteklemeleridir. Yapay zekâ destekli sistemler, yem ve su tüketimini optimize ederek doğal kaynakların korunmasına yardımcı olurken, veri odaklı karar verme yoluyla çevresel etkiyi azaltır. Dahası, bu teknolojiler hayvancılık verimliliğini artırarak ek tarım arazisine olan ihtiyacı azaltır ve ekosistemler üzerindeki baskıyı hafifletir (Kuli vd., 2025; Melak vd., 2024).

Ancak, bu yeniliklerin hayvancılık sektöründe yaygın olarak benimsenmesi çeşitli zorluklarla karşı karşıyadır. Bunlar arasında yüksek başlangıç yatırımları, altyapı eksiklikleri ve teknik uzmanlık ihtiyacı yer almaktadır. Ayrıca, otomasyonun insan emeğinin yerini tamamen alamaması, veri güvenliği gibi sorunlarla birleştiğinde önemli bir sınırlama oluşturmaktadır (Melak vd., 2024; Warbhe vd., 2024).

Hayvancılık alanında yapay zekâ uygulamaları, fiziksel süreçlerin otomasyonu ve sensör tabanlı izleme sistemlerinin ötesine geçmektedir. Doğal dil işleme teknolojilerinden yararlanan sohbet botları; bilimsel bilgilere ve çiftlik kayıtlarına erişimi kolaylaştırarak yeni olanaklar sunmaktadır. Ancak, büyük dil modelleri yanıtlarını yalnızca daha önce öğrenilmiş bilgilere dayanarak oluşturduklarından, özellikle alana özgü verilerin doğrulanabilirliği konusunda birtakım doğal sınırlamalara sahiptirler. Bu nedenle, yanıt oluşturma sürecine harici bilgi kaynaklarını dahil eden "Geri Getirme Destekli Üretim" (Retrieval-Augmented Generation, RAG) yaklaşımı, özel amaçlı sohbet botlarının geliştirilmesinde giderek daha fazla önem kazanmaktadır.

2.4. Retrieval-Augmented Generation (RAG)

Geri Getirme Destekli Üretim (Retrieval-Augmented Generation – RAG) , doğal dil işleme (NLP) alanında giderek önem kazanan bir yaklaşımdır. RAG, üretim aşamasına harici verileri dahil ederek, yalnızca önceden öğrenilmiş bilgilere dayanan dil modellerinin sınırlamalarının üstesinden gelir. Bu, metin üretimi sırasında daha güncel, doğru ve bağlam açısından zengin içerik üretilmesine olanak tanır. RAG genellikle iki adımda çalışır: ilk olarak, kullanıcının sorgusu için en alakalı veriler harici bilgi kaynaklarından alınır (alma); ikinci olarak, dil modeli bu bilgiyi kullanarak kullanıcının sorusunu veya isteğini yanıtlayan, olgusal olarak doğru metin üretir (üretim) (Shahade & Deshmukh, 2024).

Bu yaklaşımın önemli bir avantajı, büyük dil modellerinde sıkça karşılaşılan ve modelin yanlış ya da olgusal temelden yoksun bilgiler üretmesi anlamına gelen

"halüsinasyon" sorununu hafifletmesidir. RAG, yanıt oluşturma sürecinde harici bilgi kaynaklarından yararlanarak, desteklenmeyen içerik üretme riskini azaltmaya yardımcı olabilir. Bununla birlikte, bilgi getirme aşamasında konuyla ilgisiz verilerin elde edilmesi veya dil modelinin kendisine sunulan kaynakları yanlış yorumlaması durumunda, sistem yine de hatalı yanıtlar ya da kaynak materyale dayanmayan içerikler üretebilir (Gupta, 2025). Mimari açıdan RAG sistemleri; bilgi getirme (retrieval) modülü, içerik oluşturma (generation) modülü ve bir bilgi tabanı olmak üzere üç temel bileşenden oluşur. Bu bileşenlerin etkin bir şekilde entegre edilmesi kritik öneme sahiptir ve RAG sistemlerinin performansını doğrudan etkiler. Ayrıca, bilgi getirme ve içerik oluşturma stratejileri, farklı uygulamaların kendine özgü gereksinimlerini karşılayacak şekilde uyarlanabilir (Gu, 2025; Oche ve diğerleri, 2025).RAG, birçok bilgi tabanlı NLP uygulamasında kullanılır. Özellikle akademik bilgi alma, soru-cevap sistemleri, metin özetleme ve bilgi tabanlı diyalog sistemleri gibi alanlarda güçlü performans sergiler. Bu sistemler, bilgi alma ve oluşturma modüllerinin performansını ölçen birden fazla metrik kullanılarak değerlendirilir. Bu değerlendirmeler, dinamik bilgiye

dayanan RAG'ın karmaşık yapısıyla uyumlu bir şekilde yapılmalıdır (Cheng vd., 2025; Gan vd., 2025; Yu vd., 2024). Özetle, Geri Getirme Destekli Üretim (RAG), büyük dil modellerinin bilgi tabanını, gerçek zamanlı veya güncellenmiş verileri harici kaynaklardan alarak dinamik olarak genişleten ve böylece doğruluğu bağlamsal zenginlikle birleştiren hibrit bir doğal dil işleme yaklaşımıdır. Bu teknoloji, yanlış bilgiyi azaltmak ve bilgi tabanlı sistemlerin kapsamını genişletmek için doğal dil işleme (NLP) alanında çok önemli bir adımı temsil etmektedir (Gupta, 2025; Oche vd., 2025; Shahade & Deshmukh, 2024).

Geri Getirme Destekli Üretim (RAG) sistemlerinde, bilgi edinme ve metin oluşturma bileşenleri arasındaki etkileşimin optimize edilmesi, her bir bileşenin ve sistemin genel performansını iyileştirmek için çok önemlidir. Optimize edilmiş etkileşim, yalnızca bireysel bileşenlerin optimizasyonunu değil, aynı zamanda veri akışı, bağlam kullanımı, temsil ve entegrasyon stratejilerine yönelik bütünsel bir yaklaşımı da gerektirir.

Öncelikle, bilgi alma bileşeninin optimizasyonu, metin üretiminin altında yatan bilginin doğruluğu ve bağlamsal zenginliği için çok önemlidir. Modern yaklaşımlar, metinler içindeki anlamsal ve yapısal ilişkileri daha iyi yakalamak için, örneğin Bağlamsal Bilgi Grafiği Oluşturma (CKGC) gibi yöntemler kullanarak, bilgi yapılarının dinamik olarak oluşturulmasını tercih eder. CKGC, metin analizi yoluyla temel varlıkları ve ilişkileri belirler ve bunları bağlamsal olarak bilgi grafiğine entegre eder. Bu, alma sürecinin yalnızca yüzeysel anlamsal benzerliklere değil, ilişkilerin daha derin bir anlayışına dayanmasını sağlayarak, alınan verilerin bağlamsal tutarlılığını ve bilgi yoğunluğunu artırır (Mankari & Sanghavi, 2024).

Optimizasyon için bir diğer önemli alan, alınan belgelerin üretim sistemine etkili bir şekilde entegre edilmesidir. RAG sistemlerinde, alma sonuçları metin üreticisine uygun bir biçimde sunulmalıdır. Burada öbek boyutu, sorgu genişletme teknikleri, istem tasarımı ve bağlam yönetimi gibi faktörler rol oynar. Örneğin, uygun uzunlukta belge parçaları seçmek, bilgi yoğunluğu ve işlem çabası arasında bir denge kurduğu için doğruluk ve hız

açısından avantajlar sunar. Dahası, bağlam içi karşılaştırmalı öğrenme gibi yeni yöntemler, sorgu bağlamı içindeki ilgili bilgilerin analizini ve belirli amaca uygun içeriğin önceliklendirilmesini sağlar. Bu, alma ve oluşturma süreçleri arasında daha yakın bir bağlamsal bağlantıyı teşvik eder (Li vd., 2025). RAG bileşenlerinin etkileşimini daha da güçlendiren pratik bir çözüm, dinamik anlamsal öbekleme kullanımıdır. Bu yöntem, verilerin alma işlemi sırasında içerik ve bağlamsal ilişkilerin korunacağı şekilde bölümlere ayrılmasını sağlar ve bu da alma sonuçlarının kalitesini doğrudan iyileştirir. Bu şekilde, oluşturma aşamasında sağlanan her bilgi parçası daha tutarlı ve hedefli bir bağlamda işlenir. Ayrıca, optimize edilmiş indeksleme ve FAISS HNSW (yaklaşık en yakın komşu indeksi) ve ayrı bir çapraz kodlayıcı ile yapılan yeniden sıralama, üretim aşamasına iletilen bilgilerin alaka düzeyini ve sıralamasını artırır (Arthana vd., 2026; Tanyildiz vd., 2024).

Uyarlanabilir etkileşimlerin ve modüler yapay zekâ hizmet mimarilerinin özel senkronizasyonu güçlendirir. Örneğin, hastane konsültasyon sistemlerinde, alan özelinde yönlendirme stratejileri ve çok seviyeli sesli etkileşim gibi özellikler, üretim sırasında geri alınan bilgilerin hassas ve kişiselleştirilmiş kullanımını sağlar. Bu tür senaryolarda, bileşenler arasındaki bilgi akışı yalnızca metin tabanlı etkileşimlerle değil, aynı zamanda çok modlu ve etkileşimli dinamiklerle de desteklenir (Pan & Su, 2026).

uygulam kullanılması, geri alma ve üretim bileşenleri arasındaki alarda

Son olarak, RAG sistemlerinde geri alma ve üretim arasındaki etkileşimin optimize edilmesi, dinamik geri bildirim mekanizmalarının uygulanmasını da içerir. Bu, elde edilen bilgilere dayalı olarak oluşturulan metnin değerlendirilmesinden sonra elde edilen sonuçların kalite ve tutarlılık açısından analiz edildiği ve buna göre arama stratejilerinin ayarlandığı anlamına gelir. Bu ayarlama, sistemin öğrenme ve geliştirme yeteneklerini güçlendirir. Ayrıca, uyumluluğu sağlamak için arama ve oluşturma parametrelerinin ve yapılandırmalarının optimize edilmesi, daha tutarlı ve güvenilir sonuçlara yol açar (Arthana vd., 2026; Li vd., 2025; Shahade & Deshmukh, 2024).

Literatürde, RAG sistemlerinin performansını artırmaya yönelik; dinamik metin parçalama, bilgi grafikleri, yeniden sıralama (re-ranking) ve geri bildirim temelli optimizasyon gibi çeşitli yaklaşımlar bulunmaktadır. Bu yöntemler, RAG mimarilerini geliştirmek için kullanılan alternatif tekniklerdir ve tüm RAG uygulamalarında mutlaka bir arada kullanılmaları gerekmez. Bu araştırma kapsamında geliştirilen prototipin teknik bileşenleri ve uygulanan yöntemler, üçüncü bölümde daha ayrıntılı olarak açıklanmıştır.

Özetle, RAG sistemlerinde bilgi alma ve metin oluşturma bileşenleri arasındaki etkileşim aşağıdaki yaklaşımlarla optimize edilir:

Bağlamsal bilgi yapılarının oluşturulması: Bağlamsal bilgi grafikleri oluşturarak arama verilerini zenginleştirme ve bağlam bütünlüğünü güçlendirme.

Dinamik ve anlamlı öbekleme: Arama ve oluşturma süreçlerinde metin parçalarının uzunluğunu ve anlamsal yoğunluğunu optimize etme.

Gelişmiş arama stratejileri: İndeksleme ve yeniden sıralama teknikleri aracılığıyla arama sonuçlarının kalitesini iyileştirme.

Bağlamsal entegrasyon ve komut istemi tasarımı: Sorgu genişletme, karşılaştırmalı öğrenme ve uyarlanabilir komut istemi kullanımı yoluyla arama bilgilerini oluşturma aşamasına verimli bir şekilde aktarma.

Modüler ve uyarlanabilir mimari kullanımı: Özellikle uzmanlaşmış alanlardaki uygulamalar için çok modlu ve katmanlı etkileşimleri arama ve oluşturma süreçlerine entegre etme.

Geri bildirim döngüleri: Oluşturma sonuçlarına dayalı olarak arama stratejilerini sürekli olarak optimize etme. Bu çok bileşenli optimizasyon yaklaşımları, RAG sistemlerinin doğruluk ve tutarlılık açısından üstün performans elde etmelerini sağlarken, gerçek dünya uygulamalarında dinamik, doğru ve kullanıcı merkezli sonuçlar sunmalarına olanak tanır (Arthana vd., 2026; Li vd., 2025; Mankari & Sanghavi, 2024; Pan & Su, 2026; Shahade & Deshmukh, 2024).

RAG sistemlerinde, dinamik geri bildirim mekanizmaları, bilgi alma ve metin üretimi bileşenleri arasındaki etkileşimi optimize ederek model performansını önemli ölçüde iyileştirir. Bu mekanizmalar, alma zamanlamasını ve alınan bilginin kalitesini dinamik olarak kontrol ederek, gereksiz veya düşük kaliteli verilerin kullanımını önlerken, üretilen metnin doğruluğunu ve

bağlamsal uygunluğunu artırır. Özellikle, DioR mekanizması, geri bildirim yoluyla uyarlanabilir bilişsel farkındalığı ve bağlam duyarlı bilgi alma optimizasyonunu kolaylaştırır. Bu yöntem, bilgi almanın ne zaman gerçekleşmesi gerektiğini dinamik olarak belirler ve üretim süreciyle ilgili bilgileri tanımlar. Bu, arama tetikleyicileri ve içerik doğrulaması üzerindeki kontrolü iyileştirir. Büyük dil modeli (LLM) tabanlı sistemlerde hatalı bilgi (halüsinasyon) üretme riskini azaltır ve genel performansı artırır (Guo vd., 2025). Ayrıca, dinamik geri bildirim yaklaşımları, arama ve üretim bileşenleri arasında karşılıklı etkileşimi mümkün kılar. Metin üretimi, arama sonuçlarına göre değerlendirilir ve bu sonuçlar arama stratejisini ayarlamak için kullanılır. Bu döngüsel geri bildirim, hem arama algoritmalarının hem de üretim yaklaşımlarının sürekli olarak gelişmesini sağlar. Sonuç olarak, sistemler gelişen bilgi ihtiyaçlarına esnek bir şekilde yanıt verebilir ve doğruluk ve tutarlılık sağlayan sonuçlar üretebilir (Cheng vd., 2025; Gu, 2025). Pratik uygulamalarda, dinamik geri bildirim, arama sürecinde dinamik öbekleme ve optimize edilmiş vektör arama yöntemlerine dayanır. Dinamik öbekleme, bağlamsal bütünlüğü koruyan ve gereksiz bilgi yükünü azaltan stratejiler sunarak arama sonuçlarının kalitesini artırır. Gelişmiş indeksleme yöntemleri (örneğin, FAISS HNSW) ve çapraz kodlayıcı modelleri kullanılarak yapılan sonraki bir yeniden sıralama aşaması, sonuçların üretim aşamasına geçmeden önce doğruluğunu artırır. Bu süreç, geri bildirim mekanizmasının verimli çalışmasını sağlar ve metin üretimi için yüksek kaliteli, bağlamsal olarak tutarlı girdi verileri sağlar (Tanyildiz vd., 2024).

Ayrıca, sistemin yanıtlarının doğruluğu, bağlamsal uygunluğu ve tutarlılığı, geri bildirim mekanizmaları aracılığıyla sürekli olarak izlenir. Sistem performans metriklerine dayalı ayarlamalar, arama stratejisinin ve üretim modeli parametrelerinin gerçek zamanlı optimizasyonunu sağlar. Bu, son kullanıcıya sağlanan bilginin kalitesini artırırken kaynakların verimli kullanımını sağlar (Cheng vd., 2025)

Özetle, RAG sistemlerindeki dinamik geri bildirim mekanizmaları etkilidir ve aşağıdaki gibi uygulanır:

Retrieval tetikleme ve içerik seçiminin adaptif kontrolü: Ne zaman ve ne tür bilgilerin getirilip kullanılacağı dinamik olarak belirlenir, böylece bilgi kalitesi ve üretim tutarlılığı artırılır (Guo vd., 2025).

Geri dönüşlü veri akışı: Üretilen metinlerin kalitesi değerlendirilerek retrieval stratejileri gerçek zamanlı olarak uyarlanır, böylece sistem sürekli öğrenir ve gelişir (Cheng vd., 2025).

Dinamik chunking ve optimize indeksleme: Metin parçalarının işlenmesi ve retrieval sonrası yeniden sıralama süreçleri geri besleme döngüsünü destekleyerek doğruluk ve bağlamsal uygunluğu maksimize eder (Tanyildiz vd., 2024).

Performans izleme ve parametre optimizasyonu: Sürekli performans ölçümleri geri besleme için referans olur ve retrieval ile generation bileşenlerinin parametreleri canlı olarak optimize edilir.

Bu araştırmada RAG yaklaşımı, süt sığırcılığına ilişkin bilimsel belgelerden kullanıcı sorgularıyla ilişkili içeriklerin getirilmesi ve büyük dil modeli tarafından oluşturulan yanıtlarda kullanılması amacıyla uygulanmıştır. Bilgi erişim aşamasında anlamsal arama ve sözcüksel arama yöntemlerinden yararlanılmış, ayrıca bu yöntemlerin sonuçlarını birleştiren hibrit bir bilgi erişim mekanizması geliştirilmiştir. Farklı bilgi erişim yöntemlerinin performanslarının karşılaştırılması, RAG bileşeninin deneysel değerlendirilmesinin temel unsurlarından birini oluşturmaktadır.

2.5. LangChain ve RAG Tabanlı Sistemler

LangChain ve Geri Getirme Destekli Üretim (RAG) sistemleri, Büyük Dil Modelleri (LLM'ler) kullanarak harici kaynaklardan dinamik olarak bilgi alarak doğal dil işleme yeteneklerini geliştirmek için tasarlanmış teknolojilerdir. Özellikle RAG, kullanıcı sorgularına dayalı olarak gerçek zamanlı veya kapsamlı veritabanlarından ilgili içeriği alarak ve bunu metin üretimine bağlayarak LLM'lerdeki bilgilerin güncelliği ve doğruluğuyla ilgili sınırlamaları gidermek için geliştirilmiştir (Oche vd., 2025; Shahade & Deshmukh, 2024).

LangChain ise, RAG sistemleri de dahil olmak üzere LLM tabanlı uygulamalar içinde bilgi alma, işleme ve üretimini programatik olarak düzenleyen bir altyapı ve araç zinciri sağlar. Uygulamada bu, RAG sistem bileşenlerinin modüler montajı yoluyla karmaşık bilgi işleme iş akışlarının oluşturulmasını sağlar: bilgi alma, bellek yönetimi, bağlantılar ve ilgili API çağrıları. Bu, LangChain kullanıcılarının arama işlemlerini (örneğin, özel veri depolarında, API'ler aracılığıyla veya belge koleksiyonlarında) LLM'lerle daha etkili bir şekilde entegre etmelerini sağlar (Gu, 2025; Oche vd., 2025).

RAG sistemleri tipik olarak statik bir alma-sonra-oluşturma yaklaşımıyla çalışır, ancak modern araştırmalar dinamik alma ve parametrik RAG (alınan bilgileri parametre düzeyinde işleme) gibi gelişmiş yöntemlere odaklanmaktadır. Bu yaklaşımlar, LangChain gibi platformlar aracılığıyla programatik olarak kontrol edilebilir ve optimize edilebilir; dinamik alma, gerçek zamanlı bilgilerin ve bağlamsal entegrasyonun kullanımını iyileştirir (Su vd., 2025).

Ayrıca, RAG sistemlerinde kullanılan alma teknikleri, gömme tabanlı vektör aramasını geleneksel anahtar kelime tabanlı aramayla birleştiren hibrit uygulamaları içerir. LangChain, bu çeşitli alma stratejilerini destekler ve belirli uygulama bağlamına uyarlanabilen bilgi erişimi sunar. Bu, hem büyük ölçekli uygulamalar hem de uzmanlaşmış alanlar (hukuk, tıp ve finans gibi) için güncel ve tutarlı bilgilerin üretilmesini sağlar (Kiran, 2025; Oche vd., 2025).

Özetle, LangChain, RAG sistemleri için bileşenlerin ve iş akışlarının organizasy ve programlanması kolaylaştırırken RAG, Büyük Dil onunu nı Modellerinin (LLM'ler) harici bilgi kaynaklarına dayalı olarak doğru, güncel ve bağlamsal olarak ilgili metinler üretmesini sağlar. Bu iki aracın birlikte kullanımı, Büyük Dil Modellerinin gerçek dünya bilgi kaynaklarıyla entegrasyonunu hızlandıran daha esnek, ölçeklenebilir ve uygulama odaklı çözümlerle sonuçlanır (Gu, 2025; Oche vd., 2025; Shahade & Deshmukh, 2024).

RAG sistemlerinde, dinamik geri alma yöntemleri, bilgilerin güncel tutulmasında çok önemli bir rol oynar. Bu yöntemler, statik "al-sonra-oluştur" süreçlerinin ötesine geçerek, dış kaynaklardan en güncel ve ilgili bilgilerin

gerçek zamanlı olarak dinamik bir şekilde alınmasını sağlar. Bu, büyük dil modellerinin (LLM'ler) yalnızca önceden öğrenilen bilgilere değil, aynı zamanda ilgili, doğru ve gerçek zamanlı olarak güncellenen verilere de erişmesine olanak tanır. Özellikle, dinamik bilgi alma sistemlerinin uyarlanabilir mekanizmaları, sorgu içeriğine bağlı olarak bilgi alma stratejilerini otomatik olarak seçer ve optimize eder. Örneğin, RAP-RAG mimarisi, hem küçük hem de büyük modellerle uyumlu olan, örneğin anlamsal benzerlik ve yapısal bağlantıya dayalı heterojen indeks yapılarıyla verimli bilgi alma yöntemlerini birleştirir. Bu uyarlanabilir planlama, çok aşamalı sorgular ve karmaşık bağlamlarda hızlı bilgi erişimi sağlar (Ji vd., 2025).

Dinamik bilgi erişim yöntemlerinin bilgi güncelliğine katkısı, metinleri anlamlı ve bağlamsal olarak ilgili bölümlere ayırarak (dinamik öbekleme) elde edilen gelişmiş indeksleme ve yeniden sınıflandırma mekanizmalarına dayanmaktadır. Bu tekniklerle, yalnızca ilgili bölümler alınır, böylece kullanıcıya özgüllük ve bağlamsal doğruluk artırılır. Örneğin, FAISS üzerinde HNSW yaklaşık en yakın komşu indeksi ve bundan ayrı bir çapraz kodlayıcı ile yeniden sıralama metodolojisi, erişim kalitesini iyileştirir ve doğru bilgileri güncel veritabanlarından üretim aşamasına verimli bir şekilde aktarır (Tanyildiz vd., 2024). Ayrıca, dinamik erişim, dil modellerindeki eski verilerden kaynaklanan bilgi boşluklarını ve hataları en aza indirir. Uyarlanabilir tetikleme mekanizmaları gibi gelişmiş yöntemler, belirli bilgilerin ne zaman alınması gerektiğini tespit eder. Bu, gereksiz erişimleri önler ve modele yalnızca kritik ve güncel içeriğin aktarılmasını sağlar. DioR yöntemi bu yaklaşıma örnek teşkil eder. Uyarlanabilir bilişsel tanıma ve bağlam tabanlı optimizasyon yoluyla bilgi alma tetikleme ve içerik seçimini iyileştirerek modelin yanıtlarının doğruluğunu ve zamanlamasını sağlar (Guo vd., 2025).

Genel olarak, dinamik bilgi alma yöntemleri, RAG sistemlerinde bilgi zamanlamasını aşağıdaki şekillerde iyileştirir:
Gerçek zamanlı uyarlama: En alakalı bilgilerin anında ve bağlama duyarlı

seçimi, eski veya alakasız verilerin kullanımını önler (Cheng vd., 2025; Ji vd., 2025).

Gelişmiş indeksleme ve yeniden sınıflandırma: Bağlamsal tutarlılığı sağlayan dinamik dilimleme ve verimli vektör arama yöntemleri, doğruluğu ve alaka düzeyini artırır (Tanyildiz vd., 2024).

Uyarlanabilir bilgi alma tetikleme: Alınacak bilginin zamanlamasının ve niteliğinin otomatik olarak algılanması yoluyla gereksiz sorgular azaltılır. Güncel ve alakalı bilgilere öncelik verilir (Guo vd., 2025). Çok aşamalı ve heterojen arama: Çeşitli arama tekniklerinin ve heterojen veri yapılarının dinamik seçimi, hem verimliliği hem de güncel içeriğe erişimi iyileştirir (Ji vd., 2025).

2.6. Veri Tabanları ve Yapay Zekâ Entegrasyonu

Veritabanları ve yapay zekânın entegrasyonu, her iki teknolojinin de güçlü yönlerini birleştirerek veri yönetimi, analizi ve karar destek sistemlerinde önemli ilerlemeler sağlar. Yapay zekâ (YZ), büyük ve karmaşık veri kümelerinden ilgili içgörüleri çıkarmak için gelişmiş algoritmalar ve öğrenme yöntemleri sunarken, veritabanları bu verilerin yapılandırılmış depolanmasını, yönetimini ve hızlı erişimini sağlar. Bu entegrasyon, çok sayıda alanda veri odaklı uygulamaların doğruluğunu, verimliliğini ve ölçeklenebilirliğini artırır. YZ yöntemleri -özellikle makine öğrenimi ve derin öğrenme algoritmaları- veritabanlarında depolanan çok miktarda heterojen veri üzerinde otomatik örüntü tanıma, sınıflandırma ve tahmin gibi işlemleri verimli bir şekilde gerçekleştirir. YZ ve veritabanı sistemlerinin birleşimi, elektronik sağlık kayıtları, finansal işlemler ve üretim verileri gibi alanlarda karmaşık veri kümelerinin analizinde çok önemli bir rol oynar (Clement David-Olawade vd., 2026; Saha vd., 2026).

Yapay zekâ tabanlı yöntemler, doğal dille ifade edilen kullanıcı sorgularının veritabanı sorgularına dönüştürülmesini sağlayarak verilere erişimi kolaylaştırır. doğal dil işleme (NLP) ve bilgi erişim sistemleri, kullanıcı taleplerini daha iyi anlamak ve anlamsal açıdan zengin, veritabanına özgü sorgular oluşturmak için özellikle kullanılır. Bu sayede kullanıcılar, doğal dili

kullanarak sistemle etkileşime girip karmaşık sorguları kolaylıkla gerçekleştirebilirler. Söz konusu süreç, bilgi erişimi ile metin oluşturma bileşenlerinin yakın iş birliği içinde çalıştığı, RAG gibi sistemler için de önemli bir uygulama alanı oluşturur (Barrios-González ve diğerleri, 2026; Shahade & Deshmukh, 2024). Veritabanları ile yapay zekânın entegrasyonu, gerçek zamanlı ve bağlama duyarlı öneriler sunmak amacıyla karar destek sistemlerinde de kullanılır. Örneğin sağlık sektöründe, hasta verilerini toplamak ve işlemek üzere tasarlanmış yapay zekâ modelleri, klinik kararlara yön verecek tahminler üretebilir; veritabanları ise bu verilere hızlı ve güvenli erişim sağlar. Sonuç olarak, veri yönetimi ile yapay zekâ destekli analiz süreçleri eş zamanlı ve kesintisiz bir şekilde gerçekleşir (Ong ve diğerleri, 2022; Pan & Su, 2026). Günümüzün hızla gelişen teknolojik ekosisteminde, yapay zekâ ve veritabanlarının entegrasyonu, donanımdan yazılım altyapısına kadar çok geniş bir yelpazeye yayılmaktadır. Özellikle Büyük Veri (Big Data), Nesnelerin İnterneti (IoT) ve Endüstri 4.0'ın etkisiyle ortaya çıkan büyük ve dinamik veri kümelerini işleme ihtiyacı, yapay zekâ tabanlı veri yönetimi çözümlerine olan talebi artırmıştır. Bu bağlamda, veriye dayalı yapay zekâ yöntemlerinin sunduğu makine öğrenimi ve uyum sağlama yetenekleri, veritabanı sistemlerinin ölçeklenebilirliğini ve analitik performansını geliştirmek için vazgeçilmezdir (Ghazo & Salah, 2026; Song ve diğerleri, 2025).

Ayrıca, veritabanı sorgularını optimize etmek için yapay zekâ tabanlı teknikler kullanılmaktadır. Özellikle doğal dil işleme ve bilgi alma sistemleri, kullanıcı isteklerinin daha iyi anlaşılmasını ve anlamsal olarak zengin, veritabanına uygun sorguların oluşturulmasını sağlar. Bu, kullanıcıların doğal dil kullanarak karmaşık sorguları basit ve sezgisel bir şekilde yürütmelerine olanak tanır. Bu süreç, bilgi alma ve metin oluşturmanın birlikte çalıştığı geri getirme destekli üretim (RAG) gibi sistemler için de önemli bir uygulama alanıdır (Barrios-González vd., 2026; Shahade & Deshmukh, 2024).

Günümüzün dinamik teknoloji ekosisteminde, yapay zekâ (YZ) ve veritabanlarının entegrasyonu, donanımdan yazılım altyapısına kadar çeşitli

alanlarda uygulama bulmaktadır. Özellikle, Büyük Veri, Nesnelerin İnterneti (IoT) ve Endüstri 4.0 tarafından üretilen yüksek hacimli ve hızlı verilerin yönetimi ihtiyacı, YZ destekli veri yönetimi çözümlerine olan talebi artırmıştır. Bu bağlamda, YZ yöntemlerinde -özellikle makine öğrenimi ve adaptif sistemlerde- bulunan veri işleme yetenekleri, veritabanı sistemlerinin ölçeklenebilirliğini ve analitik yeteneklerini artırmak için çok önemlidir (Ghazo & Salah, 2026; Song vd., 2025). YZ ve veritabanlarının entegrasyonu, çeşitli sektörlerde önemli bir etkiye sahiptir. Bu entegrasyonun etkileri özellikle sağlık, finans, üretim, siber güvenlik, tarım, eğitim ve enerji sektörlerinde belirgindir.

Sağlık sektörü, YZ ve veritabanlarının entegrasyonu sayesinde tanı doğruluğu, hastalık tahmini ve kişiselleştirilmiş tedavi planlamasında önemli ilerlemeler kaydetmektedir. Yapay zekâ (YZ), büyük veri analitiğiyle birleştiğinde, tıbbi kayıtlardan gelen bilgileri verimli bir şekilde işler, tanı süreçlerini hızlandırır ve tedavi sonuçlarını iyileştirir (Almanasra, 2024; Weng vd., 2024). Finans sektörü, risk değerlendirmesi, dolandırıcılık tespiti, finansal tahmin ve stratejik karar alma için YZ odaklı büyük veri analitiğinden yoğun bir şekilde yararlanmaktadır. Bu entegrasyon, finans kurumlarının gerçek zamanlı verileri işleyerek ve müşteri hizmetlerini optimize ederek piyasa dalgalanmalarına hızlı bir şekilde tepki vermesini sağlar (Ahmed vd., 2025; Weng vd., 2024).

Üretim ve tedarik zinciri yönetiminde, YZ tabanlı ERP sistemleri ve tedarik zinciri optimizasyon araçları, süreç verimliliğini artırır, envanter ve lojistik yönetimini iyileştirir ve işletme maliyetlerini düşürür. YZ tabanlı tahmin ve otomasyon sistemleri, üretim süreçlerinde sürekli verimlilik sağlar (Adenekan vd., 2024; Singh, 2024).

Siber güvenlik sektörü, siber tehditleri tespit etmek ve bunlarla mücadele etmek için YZ ve büyük veri analitiğini kullanarak güvenlik duruşunu güçlendirmektedir. Yapay zekâ algoritmaları, anomali tespiti ve tehdit analizinde yüksek doğruluk sunarken, büyük veri platformları hızlı ve ölçeklenebilir işleme yetenekleri sağlar (Ansari vd., 2022; Arif vd., 2025; Nugroho vd., 2024). Tarım ve akıllı tarımda, yapay zekâ ve veritabanlarının entegrasyonundan yararlanılarak toprak, hava ve ürün verilerinin analizi yoluyla verimlilik ve sürdürülebilirlik artırılır. Yapay zekâ destekli sensörler ve

veri analiz araçları, daha hassas ve çevre dostu üretim yöntemlerinin uygulanmasını sağlar (Almanasra, 2024; Singh, 2024).

Eğitim sektörü, yapay zekâ ve veritabanlarından elde edilen öğrenci performans verilerini kullanarak eğitim içeriğini uyarlayabilir ve öğrenme süreçlerini optimize edebilir, böylece kişiselleştirilmiş öğrenme deneyimleri sağlayabilir (Almanasra, 2024).

Enerji sektöründe ise, yenilenebilir enerji entegrasyonu, talep tahmini ve enerji yönetimi için büyük veri analitiği ile birlikte kullanılan yapay zekâ, işletme maliyetlerini ve çevresel etkileri önemli ölçüde azaltmaya katkıda bulunur (Gülmez, 2026; Singh, 2024).

Özetle, yapay zekâ ve veritabanlarının entegrasyonu özellikle sağlık, finans, sanayi, siber güvenlik, tarım, eğitim ve enerji alanlarında etkili olduğunu kanıtlamıştır. Bu alanlarda, şirket ve kurumlarda operasyonel verimlilik, karar alma süreçleri ve yenilikçi uygulamalar önemli ölçüde iyileşmiştir (Adenekan vd., 2024; Almanasra, 2024; Nugroho vd., 2024; Singh, 2024; Weng vd., 2024).

Yapay zekâ ve veri tabanlarının entegrasyonu, özellikle hassas tarım alanında, hayvancılıkta devrim niteliğinde ilerlemelere yol açmaktadır. Bu entegrasyon, hayvan sağlığı ve refahı, üretim verimliliği ve sürdürülebilirlik açısından önemli faydalar sunmaktadır. Hassas tarımda, çok sayıda sensör, bilgisayar görüş sistemi, yapay zekâ algoritması ve kapsamlı veri tabanları, hayvan davranışlarının, biyometrik verilerin ve çevresel parametrelerin gerçek zamanlı olarak toplanmasını ve analizini mümkün kılmaktadır. Örneğin, RGB ve derinlik kameralarından, 3 boyutlu görüntüleme sistemlerinden ve IoT platformlarından elde edilen veriler, yapay zekâ destekli erken hastalık tespiti, yem optimizasyonu ve üreme yönetimi için kullanılmaktadır. Bu, hayvanların bireysel olarak izlenmesini ve bakımını sağlar; bu da geleneksel, sürü tabanlı yaklaşımlardan daha hassas ve verimlidir (Tedeschi vd., 2025; Zin & Tin, 2026).

Bilgisayar görüşü ve derin öğrenme yöntemleri, ahırdaki hayvanların hareketlerini, fiziksel durumlarını ve davranışlarını sürekli olarak izler. Bu,

topallık tespiti, doğum tarihi tahmini ve stres seviyesi değerlendirmesi gibi kritik sağlık göstergelerinin izlenmesine olanak tanır. Bu sistemlerin temelini oluşturan yapay zekâ modelleri, hayvan sağlığı ve verimliliği ile ilgili toplanan verileri yorumlar, bunları veritabanlarından elde edilen kapsamlı tarihsel ve güncel bilgilerle karşılaştırır ve operatörlere erken uyarılar ve yönetim önerileri sunar (Sztandarski vd., 2025; Zin & Tin, 2026).

Ayrıca, yapay zekâ destekli analiz yöntemleri, hayvan beslenmesinin optimizasyonunu sağlar. Matematiksel modelleme ile desteklenen yapay zekâ algoritmaları, hayvanların gerçek beslenme ihtiyaçlarını dikkate alarak yem planlamasını optimize eder. Bu, yem kayıplarını azaltır, verimliliği artırır ve çevresel etkiyi en aza indirir (Condotta & Tedeschi, 2026).

Ses analizi yöntemleri ve çok modlu yapay zekâ sistemleri, stres seviyelerini ve sağlık durumunu değerlendirmek için sığır seslerini gerçek zamanlı olarak değerlendirir. Akustik, görsel ve biyometrik verileri birleştiren bu yaklaşımlar, hasta veya stresli hayvanların erken tespitini kolaylaştırır ve refahlarını iyileştirir (Kate & Neethirajan, 2025). Bu bağlamda, veritabanları, yapılandırılmış ve yapılandırılmamış çok çeşitli verilerin, hatta büyük veri kümelerinin bile güvenilir bir şekilde depolanmasını, basitleştirilmiş yönetimini ve hızlı erişimini sağlar. Bu, yapay zekâ modellerinin mevcut verileri geçmiş kayıtlarla karşılaştırmasını ve sürekli öğrenme yoluyla doğruluklarını artırmasını sağlar. Ayrıca, veri standardizasyonu ve entegrasyon sorunlarının ele alınması, PLF sistemlerinin yaygın olarak benimsenmesi ve uygulanabilirliği için, hatta daha küçük çiftliklerde bile çok önemlidir (“Hayvan sağlığı yönetimi ve izleme için akıllı çözümler”, 2026; Sztandarski vd., 2025).

Bu yaklaşımlar, yapılandırılmış çiftlik kayıtları ile bilimsel kaynakların birlikte kullanımı yoluyla daha güvenilir karar destek sistemleri oluşturmayı amaçlar.

2.7. Tarım ve Hayvancılık Alanında Yapılan Çalışmalar

Tarım ve hayvancılıkta yapay zekâ (YZ) uygulamalarına yönelik araştırmalar, verimlilik artışı, hayvan sağlığı izleme, sürdürülebilirlik ve

kaynak optimizasyonu gibi önemli alanlarda önemli ölçüde ilerleme kaydediyor. Bu sektörlerde YZ, tarımsal ve hayvancılık üretim süreçlerini daha verimli ve hassas hale getirmek için sensör teknolojileri, bilgisayar görüşü, büyük veri analizi, makine öğrenimi ve doğal dil işleme gibi en yeni yöntemlerle birleştiriliyor. Özellikle hayvancılıkta, hassas hayvancılık (PLF) uygulamaları, akıllı sensörler, bilgisayar görüş sistemleri (RGB ve derinlik kameraları, 3D görüntüleme) ve IoT platformları kullanarak hayvan davranışının, sağlık durumunun ve çevresel parametrelerin gerçek zamanlı olarak izlenmesini sağlıyor. Bu, örneğin hastalıkların erken teşhisi, stres seviyesi ölçümü, üreme yönetimi ve yem optimizasyonu gibi konularda çok daha hassas karar vermeyi kolaylaştırıyor. Bilgisayar görüşü ve derin öğrenme teknikleri, topallık tespiti, doğum tahmini ve vücut kondisyonu değerlendirmesi gibi hayvan refahını doğrudan etkileyen alanlarda önemli avantajlar sunuyor (Tedeschi vd., 2025; Zin & Tin, 2026). Ayrıca, YZ tabanlı modeller, yem planlama kararlarını optimize ederek sürdürülebilir hayvancılık üretimini destekliyor. Bu sistemler, yem israfını azaltırken hayvanların gerçek beslenme ihtiyaçlarına göre uyarlanmış rasyonların formüle edilmesini sağlar. Ses analizi ve çok modlu yapay zekâ sistemleri, sığırlarda stres ve sağlık durumunu değerlendirmek için seslendirmeleri ve biyometrik verileri sentezleyerek erken uyarılar üretir (Condotta & Tedeschi, 2026; Kate & Neethirajan, 2025).

Hayvancılıkta, çeşitli sensörlerden gelen bilgileri depolamak ve yönetmek için büyük veri tabanları da gereklidir. Bu veri altyapıları sayesinde, yapay zekâ modelleri gerçek zamanlı ve geçmiş verilerden sürekli olarak öğrenerek karar destek sistemlerini daha doğru hale getirebilir (Smart solutions for livestock management and health monitoring, 2026; Sztandarski vd., 2025).

Tarımda, yapay zekâ uygulamaları, toprak ve ürün kalitesi analizinden iklim ve hastalık tahminine, otomatik sulama ve gübreleme sistemlerine kadar geniş bir yelpazeyi kapsar. Yapay zekâ tabanlı tarım platformları, daha verimli kaynak kullanımı ve tarımsal üretimin çevresel sürdürülebilirliğini sağlamak için sensör verilerini analiz eder. Ayrıca, drone görüntüleri ve uydu verileri,

bitki sağlığı ve hastalıkları hakkında erken uyarılar sağlamak için yapay zekâ kullanılarak işlenmektedir (Almanasra, 2024). Yapay zekâ uygulamaları, özellikle süt ve domuz endüstrilerinde olmak üzere, hayvancılık sektöründe yaygın olarak kullanılmaktadır. Yapay zekâ tabanlı sistemler, hayvan refahını, sağlık takibini ve verimliliği artırmak için kümes hayvanları, koyunlar, domuzlar ve diğer türler için de giderek daha fazla kullanılmaktadır. Özellikle sığır yetiştiriciliğinde, yapay zekâ destekli sensörler, görüntü işleme sistemleri ve Nesnelerin İnterneti (IoT) çözümleri, hayvan davranışlarının izlenmesi, erken hastalık tespiti, beslenme optimizasyonu ve üreme yönetimi gibi çok sayıda uygulama alanı bulmuştur. Bu teknolojiler, bireysel hayvan takibini mümkün kılar, süt üretimini en üst düzeye çıkarır ve sağlık sorunlarının erken tespitini kolaylaştırır (Condotta & Tedeschi, 2026; Sztandarski vd., 2025; Tedeschi vd., 2025).

Domuz yetiştiriciliği, yapay zekânın uygulanması için bir diğer önemli alandır. Bu sektörde, hayvan sağlığı ve refahını izlemek için video analiz sistemleri ile seslendirme ve davranış tanıma teknolojileri kullanılmaktadır. Bu uygulamalar, domuzlarda stres, hastalık ve davranış bozukluklarının erken teşhisi için çok önemlidir ve aynı zamanda çiftlik yönetim verimliliğini de artırır (Wang vd., 2022).

Ayrıca, yapay zekâ ve makine öğrenimi, kümes hayvanı yetiştiriciliğinde hastalık tespiti, davranış analizi, çevre kontrolü ve üretim süreci optimizasyonu için etkili bir şekilde kullanılmaktadır. Yapay zekâ tabanlı görüntü tanıma ve IoT sensörlerinden elde edilen veriler, sağlık durumunun izlenmesi ve belgelenmesi için değerli araçlar sağlar.(Natsir vd., 2025).

Yapay zekâ (YZ), hayvan refahı, sağlık takibi, erken hastalık tespiti, yem optimizasyonu ve davranış analizi gibi kritik alanlarda tüm hayvancılık türlerinde yaygın olarak kullanılmaktadır. Bununla birlikte, uygulama ve geliştirme düzeyi, diğer hayvan türlerine göre sığır ve domuz yetiştiriciliğinde daha ileridir. Bu gelişme, bu türlerin hayvancılıkta ekonomik öneminden ve bu teknolojilerin kullanımından kaynaklanan verimlilik kazanımlarından

kaynaklanmaktadır (Condotta & Tedeschi, 2026; Natsir vd., 2025; Sztandarski vd., 2025; Tedeschi vd., 2025; Wang vd., 2022).

Yapay zekâ (YZ), sığır yetiştiriciliğinde verimliliği ve hayvan refahını artırmada giderek daha önemli bir rol oynamaktadır. Özellikle, Hassas Hayvancılık (PLF) gibi gelişmiş yaklaşımlar, çiftlik yönetimini daha bilimsel, hassas ve verimli hale getirmek için YZ yöntemlerini sensör verileri, bilgisayar görüş teknolojileri ve makine öğrenme algoritmalarıyla birleştirir. YZ destekli bilgisayar görüş sistemleri, sığırların davranışlarını, sosyal etkileşimlerini ve sağlıklarını otomatik olarak yakalar ve izler. Bu yöntemler, erken hastalık teşhisini, stres göstergelerinin tespitini ve kritik sağlık sorunlarının proaktif olarak belirlenmesini sağlayan objektif, sürekli veriler sunar. Örneğin, beslenme davranışı, hareketler ve sosyal etkileşimler kameralar ve sensörler kullanılarak kaydedilir ve bireysel refah ve verimliliğin ayrıntılı analizine olanak tanır. Bu, hastalık veya strese bağlı performans düşüşünden kaynaklanan üretim kayıplarını en aza indirir (Kate & Neethirajan, 2025; Ozella vd., 2024). Yapay zekâ teknolojileriyle elde edilen kapsamlı biyometrik ve davranışsal veriler, besleme stratejilerinin optimizasyonunu da mümkün kılar. Gerçek zamanlı veriler ve makine öğrenimine dayalı analizler sayesinde, besleme planları her hayvanın ihtiyaçlarına göre bireysel olarak uyarlanabilir, yem israfı azaltılırken hayvan sağlığı ve performansı en üst düzeye çıkarılabilir. Bu, karlılığı artırır ve çevresel etkiyi azaltmaya katkıda bulunur (Kate & Neethirajan, 2025; Sztandarski vd., 2025). Hayvan sağlığı alanında, yapay zekâ ve yapay sinir ağlarına dayalı erken uyarı sistemleri, bulaşıcı hastalıkların, metabolik bozuklukların ve diğer sağlık sorunlarının daha erken ve daha doğru tespitini sağlar. Bu, daha etkili veteriner müdahalelerini kolaylaştırır, hayvanların iyileşmesini hızlandırır ve hayatta kalma oranlarını artırır. Dahası, bu teknolojiler hayvanların fiziksel durumunun ve vücut sağlığının yanı sıra sağlıklı üretim için önemli parametrelerin izlenmesini basitleştirir (Liu vd., 2023; Siva Kiran & Dhamodhar, 2025).

Sürü yönetiminin optimize edilmesi, yapay zekânın sığır yetiştiriciliğinde verimliliği artırmaya yönelik bir diğer önemli katkısını temsil etmektedir.

Büyük miktarda veri toplayan sensörler ve yapay zekâ algoritmaları, sürü içindeki bireysel farklılıkları dikkate alarak daha hassas izleme, başarılı üreme ve yüksek kaliteli süt üretimi sağlar. Bu, üretim artışına ve sürdürülebilir tarım uygulamalarına doğru ilerlemeye yol açar (Kleen & Guatteo, 2023; Melak vd., 2024).

Yapay zekâ destekli sohbet robotları, özellikle hayvan sağlığı ve bakımı alanında, hayvancılıkta giderek daha önemli bir rol oynamaktadır. Bu chatbotlar, çiftçilere ve yetiştiricilere sağlık, hastalık teşhisi, bakım önerileri ve yönetim desteği hakkında bilgi sağlayarak veteriner hekimlerle iş birliğini geliştiren tamamlayıcı araçlar olarak hizmet vermektedir (Jokar vd., 2024).

Hayvancılıkta yapay zekâ tabanlı chatbotların kullanımı, sürdürülebilir hayvan yönetimini desteklemek için genişlemektedir. Bu sohbet robotları çiftçilere gerçek zamanlı veri analizi ve öneriler sunabilir; örneğin, hastalık erken teşhisi, beslenme stratejileri, üreme yönetimi gibi kritik alanlarda karar destek sistemleri olarak görev yapabilirler (Asolo vd., 2024; Tedeschi vd., 2025).

Bununla beraber, yapay zekâ sohbet robotlarının hayvancılıkta etkin ve güvenli kullanımı için çeşitli zorluklar da bulunmaktadır. Bu zorluklar; veri standartlaştırma eksiklikleri, kırsal alanlarda bağlantı sorunları, yüksek uygulama maliyetleri, etik kaygılar ve hayvan sağlığı alanında uzman kişilerle işbirliğinin gerekliliği şeklindedir. Ayrıca, chatbotların şeffaflık, değerlendirme ve sorumluluk paylaşımı çerçevesinde geliştirilmesi, güvenli ve etkili entegrasyonları için kritik önemdedir (Jokar vd., 2024; Lee vd., 2026).

Bu tezle karşılaştırıldığında literatür dört eksende durur. RAG çalışmaları dış bağlamla üretimi birleştirmeyi önerir; bu tez aynı çerçeveyi süt sığırcılığı belgelerine uygular ve atıf tamlığının düşük kaldığını ölçer. Hibrit retrieval çalışmaları yoğun ve seyrek sıralamayı birleştirir; bu tez FAISS ile BM25 sonuçlarını 0,60/0,40 ağırlıklı RRF ile birleştirir, ancak doğru belgenin yanıt cümlesine taşınmadığını ayrıca gösterir. Text-to-SQL çalışmaları modelin yazdığı sorgunun yürütme doğruluğunu ölçer; bu tez şablon SQL ve referans sorgu çalıştırılabilirliğini ölçer, model SQL'ini ölçmez. Yapılandırılmış ve

yapılandırılmamış kaynağı birlikte kullanan karar destek çalışmaları sentez vaat eder; bu tezde HYBRID başarısı kaynak seçimine indirgenmiş, sentez doğruluğu ayrı puanlanmamıştır.

Bu literatürün tezle ilişkisi üç boşlukta toplanabilir. Birincisi, hayvancılıkta yapay zekâ çalışmaları büyük ölçüde sensör, robot ve sürü izleme üzerinedir; doğal dille hem sürü kaydını hem bilimsel belgeyi aynı yanıtta birleştiren sohbet asistanı azdır. İkincisi, RAG literatürü getirilen bağlamın üretimi kendiliğinden güvenilir kılmadığını gösterir (Shahade ve Deshmukh, 2024; Gupta, 2025; Es vd., 2024); bu tez de retrieval başarısını üretim başarısından ayrı ölçer. Üçüncüsü, Text-to-SQL çalışmaları modelin yazdığı sorgunun yürütme doğruluğunu esas alır (Gao vd., 2024); bu prototipte SQL çoğunlukla şablonla üretildiği için yürütme ile doğal dildeki sayı tutarlılığı ayrı raporlanır.

3. MATERYAL VE YÖNTEM

3.1. Araştırmanın Yöntemi ve Sistem Tasarımı

Bu araştırma, hayvancılık sektöründe bilgiye erişimi kolaylaştırmak ve kullanıcıların doğal dil kullanarak tarımsal verileri sorgulamasına olanak sağlamak amacıyla tasarlanmış yapay zekâ destekli bir sohbet robotu geliştirmeyi hedefleyen uygulamalı bir çalışmanın parçası olarak yürütülmüştür. Çalışma, doğal dil işleme, büyük dil modelleri (LLM), "Geri Getirme Destekli Üretim (Retrieval-Augmented Generation – RAG) ve ilişkisel veritabanı teknolojilerini birleştiren, süt çiftlikleri için bir çiftlik asistanı oluşturulmasıyla sonuçlanmıştır. Büyük dil modellerinin doğal dil talimatlarına dayalı olarak çeşitli görevleri yerine getirme yeteneği, bunların soru cevaplama ve bilgi alma uygulamalarında kullanılmasını sağlar (Brown vd., 2020). RAG yaklaşımı ise, dil modelinin harici bilgi kaynaklarından gelen içeriğe dayalı olarak yanıtlar üretmesine yardımcı olarak, alana özgü sistemlerin geliştirilmesini kolaylaştırır (Lewis vd., 2020). Bu araştırmada geliştirilen sistem, tek bir uygulama içinde hem yapılandırılmış tarımsal verileri hem de hayvancılıkla ilgili bilimsel bilgi kaynaklarını kullanmak üzere tasarlanmıştır. Yapılandırılmış tarımsal verileri depolamak ve sorgulamak için PostgreSQL veritabanı kullanılırken, bilimsel belgeleri işlemek ve bunları kullanıcı sorgularıyla ilişkilendirmek için RAG altyapısı kullanılmıştır. Sonuç olarak, sistem hem çiftlik kayıtlarından elde edilen verilere dayalı soruları hem de hayvancılık hakkında bilimsel bilgi gerektiren soruları yanıtlayabilmektedir. Sistem geliştirme için Python programlama dili seçilmiş ve sunucu tarafı işlemleri FastAPI tabanlı bir arka uç mimarisi aracılığıyla uygulanmıştır. Dil modeli altyapısını oluşturmak ve farklı sistem bileşenleri arasındaki iş akışlarını yönetmek için LangChain ve LangGraph kütüphaneleri kullanılmıştır. Mobil ve web ortamları için optimize edilmiş bir kullanıcı arayüzü, React Native ve Expo kullanılarak geliştirilmiştir. Kullanıcı sorgusu girişinden oluşturulan yanıtın görüntülenmesine, analiz ve uygun veri kaynağına yönlendirmeye kadar tüm süreç tek bir uygulama içinde gerçekleşir. Sistem tasarımı, kullanıcı sorgularını içeriklerine bağlı olarak farklı işleme iş akışlarına yönlendirmeye dayanmaktadır. Bu bağlamda, sorgular dört ana kategoriye ayrılmıştır: SQL, RAG, HYBRID ve CHAT. Sayısal veya

yapılandırılmış veri gerektiren sorular SQL veritabanına, bilimsel bilgi gerektiren sorular ise RAG bilgi tabanına yönlendirildi. Hem tarımsal veri hem de bilimsel açıklamalar gerektiren sorular HYBRID çerçevesi aracılığıyla ele alındı; son olarak, ne veritabanı ne de bilimsel bilgi kaynağı gerektirmeyen genel sorular sohbet fonksiyonu aracılığıyla yanıtlandı. Bu yönlendirme yapısı, her kullanıcı sorgusunun içeriğine uygun bir bilgi kaynağına erişmesini sağlamak için tasarlandı. RAG (Retrieval Augmented Generation) tekniğine dayalı bilgi alma süreci çerçevesinde, süt çiftçiliği ile ilgili bilimsel belgeler sisteme entegre edildi ve bilgi erişimine uygun bir formatta hazırlandı. Bilimsel belgelerden ilgili içeriklerin getirilmesi amacıyla BGE-M3 gömme modeli ve FAISS tabanlı anlamsal arama ile BM25 tabanlı sözcüksel arama yöntemlerinden yararlanılmıştır. Ayrıca bu iki yöntemin sonuçlarını birleştiren hibrit bir bilgi erişim yaklaşımı uygulanmıştır.

Bu şekilde elde edilen ilgili içerik, büyük dil modeline bağlam olarak sağlandı ve böylece yanıtların sistemde bulunan bilimsel kaynaklara dayalı olması sağlandı. RAG yaklaşımının doğasında bulunan bilgi edinme ve metin oluşturma süreçlerinin birleşimi, büyük dil modellerinin harici kaynaklardan yararlanarak büyük miktarda bilgi gerektiren soruları yanıtlamasına olanak tanır (Lewis vd., 2020).

Araştırma uygulama süreci; veri kaynaklarının hazırlanması, sistem mimarisinin oluşturulması, RAG ve LangChain altyapısının kurulması, dil modelinin sisteme mekanizmasının geliştirilmesi, kullanıcı arayüzünün tasarlanması ve sistemin test edilmesi gibi çeşitli aşamaları kapsıyordu. Bu adımlar, tarımsal verilerden ve bilimsel bilgi kaynaklarından eş zamanlı olarak yararlanabilen ve kullanıcıların doğal dili kullanarak hayvancılıkla ilgili sorular sormasına olanak tanıyan entegre bir sohbet robotunun geliştirilmesini sağladı.

entegre edilmesi, SQL veritabanının oluşturulması, sorgu yönlendirme

3.2. Veri Kaynaklarının Hazırlanması

Geliştirilen chatbot'un hem çiftliğe özgü verileri hem de hayvancılıkla ilgili bilimsel bulguları kullanabilmesi için iki farklı veri kaynağı kullanıldı. Birinci kaynak, çiftlik operasyonlarına ilişkin yapılandırılmış verileri içeren bir PostgreSQL veritabanı iken, ikincisi RAG altyapısı içinde erişilen hayvancılıkla ilgili bilimsel belgeleri içeren bir bilgi tabanıdır. Bu ayrım, sistemin hem sentetik olarak oluşturulan çiftlik verileri sorgularını hem de özel bilgi gerektiren soruları, her biri için en uygun kaynaklardan yararlanarak yanıtlamasına olanak tanır.

Yapılandırılmış veriler, PostgreSQL 16 veritabanında depolanmıştır. Bu veritabanı içerisinde; çiftlikler, kullanıcılar, inekler, sağım verileri, uyarılar, günlük özetler ve donanım tanımlayıcılarına ilişkin bilgileri yönetmek üzere tablolar oluşturulmuştur. Hayvan ve çiftlik verilerinin ilişkisel bir veritabanında düzenlenmesi, sistemin belirli hayvanlar, üretim göstergeleri veya çiftlik verileriyle ilgili kullanıcı sorgularını işleyebilmesini sağlamaktadır. Söz konusu veriler, temel olarak SQL sorgularına veya hibrit sorgulara yanıt vermek amacıyla kullanılmıştır. Bu araştırmada kullanılan yapılandırılmış çiftlik verileri, gerçek bir süt çiftliğinden toplanmamış; prototip veritabanının sorgulama işlevselliğini uygulamak ve test etmek için sentetik olarak oluşturulmuştur. Dolayısıyla bu kayıtlar, gerçek dünyadaki çiftliklerde bulunan hayvanların üretim performansını veya sağlık durumunu yansıtan saha verilerini temsil etmemektedir. Kayıt ölçeği prototiptir: bir çiftlik, beş inek (3 Holstein, 2 Simental), 70 sağım kaydı (30 Ağustos–5 Eylül 2026, sabah ve akşam) ve bir alarm kaydı. Bu ölçek saha genellemesi kurmaz.

Sistemin bilimsel bilgi veritabanını oluşturmak için süt çiftçiliği ve hayvan sağlığıyla ilgili on altı PDF belgesi kullanıldı. İçeriklerine göre bu belgeler sekiz tematik alana ayrılmıştır: mastitis, süt kalitesi, beslenme, metabolik hastalıklar, buzağı sağlığı, üreme yönetimi, hayvan refahı ve süt ve sağım hijyeni. Kaynak belgelerin bu tematik sınıflandırması, kullanıcı sorgularının ilgili bilgi alanına atanmasını kolaylaştırmış ve bilgi erişimini optimize etmiştir. RAG tabanlı sistemler için bilgi kaynakları hazırlamak,

sadece belgeleri yüklemekten daha fazlasını içerir. Uzun metinleri, bilgi erişimi için uygun, daha kısa ve yönetilebilir bölümlere ayırmak, kullanıcı sorgularını yanıtlamak için ilgili bölümlerin belirlenmesini kolaylaştırmada temel bir adımdır. RAG yaklaşımında, üretken model için bağlam olarak harici kaynaklardan ilgili içerik sağlamak, yanıtlar oluşturulurken bilgi tabanından bilgi kullanımını mümkün kılar (Lewis vd., 2020). Bu nedenle, bu çalışmada kullanılan PDF belgeleri, bilgi erişim sürecine uygun metin işleme ve biçimlendirme işlemlerinden geçmiştir.

Belge hazırlama sırasında, metinler 900 karakterlik bölümlere ayrıldı ve ardışık bölümler 150 karakterlik bir örtüşme ile birbirine bağlandı. Bu örtüşme, bölümler arasındaki anlamsal tutarlılığı mümkün olduğunca korumak için tasarlandı. Bu işlem adımından sonra, 16 PDF belgesinden toplam 1.833 metin bölümü oluşturuldu. Bu bölümler, sonraki vektörleştirme ve bilgi alma işlemlerinin temelini oluşturdu.

Süreç, belgelerin yalnızca metin içeriğini değil, aynı zamanda kaynak hakkındaki açıklayıcı bilgileri de korumaya odaklandı. Bu, alınan içeriğin kaynaklandığı ilgili belgenin tanımlanabilmesini ve oluşturulan sistem yanıtlarının kaynaklarına kadar izlenebilmesini sağladı. Kaynak bilgilerinin korunması, özellikle pratik ve uygulamalı bilgiye dayanan hayvancılık gibi bir alanda, yanıtların izlenebilirliği için çok önemlidir. Son olarak, sisteme iki tamamlayıcı veri yapısı uygulandı. PostgreSQL veritabanı, çiftlik ve hayvan verileri gibi yapılandırılmış verileri sorgulamak için kullanılırken, bilimsel literatüre dayalı bir bilgi tabanı, hayvancılık konusunda açıklayıcı ve bilimsel bilgi gerektiren soruları yanıtlar. Her iki veri kaynağını da kullanan sorgular için, yapılandırılmış çiftlik verileri ve bilimsel bilgiler tek bir yanıt sürecine entegre edilir. Bu nedenle sistem, yalnızca genel bilgiler sunan bir sohbet robotu olarak değil, aynı zamanda sektöre özgü verileri alana özgü bilgilerle birleştiren bir tarım asistanı olarak da işlev görür.

Tablo 3.1. Bilgi tabanı corpus manifestosu (16 PDF)

Kod	**Belge / konu**	**Bibliyografik kayıt ve erişim bağlantısı**

D01	FAO Mastitis Dairy Manual	FAO (1989), Milking, milk production hygiene and udder health (FAO Paper 78) — önceki listedeki aday kayıt; raporda “FAO Mastitis Dairy Manual (2010)” ile kesin
D02	Kuru/geçiş dönemi	Kurt, S., Çolakoğlu, H. E., Yazlık, M. O., Vural, M. R. ve Küplülü, Ş. (2019). Sütçü ineklerde mastitis yönünden kuru ve geçiş dönemlerinin önemi. Atatürk Üniversitesi Veteriner Bilimleri
D03	Somatik hücre sayısı	Darbaz, İ. ve Ergene, O. (2015). Sürü meme sağlığı yönetiminde somatik hücre sayısının önemi. Erciyes Üniversitesi Veteriner Fakültesi Dergisi, 12(3), 203–
D04	Somatik hücre ve süt kalitesi	Yalçın, H. ve Çakmak, T. (2022). İnek sütlerinde somatik hücre sayısı ve bazı parametrelerin araştırılması. Manas Journal of Agriculture Veterinary and Life Sciences,
D05	Dengeli besleme	Garg, M. R. (2012). Balanced feeding for improving livestock productivity: Increase in milk production and nutrient use efficiency and decrease in methane emission. FAO Animal Production and Health Paper No. 173. FAO.
D06	Yem tüketimi	University of Tennessee Extension. Managing Intake of Dairy Cows .
D07	Doğum sonrası hipokalse mi	Bjurstrom, A., Kohlman, T. ve Ulness, A. (t.y.). Fresh cows: Milk fever. University of Wisconsin–Madison Division of Extension.
D08	Geçiş dönemi metabolik sorunlar	Overton, T. R. (2005). Effective transition cow management to maximize internal herd growth. Cornell University, PRO-DAIRY / Winter Dairy Management Conference. https://ecommons.cornell.edu/

D09	Buzağı besleme	University of Florida IFAS. Dairy calf nutrition [kısa ad; özgün yayının yazar, yıl ve tam başlığı belirlenemedi]. https://edis.ifas.ufl.edu/

D10	Kolostrum yönetimi	Utah State University Extension (2026). Colostrum management for dairy calves [kısa ad; tam yayın kimliği doğrulanamadı]. https://extension.usu.edu/
D11	Üreme yönetimi	Dairy Cattle Reproduction Council (t.y.). Reproductive management strategies for dairy cows . https:// www.dcrcouncil.org/wp-
D12	Yüksek fertilite döngüsü	Fricke, P. M., Wiltbank, M. C. ve Pursley, J. R. (2023). The high fertility cycle. University of Wisconsin–Madison Division of Extension
D13	Süt sığırı refahı	World Organisation for Animal Health (2021). Animal welfare and dairy cattle production systems. Terrestrial Animal Health Code, Chapter 7.11. https://www.woah.org/fileadmin/
D14	İşletmelerd e hayvan refahı	Öcal, G. O., Güven, F. M. ve Cedden, F. (2026). Evaluation of housing and management conditions affecting animal welfare in dairy cattle farms in Ankara Province, Türkiye. Adnan Menderes Üniversitesi Ziraat Fakültesi Dergisi, 23(1), 47–54
D15	İyi süt çiftçiliği	Food and Agriculture Organization of the United Nations ve International Dairy Federation (2011). Guide to good dairy farming practice (2nd ed.; FAO Animal Production
D16	Süt hijyeni	Codex Alimentarius Commission (2004; amended 2009). Code of hygienic practice for milk and milk products (CXC 57-2004). FAO/WHO. https://www.fao.org/fao-who-

Tablo 3.1, RAG bilgi tabanını oluşturmak için kullanılan 16 bilimsel belgeyi; alan ve yayın türüne göre sınıflandırılmış şekilde özetlemektedir. Tam bibliyografik bilgiler ve veri işlemeye ilişkin teknik özellikler, Ek Tablo 2'de sunulmuştur.

Tabloda, geliştirilen sohbet robotunun RAG tabanlı bilgi erişim altyapısında kullanılan 16 bilimsel ve teknik belgeye ilişkin bilgiler sunulmaktadır. Söz konusu belgeler; mastitis, süt kalitesi, besleme, metabolik hastalıklar, buzağı sağlığı, üreme, hayvan refahı ve süt hijyeni olmak üzere sekiz tematik kategoride sınıflandırılmıştır. Bilgi kaynakları arasında uluslararası kuruluşların rehber ve standartları, üniversite yayınları ve hakemli bilimsel makaleler bulunmaktadır. Toplam 748 sayfadan oluşan bu belgeler, veri hazırlama sürecinde 1.833 metin parçasına ayrılarak sistemin bilimsel bilgi

tabanının oluşturulmasında kullanılmıştır. Bu sınıflandırma, hayvancılıkla ilgili farklı konuların bilgi tabanında sistematik biçimde temsil edilmesini amaçlamaktadır. Bilgi tabanında kullanılan belgelerin tam bibliyografik künyeleri, erişim bağlantıları ve belge bazındaki sayfa ve metin parçası sayıları Ek Tablo 2'de sunulmuştur.

Sentetik PostgreSQL kayıtları bir prototip ölçeğindedir. Canlı veri tabanı sayımına göre hayvan ve sağım kaydı içeren tek çiftlik vardır (Tez Test Çiftliği; diğer üç çiftlik satırı kullanıcı kaydı denemelerinden kalan boş kayıtlardır). Beş inek (3 Holstein: Serap TR0001, Beyza TR0002, Papatya TR0004; 2 Simental: Boncuk TR0003, Lale TR0005), 70 sağım kaydı (2026-08-30 – 2026-09-05; günde 10 kayıt = 5 inek × sabah/akşam) ve tek bir alarm kaydı (Serap, 05.09.2026 akşam, 12,80 → 7,80 L, %39,06 düşüş, okundu) bulunur. Referans SQL'deki 50 kayıt, 1–5 Eylül kesitidir. Süt miktarı litre olarak tutulur. Şema yedi tablodan oluşur: ciftlikler, kullanicilar, inekler, sagim_kayitlari, alarmlar, gunluk_ozetler (boş) ve cihaz_tokenlari (boş); ilişkiler çiftlik → inek → sağım/alarm yönündedir. Beş hayvan ve bir haftalık kayıt, 'en yüksek on inek', çok aylık trend veya ABC segmentasyonu gibi işlevlerin genellenmesini engeller. Kayıtlar betikle üretilmiş örnek kayıtlardır; ticari bir işletmeden alınmamıştır.

3.3. Sohbet Robotunun Sistem Mimarisi

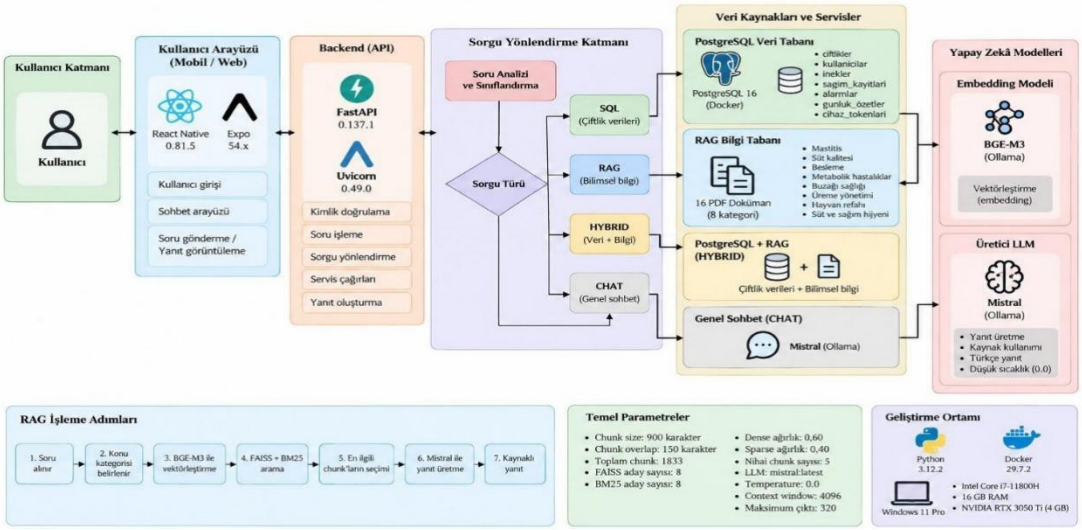
Bu çalışmada geliştirilen yapay zekâ tabanlı tarım asistanı, kullanıcı arayüzü, arka uç hizmetleri, sorgu yönlendirme sistemi, yapılandırılmış veritabanı, RAG tabanlı bilgi alma sistemi ve Büyük Dil Modeli (LLM) bileşenlerinin entegre bir şekilde çalıştığı çok katmanlı bir mimariye dayanmaktadır. Birincil tasarım amacı, kullanıcının doğal dil sorusunun içeriğini belirlemek, bunu uygun veri veya bilgi kaynağına yönlendirmek ve sonuçları kullanıcıya anlaşılabilir bir biçimde sunmaktır. LLM'lerin doğal dil girdilerini işleme ve çeşitli görevleri yerine getirme yeteneği, bu tür etkileşimli sistemlerin geliştirilmesinin temelini oluşturmaktadır (Brown vd., 2020). Doğrudan kullanıcı etkileşim katmanı, React Native ve Expo kullanılarak geliştirilmiştir. Bu arayüz aracılığıyla kullanıcılar giriş yapabilir, sohbet

fonksiyonu aracılığıyla doğal dilde sorular sorabilir ve oluşturulan yanıtları görüntüleyebilir. Kullanıcı sorguları, kullanıcı arayüzü ile diğer sistem bileşenleri arasındaki iletişimi kolaylaştıran arka uç katmanına iletilir. Arka uç için Python tabanlı FastAPI mimarisi kullanılırken, sunucu tarafı uygulama çalıştırıcısı olarak Uvicorn kullanılmıştır. Bu katman, kimlik doğrulama, kullanıcı sorgularını alma, bunları uygun hizmetlere yönlendirme ve oluşturulan yanıtları kullanıcı arayüzünde görüntüleme gibi temel işlemleri ele alır.

Sistem mimarisinin temel bir bileşeni sorgu yönlendirme katmanıdır. Her kullanıcı sorgusu öncelikle içeriğine göre analiz edilir ve gerekli bilgi türüne göre sınıflandırılır. Sonuç olarak, dört farklı sorgu yolu oluşturulmuştur: SQL, RAG, HYBRID ve CHAT. Bu yapı, çeşitli kullanıcı sorgularını ele almak için tek bir yönteme güvenmek yerine, belirli sorgu içeriğine göre uyarlanmış veri ve bilgi kaynaklarının kullanılmasını sağlar. SQL yolu, prototip kapsamında oluşturulan sentetik çiftlik verileri doğrudan ilgili sorgular için kullanılır. Örneğin, belirli bir hayvan için verileri görüntülerken, süt üretim rakamlarını karşılaştırırken veya sayısal çiftlik verilerini sorgularken, sistem PostgreSQL veritabanındaki ilgili kayıtlara erişir. Bu, kullanıcıların veritabanı sorgu dillerini anlamaya gerek kalmadan doğal dil kullanarak çiftlik verilerine erişmelerini sağlar. RAG yaklaşımı ise bilimsel veya açıklayıcı bilgi gerektiren soruları yanıtlamak için tasarlanmıştır. Bu yaklaşımda, kullanıcının sorgusuna ilişkin bilgiler harici bir kaynaktan alınır ve büyük dil modelinin yanıt oluşturma sürecine entegre edilir (Lewis vd., 2020). Bu çalışmada, özellikle süt hayvancılığı olmak üzere hayvancılığa odaklanan bilimsel bir bilgi tabanı, RAG sistemi için birincil bilgi kaynağı olarak kullanılmıştır. Kullanıcının sorgusuna ilişkin içerik bu bilgi tabanından çıkarılır ve üretken modele aktarılır. Sistem ayrıca, hem çiftlik verilerini hem de bilimsel açıklamaları gerektiren sorular için hibrit bir sorgu yolu da içerir. Bu sorgular için, PostgreSQL veritabanından alınan çiftlik verileri ve RAG bilgi tabanından alınan bilimsel içerik birlikte kullanılır. Örneğin, sistem belirli bir hayvanın üretim rakamlarındaki eğilimi ve bunun arkasındaki olası nedenleri

sorguluyorsa, hem çiftlik verilerini hem de bilimsel bilgi tabanını kullanabilir. Bu, sayısal operasyonel verilerin uzman bilgisiyle birlikte değerlendirilmesine olanak tanıyan entegre bir yanıt yapısı oluşturur. Veritabanlarına veya bilimsel belgelere erişim gerektirmeyen rutin kullanıcı sorguları, anlık mesajlaşma arayüzü aracılığıyla ele alınır; Kullanıcı sorgusunu doğrudan gönderir ve büyük bir dil modeli doğal dil yanıtı üretir. Bu ayrım, RAG veya veritabanı sorgusu gerekmediğinde gereksiz bilgi alımını önler. Sistem, yapay zekâ katmanında iki farklı modelleme fonksiyonu kullanır. BGE-M3 gömme modeli, bilimsel belgelerin ve kullanıcı sorgularının sayısal vektör temsillerini oluştururken, Mistral dil modeli nihai doğal dil yanıtlarını üretir. Modeller Ollama altyapısında yerel olarak çalışır. Bu yapı sayesinde bilgi erişimi için gerekli vektörleştirme işlemi ile kullanıcıya sunulacak doğal dil yanıtının oluşturulması birbirinden ayrı fakat bağlantılı süreçler olarak yürütülmüştür.

Sistem bileşenleri arasındaki genel işlem akışı kullanıcı sorgusunun arayüz üzerinden backend katmanına gönderilmesiyle başlamaktadır. Sorgu, yönlendirme katmanında analiz edilerek SQL, RAG, HYBRID veya CHAT yollarından uygun olanına aktarılmaktadır. İlgili veri veya bilimsel içerik elde edildikten sonra gerekli bağlam büyük dil modeline sunulmakta ve oluşturulan nihai yanıt backend aracılığıyla tekrar kullanıcı arayüzüne iletilmektedir. Bu mimari sayesinde yapılandırılmış çiftlik kayıtları, bilimsel bilgi kaynakları ve büyük dil modelinin doğal dil üretme yeteneği tek bir uygulama içerisinde bir araya getirilmiştir. Şekil 3.1'de, geliştirilen sistemin temel bileşenleri ve bu bileşenler arasındaki veri akışı gösterilmektedir.



Şekil 3.1. Yapay Zekâ Destekli Çiftlik Asistanı Sistem Mimarisi

Şekil 3.1'de gösterildiği gibi, sistem kullanıcının doğal dil sorgusunu tek bir bilgi kaynağına göre değerlendirmek yerine, sorgunun niteliğine bağlı olarak farklı işleme yollarına yönlendirir. Bu yapı, tarımsal veri sorgulamasını bilimsel bilgi erişim süreçlerinden ayırmayı sağlarken, gerektiğinde hibrit bir sorgu yapısı aracılığıyla bunların birlikte kullanılmasına da olanak tanır. Geliştirilen mimaride sorgu yönlendirme, bilgi erişim ve yanıt üretim süreçleri birbirleriyle ilişkili olmakla birlikte farklı işlevler üstlenmektedir. Sorgunun uygun kanala yönlendirilmesi, gerekli bilgi kaynağının seçilmesini amaçlarken bilgi erişim bileşeni ilgili içeriklerin getirilmesini sağlamaktadır. Büyük dil modeli ise elde edilen verilerden veya bilimsel içeriklerden yararlanarak kullanıcıya sunulacak yanıtı oluşturmaktadır. Bu nedenle sistemin değerlendirilmesinde sorgu yönlendirme başarısı, bilgi erişim performansı ve nihai yanıtların doğruluğu birbirinden ayrı ölçütler olarak ele alınmalıdır.

3.4. LangChain ve RAG Altyapısının Geliştirilmesi

Geliştirilen chatbot'un hayvancılık alanındaki bilimsel bilgi kaynaklarına erişebilmesi için, RAG tabanlı bir bilgi alma altyapısı kurulmuştur. RAG yaklaşımı, büyük dil modellerinin yanıt oluşturma yeteneklerini harici bilgi kaynaklarından gelen içerikle birleştirir. Kullanıcı sorgusuyla ilgili belgeler veya metin parçaları bilgi veritabanından alınır ve büyük dil modeline bağlam olarak sağlanır; yanıt daha sonra bu bilgilere dayanarak oluşturulur (Lewis vd., 2020). Bu çalışmada, chatbot'un süt hayvancılığı ve hayvan bilimi alanlarındaki bilimsel belgelere erişebilmesi için RAG altyapısı kullanılmıştır. Bu altyapının geliştirilmesi sırasında, Bölüm 3.2'de açıklanan veri hazırlama sürecinden elde edilen metin parçaları,

bilgi almayı optimize etmek için daha da işlenmiştir. Metinlerin anlamsal özelliklerini sayısal olarak temsil etmek için BGE-M3 gömme modeli kullanılmıştır. BGE-M3, çeşitli bilgi alma yöntemleriyle uyumlu, çok işlevli, çok dilli bir gömme modeli olarak geliştirilmiştir (Chen vd., 2024b).

Bu çalışmada, model, bilgi tabanındaki metin parçalarının ve kullanıcı sorgularının vektör temsillerini oluşturmak için kullanılmıştır. Bu, kullanıcı sorguları ile bilimsel belgelerin içeriği arasındaki anlamsal benzerliğin hesaplanmasını sağlamıştır. Oluşturulan vektörleri depolamak ve benzer içeriği belirlemek için FAISS (Facebook AI Similarity Search) çerçevesi kullanılmıştır. FAISS, yüksek boyutlu vektörler üzerinde benzerlik aramalarını verimli bir şekilde gerçekleştirmek için tasarlanmış bir kütüphanedir (Johnson vd., 2019).

Bir kullanıcı bir soru gönderdiğinde, sorgunun vektör temsili oluşturulur ve FAISS'te indekslenen metin parçalarıyla karşılaştırılır. Bu işlem, sorguyla anlamsal olarak ilişkili içeriğin belirlenmesini sağlar. Sistem, yalnızca anlamsal benzerliğe dayalı vektör aramalarıyla sınırlı kalmamıştır; bunun yerine, sözcüksel eşleşmeleri de dikkate almak için BM25 algoritması kullanılmıştır. BM25, bir belgedeki arama terimlerinin dağılımını ve özgüllüğünü dikkate alan, bilgi erişiminde yaygın olarak kullanılan bir sıralama yöntemidir (Robertson & Zaragoza, 2009).

Tablo 3.2 Tekrarlanabilir deney yapılandırması

Bileşen	Değer
LLM (üretim)	mistral; temperature 0; seed 0; max 160 token ctx 2048
Yönlendirici LLM	mistral (kural eşleşmezse); kural eşleşirse LL çağrılmaz
Gömme modeli	bge-m3 (Ollama)
Parçalama	900 karakter, 150 örtüşme
Top-K	FAISS 8, BM25 8, nihai 5
Birleştirme	Weighted RRF; 0,60 / 0,40; k = 60

BM25	k1 = 1,5; b = 0,75
FAISS	IndexFlatL2 (L2 uzaklık)
Veritabanı	PostgreSQL, sentetik prototip kayıtlar
Test ayrımı	100 soru = pilot; 89 soru = ayrık final

Sonuç olarak, kullanıcının sorgusunda yer alan belirli kavramlar, hastalıklar, hayvan türleri veya teknik terimlerle sağlanan doğrudan eşleşmeler de bilgi erişimine katkıda bulunur. Bu bağlamda, sisteme hibrit bir arama yaklaşımı entegre edilmiştir. FAISS kullanılarak elde edilen anlamsal (semantik) arama sonuçları ile BM25 değerlendirilmiştir. Bu çalışmada, hem anlamsal hem de sözcüksel arama yöntemlerinin çıktılarını birleştirmek için hibrit bir bilgi erişim yaklaşımı uygulanmıştır. BGE-M3 gömme (embedding) modeli ve FAISS aracılığıyla üretilen anlamsal arama sonuçları, BM25 algoritmasından elde edilen sözcüksel arama sonuçlarıyla, Ağırlıklı Karşılıklı Sıralama Birleştirme (Weighted Reciprocal Rank Fusion - RRF) yöntemi kullanılarak birleştirilmiştir. Bu birleştirme sürecinde, anlamsal arama sonuçlarına 0,60, BM25 sonuçlarına ise 0,40 ağırlık verilmiştir. RRF yönteminde sıralama konumlarını dengelemek için kullanılan sabit değer 60 olarak belirlenmiştir. Her iki arama yönteminden en üstteki sekiz sonuç seçilmiş; birleştirme ve yeniden sıralama işlemlerinin ardından, en yüksek puana sahip beş metin parçası, yanıt oluşturma sürecine aktarılmıştır (LangChain, 2026).

kullanıla elde edilen sözcüksel (leksikal) arama sonuçları birlikte rak

Bu çalışmada, kullanıcı sorgusunu alma, türünü belirleme, gerekli bilgi alma işlemlerini gerçekleştirme ve alınan bağlamı büyük dil modeline iletme adımları bu yapı içinde birbirine bağlanmıştır. Bir kullanıcı sorgusu RAG işlem hattına yönlendirildiğinde, önce sorgunun vektör temsili oluşturulur, ardından FAISS ve BM25 kullanılarak aramalar yapılır. Sonuçlar birleştirilip yeniden sıralandıktan sonra, en alakalı içerik belirlenir. Seçilen metin parçaları, bağlam olarak kullanıcı sorgusuyla birlikte büyük dil modeline sağlanır ve ardından bu içeriğe dayalı olarak nihai yanıt oluşturulur. RAG yaklaşımının temelini oluşturan bu süreç, üretken modelin yalnızca kendi parametrelerinde depolanan

bilgilere güvenmek yerine, harici bilgi kaynaklarından gelen içeriği kullanmasını sağlar (Lewis vd., 2020).

Sistem dahilinde RAG altyapısı, yalnızca özel bilimsel bilgi gerektiren soruları yanıtlamak için değil, aynı zamanda "hibrit" olarak adlandırılan sorgular için de kullanıldı. Bu sorgular, RAG bilgi tabanındaki bilimsel içeriğin PostgreSQL veritabanındaki sentetik çiftlik kayıtlarıyla birlikte analiz edilmesini içeriyordu. Örneğin bu sayede, belirli bir hayvanın süt verimindeki değişimlerin sayısal olarak belirlenmesi ve bu değişimlerin olası nedenlerinin bilimsel bilgiler ışığında açıklanması mümkün hale geldi. Bu mimari sayesinde RAG altyapısı, sohbet robotunun hayvancılık alanındaki bilimsel bilgi kaynaklarına hem anlamsal hem de sözcüksel düzeyde erişmesini ve ilgili içeriği büyük dil modelinin yanıt oluşturma sürecine dahil etmesini sağladı. Uygulanan hibrit bilgi erişim yaklaşımı, yalnızca anahtar kelime eşleştirme veya vektör benzerliğine dayanmayan, daha kapsamlı bir mekanizma oluşturdu.

3.5. Büyük Dil Modeli Entegrasyonu

Final deneyin geçerli yapılandırması Tablo 3.2'dir. Üretim modeli Ollama üzerinde mistral etiketidir; yüklü paket mistral:latest, GGUF, 7,2 milyar parametre ve Q4_K_M kuantizasyonudur. Model özeti 6577803aa9a0 ile başlar. Deney parametreleri temperature 0, seed 0, num_predict 160 ve num_ctx 2048'dir. Model kartındaki üst bağlam uzunluğu 32768'dir; deney bu üst sınırı değil, 2048 değerini kullanmıştır. Şekil 3.1'de görülen 4096 bağlam, 320 token çıktı ve mistral:latest etiketi önceki mimari çizime aittir ve final sayılar için esas alınmaz. Üretim çağrısı kodda num_gpu=0 ile yapılmıştır. Donanım Intel Core i7-11800H, 16 GB RAM ve NVIDIA GeForce RTX 3050 Ti 4 GB'dir. Ortalama 44,6 saniyelik RAG gecikmesi bu koşullarda ölçülmüştür; gecikmenin tek nedeni olduğu ayrıca ölçülmemiştir. Üretim istemi Türkçe yanıt, en fazla üç cümle, her bilimsel cümlenin sonunda [K] atıfı, bağlam dışında 'yeterli bilgi bulunamadı' deme, tanı ve antibiyotik yasağı kurallarını içerir. İstem metni Ek Tablo H'dedir. Konu kategorisi, belge klasörünü retrieval sırasında süzmek için ayrı bir doğruluk tablosuyla raporlanmamıştır.

Geliştirilen chatbot için, doğal dildeki kullanıcı sorgularını analiz etmek ve ortaya çıkan bilgileri veya verileri anlaşılabilir bir yanıta dönüştürmek amacıyla büyük bir dil modeli (LLM) kullanıldı. Büyük metin külliyatları üzerinde eğitim yoluyla, büyük dil modelleri, sağlanan bağlama ve talimatlara bağlı olarak çeşitli doğal dil işleme (NLP) görevlerini gerçekleştirebilir (Brown vd., 2020). Bu çalışmada, Mistral modeli sistemin doğal dil üretme işlevini sağladı ve Ollama altyapısı kullanılarak yerel bir ortamda çalıştırıldı.

Mistral, hesaplama verimliliği göz önünde bulundurularak tasarlanmış, Transformer mimarisine dayalı açık ağırlıklı bir büyük dil modelidir. (Jiang vd., 2023), Mistral-7B modeline yapılan mimari ayarlamaların -özellikle dikkat mekanizmasının daha verimli kullanımının- model performansı ve hesaplama maliyeti arasında optimal bir dengeye katkıda bulunduğunu belirtmektedir. Bu çalışma için Mistral modelinin seçimi, chatbot'un harici, bulut tabanlı dil modelleme hizmetlerine güvenmeden doğal dil yanıtları üretmesine olanak sağladı.

Modelin yerel olarak yürütülmesi için Ollama kullanıldı. Ollama, büyük dil modellerinin yerel sistemlerde çalışmasına ve uygulamalar tarafından erişilebilir olmasına olanak tanıyan bir çalışma ortamı sağlar. Bu çerçevede, Mistral modeli arka uç ve yapay zekâ bileşenleriyle birlikte çalışarak, kullanıcı isteği işleme ve yanıt oluşturma sırasında model ile diğer uygulama katmanları arasında doğrudan iletişimi kolaylaştırdı.

Büyük dil modeline iletilen içerik, kullanıcının isteğinin yönlendirildiği yola bağlı olarak değişir. "CHAT" olarak sınıflandırılan istekler için, kullanıcının mesajı doğrudan model tarafından analiz edilir; ancak RAG istekleri için, kullanıcının sorusunu tamamlamak ve bağlam sağlamak üzere bilimsel bir bilgi tabanından ilgili metin parçaları modele iletilir. SQL yaklaşımında, veritabanından çıkarılan sonuçlar doğal dilde açıklanmak üzere modele iletilirken, "HYBRID" sorgular, PostgreSQL veritabanından operasyonel verileri ve RAG altyapısından bilimsel içeriği tek bir yanıt oluşturma sürecinde birleştirdi. Bu yapı, büyük dil modelinin rolünün yalnızca bağımsız olarak bilgi üretmekle sınırlı olmadığını ima ediyordu; Bu aynı zamanda, kullanıcı tarafından anlaşılabilir bir yanıt üretmek için çeşitli kaynaklardan gelen içeriğin sentezlenmesini de içeriyordu. Önceki bölümde

açıklanan hibrit bilgi alma mekanizması, RAG süreci içinde büyük dil modeline (LLM) sağlanan bağlamı geliştirmek için kullanıldı. Kullanıcının sorgusu için en alakalı metin parçaları, oluşturulan yanıtın bu içeriği dikkate almasını sağlamak için modelin bağlamına entegre edildi. RAG yaklaşımı sayesinde, harici kaynaklardan gelen içeriğin üretken modele aktarılması, modelin parametrelerinde bulunan bilgilerin harici kaynaklardan gelen bilgilerle birleştirilmesine olanak tanır; bu yöntem özellikle derinlemesine bilgi gerektiren görevler için çok uygundur (Lewis vd., 2020). Bu nedenle, Mistral modeli ve RAG bilgi tabanı bağımsız bileşenler olarak değil, bilgi alma ve yanıt oluşturmanın birbirini tamamlayıcı olduğu birleşik bir yapı içinde entegre edildi.

Model ile diğer sistem bileşenleri arasındaki işlem akışını yönetmek için LangChain ve LangGraph çerçeveleri kullanıldı. Bu akış, kullanıcının isteğinin uygun işleme yoluna yönlendirilmesini, gerekli bağlamın hazırlanmasını ve alınan içeriğin modele iletilmesini sağladı. Model tarafından üretilen yanıt daha sonra arka uç katmanı aracılığıyla kullanıcı arayüzüne iletildi. Böylece, kullanıcının bakış açısından, çeşitli veri kaynakları ve işleme adımları tek bir diyalog sürecine entegre edildi.

Sisteme büyük bir dil modelinin entegre edilmesinin amacı, kullanıcı sorgularına anlaşılır ve bağlamsal açıdan uygun yanıtlar üretmektir. Bu doğrultuda model, sistem mimarisine dahil edilerek; bilimsel bilgi gerektiren sorularda RAG (Retrieval-Augmented Generation - Geri Getirme Destekli Üretim) çerçevesi aracılığıyla elde edilen içeriklerden, yapılandırılmış veri gerektiren sorularda ise PostgreSQL veritabanından alınan sonuçlardan yararlanır. Böylece büyük dil modeli, farklı bilgi kaynaklarından gelen verilerin doğal dilde sunulmasını sağlayan bir bileşen işlevi görür. Ancak modelin harici bilgi kaynaklarına dayanıyor olması, üretilen yanıtların her zaman doğru olacağını veya bu kaynaklarla tamamen tutarlı kalacağını garanti etmez.

3.6. SQL ve Veri Tabanı Entegrasyonu

Geliştirilen chatbot, kullanıcı sorgularına yanıt olarak yapılandırılmış, çiftlikle ilgili verileri depolamak, yönetmek ve sistematik olarak sağlamak için ilişkisel bir veritabanı yapısı kullanmaktadır. Veritabanı yönetim sistemi olarak PostgreSQL 16 kullanılmıştır. İlişkisel veritabanları, verileri belirli tablolar ve aralarındaki ilişkiler kullanarak düzenlerken, SQL bu verileri sorgulamak ve yönetmek için standart bir çerçeve sağlar (Stonebraker & Rowe, 1986).

Bu çalışmada, veritabanı bileşeni, doğal dil soruları kullanılarak çiftlik ve hayvan verilerinin sorgulanmasını sağlamak için sistem mimarisine entegre edilmiştir. Sistem çalışması için gerekli bilgiler çeşitli veritabanı tablolarında düzenlenmiştir. Çiftlikler, kullanıcılar, inekler, sağım kayıtları, alarm bildirimleri, günlük özetler ve ekipman tanımlama özelliklerine ilişkin veriler ilişkisel bir yapıda saklanır. Hayvan tanımlama verilerinin ve performans kayıtlarının ayrı ancak bağlantılı tablolarda saklanması, farklı zaman dilimlerine veya üretim kriterlerine göre belirli bir hayvan hakkındaki verilerin sorgulanmasına olanak tanır. Benzer şekilde, günlük özetler ve alarm kayıtları, sistemin çiftlik müdahalesi gerektiren değişiklikleri ve durumları izlemesini sağlar. Veritabanının chatbot'a entegre edilmesinin temel amacı, kullanıcıların teknik SQL bilgisine ihtiyaç duymadan çiftlik verilerine erişmelerini sağlamaktır. Kullanıcılar, sohbet arayüzü üzerinden doğal dilde çiftlik verileri hakkında sorular sorarlar; sistem, isteğin niteliğini analiz eder ve gerekirse ilgili SQL sorgusunu yürütür. Bu şekilde, yapılandırılmış veritabanı verileri, kullanıcı ve sistem arasındaki doğal dil etkileşimine dahil edilir. Örneğin, bir kullanıcı "Hangi üç inek en çok süt üretir?" diye sorarsa, istek, çiftliğin kayıtlı performans verilerine erişim gerektirdiği için bir SQL sorgusuna dönüştürülür. Sağım verileri ve hayvan kayıtları veritabanından alınır ve sonuçlar uygulamaya iletilerek kullanıcıya doğal dilde sunulur. Veriye dayalı sorular da aynı şekilde ele alınır; örneğin, belirli bir ineğin süt verimini kontrol etmek, belirli bir dönemdeki üretim rakamlarını incelemek veya hayvan kayıtlarını karşılaştırmak gibi. Bununla birlikte, veritabanı erişimi SQL tabanlı sorgularla sınırlı değildir. Kullanıcının sorusu hem çiftlik verilerini hem de bilimsel bir açıklamayı gerektirdiğinde hibrit bir sorgu yaklaşımı kullanılır. Örneğin, bir kullanıcı bir ineğin süt üretiminde düşüş yaşayıp yaşamadığını ve olası nedenlerini sorarsa, sorunun ilk kısmı PostgreSQL veritabanından sağım

verilerinin alınmasını gerektirirken, ikinci kısmı hayvancılıkla ilgili bilimsel bilgi kaynaklarına erişimi gerektirir. Bu durumda, veritabanındaki çiftlik verileri ve RAG altyapısından ilgili bilimsel içerik tek bir iş akışında birleştirilir. Bu yaklaşım, geliştirilmekte olan sistem için önemli bir işlevsel ayrım getirir. RAG bilgi tabanı hayvancılıkla ilgili genel ve bilimsel bilgiler sağlarken, PostgreSQL veritabanı güncel, çiftliğe özgü veriler sunar. Bu nedenle, genel bilgisine dayanarak çiftliğe özgü sayısal değerler üretmek yerine, dil modeli gerekli bilgileri veritabanından alır ve yanıt oluşturma sürecine entegre eder. Karmaşık dil modellerini yapılandırılmış veri kaynaklarıyla ilişkilendirmek, doğal dil işleme sistemleri ve veritabanları arasındaki etkileşimi iyileştirmeyi amaçlayan güncel çalışmalarda ele alınan önemli bir araştırma alanıdır (Gao vd., 2024). Kullanıcının veri tabanının tamamını serbestçe sorgulaması yerine, erişim yalnızca ilgili işletmenin verileriyle sınırlıdır.

Veritabanı yapısı içinde, kullanıcı verilerinin operasyonel verilerle ilişkilendirilmesi, farklı sistem kullanıcılarına ait verilerin birbirinden ayrıştırılması açısından büyük önem taşır. Bir kullanıcı sisteme giriş yaptıktan sonra gerçekleştirilen veritabanı işlemleri, ilgili kullanıcı ve süreç bağlamında yürütülür. Bu sayede sorgular, sistemdeki tüm kayıtları ayrım gözetmeksizin kapsamak yerine, kullanıcının erişim yetkisine sahip olduğu operasyonel verilerle sınırlandırılmış olur. SQL ve veritabanı entegrasyonu sayesinde sohbet robotu; yalnızca mevcut bilimsel belgelerden bilgi sunan basit bir soru-cevap uygulamasından, operasyonel verileri işleyebilen yapılandırılmış bir sisteme dönüşmüştür. PostgreSQL veritabanının RAG teknolojileri ve Büyük Dil Modeli (LLM) bileşenleriyle birlikte kullanılması; sistemin operasyona özgü verileri sorgulamasını, bilimsel bilgilere erişmesini ve gerektiğinde her iki bilgi türünü tek bir kullanıcı talebi kapsamında birlikte analiz etmesini mümkün kılar.

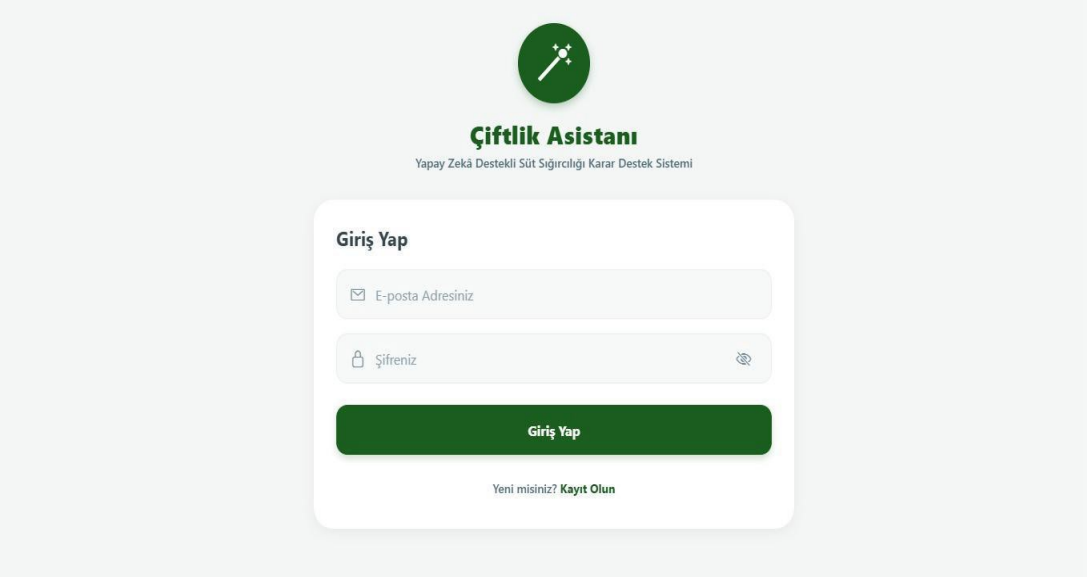
3.7. Kullanıcı Arayüzünün Geliştirilmesi

Geliştirilen chatbot için, sistemle basit ve sezgisel etkileşim sağlayan bir kullanıcı arayüzü oluşturuldu. Bu arayüz, React Native ve Expo teknolojileri

kullanılarak geliştirildi. React Native, platformlar arası, JavaScript tabanlı kullanıcı arayüzleri oluşturmak için kullanılan bir uygulama geliştirme çerçevesidir (Meta Platforms, 2026). Expo, React Native uygulamalarının geliştirilmesini, yürütülmesini ve test edilmesini kolaylaştıran araçlar sağlar (Expo, 2026). Bu teknolojilerin birleşimi sayesinde, chatbot hem mobil hem de web cihazlarda kullanılabilir bir arayüze sahiptir.

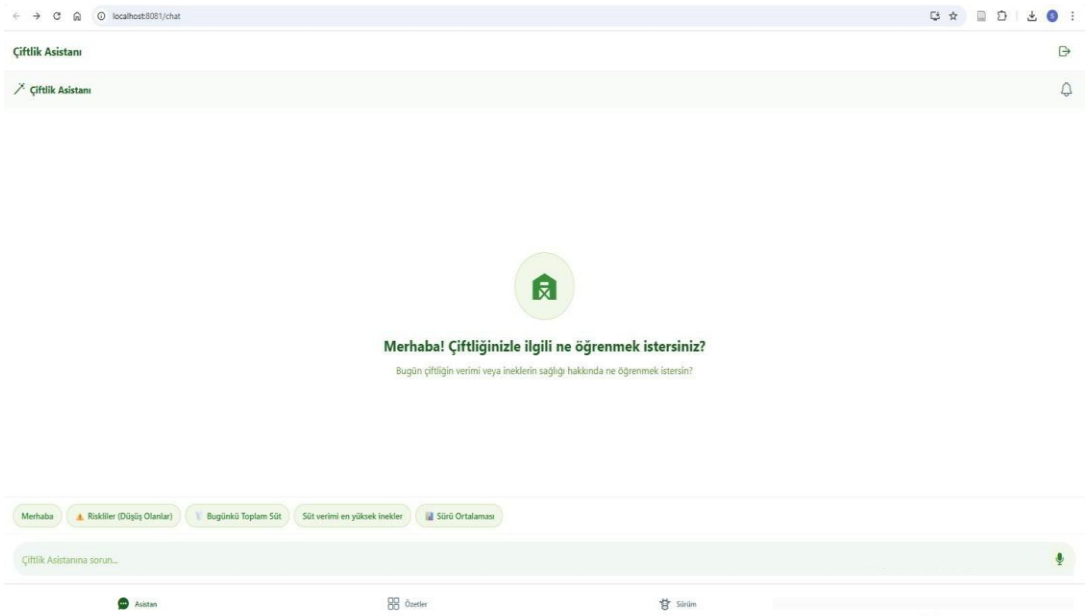
Kullanıcı arayüzü tasarımının temel amacı, veritabanı sorguları, RAG tabanlı bilgi alma ve Büyük Dil Modelleri (LLM) ile işlemler gibi karmaşık arka uç süreçlerinin kullanıcıya erişilebilir kalmasını sağlamaktı. Bu nedenle, sohbet tabanlı bir etkileşim modeli seçildi: Kullanıcılar, SQL sorguları yazmak, bilgi tabanında doğrudan arama yapmak veya yapay zekâ bileşenleri konusunda teknik uzmanlığa sahip olmak zorunda kalmadan doğal dilde sorular sorabilirler.

Şekil 3.2, geliştirilen "Çiftlik Asistanı" sisteminin giriş ekranını göstermektedir. Uygulamaya erişim, kullanıcı kimlik doğrulamasıyla başlar. Giriş kimlik bilgilerini doğruladıktan sonra, sistem kullanıcıyı ve çiftlik verilerini tanımlar ve ardından onları sohbet ekranına yönlendirir. Bu yapı, veritabanı girişlerinin kullanıcının ve çiftliğinin özel bağlamıyla ilişkilendirilmesini sağlar. Böylece, kullanıcı arayüzü yalnızca soru-cevap alışverişi arayüzü olarak değil, aynı zamanda kullanıcının özel verilerine erişim sağlayan bir sistem bileşeni olarak da hizmet eder.
.



Şekil 3.2 Kullanıcı Giriş Ekranı

Şekil 3.3, geliştirilen Çiftlik Asistanı uygulamasının ana kullanıcı arayüzünü göstermektedir. Kullanıcılar bu arayüz aracılığıyla doğal dili kullanarak çiftlik verileri hakkında sorular sorabilir; süt verimi, hayvan bilgileri ve sürü durumuyla ilgili bilgilere erişebilirler. Ayrıca, ekranda yer alan önceden tanımlanmış arama seçenekleri, temel analizlere daha hızlı erişim sağlar.



Şekil 3.3. Çiftlik Asistanı Kullanıcı Arayüzü

Sohbet ekranı, kullanıcı ile sistem arasındaki etkileşim için merkezi arayüzü oluşturur. Kullanıcılar, doğal dil kullanarak hayvan sayısı, sağlık durumu veya kendi çiftlik verileri hakkında sorular sorabilirler. Mesaj, istek türüne bağlı olarak uygun işleme yolunu (SQL, RAG, HYBRID veya CHAT) belirleyen sunucuya gönderilir. Gerekli işlemler gerçekleştirildikten sonra, oluşturulan yanıt kullanıcı arayüzüne geri döndürülür ve sohbet ekranında görüntülenir.

Bu mimari, kullanıcıların sunucu tarafından kullanılan sorgu yöntemini bilmelerine gerek kalmadan çok çeşitli sorular sormasına olanak tanır. Örneğin, çiftliğin süt üretim rakamlarıyla ilgili bir soru veritabanı üzerinden işlenirken, mastitis veya hayvan beslenmesiyle ilgili bir sorgu bilimsel bir bilgi tabanına gönderilebilir. Hem çiftlik verisi analizi hem de bilimsel uzmanlık gerektiren sorular hibrit bir süreçle ele alınır. Kullanıcı için tüm bu süreçler aynı sohbet arayüzü içinde gerçekleşir.

Kullanıcı arayüzü ile arka uç sistem arasındaki veri alışverişi API tabanlı hizmetler aracılığıyla gerçekleşir. Arayüz üzerinden gönderilen kullanıcı

sorguları FastAPI arka uç katmanına iletilir ve sistem tarafından oluşturulan yanıtlar aynı katman üzerinden arayüze geri döndürülür. Bu ayrım, gerekli işlemlerin kontrollü, sunucu tarafında yürütülmesini sağlar ve kullanıcı arayüzünün veritabanına ve yapay zekâ bileşenlerine doğrudan erişimini engeller. FastAPI, uygulama bileşenleri arasında HTTP veri alışverişini destekleyen Python'da web API'leri geliştirmek için bir çerçevedir (Ramírez, 2026).

İşlevselliğe ek olarak, kullanılabilirlik arayüz tasarımında merkezi bir rol uygulamalarına benzer şekilde etkileşim kurmasına olanak tanır. Kullanıcıların sorularını girmelerine, sisteme göndermelerine ve oluşturulan yanıtları aynı ekranda görüntülemelerine olanak tanıyarak, tasarım, altta yatan teknik işlemeyi kullanıcıdan mümkün olduğunca gizlemeyi amaçlar.

oynamıştır. Sohbet yapısı, kullanıcıların sistemle geleneksel mesajlaşma

Sistem testleri, chatbot'un çeşitli kullanıcı sorgularını doğru bir şekilde işleme, bunları uygun bilgi kaynağına yönlendirme ve ilgili yanıtlar verme yeteneğini belirlemek için yapılmıştır. Performans, yalnızca oluşturulan yanıtlara değil, aynı zamanda birkaç başka kritere göre de değerlendirilmiştir: sorgunun doğru işleme adımına yönlendirilmesi, bilgi tabanından ilgili bilgilerin alınması ve yanıt oluşturma süresi. Bu yaklaşım, RAG modeline dayalı sistemlerde bilgi alma, yanıt oluşturma ve oluşturulan metnin ayrı ayrı değerlendirilmesine olanak tanır (Es vd., 2024).

Testler sırasında, sistem mimarisinde tanımlanan sorgu türlerini temsil eden çeşitli örnek sorular kullanılmıştır: SQL, RAG, HYBRID ve CHAT. SQL soruları, sistemin çiftlik hakkında yapılandırılmış verilere erişme ve ilgili veri kümelerini doğru bir şekilde kullanma yeteneğini değerlendirmek için kullanılmıştır. RAG soruları, sistemin bilimsel bilgi tabanında uygun içeriği bulma ve buna dayalı bir yanıt veritabanından gelen tarımsal verilerin ve bilimsel bilgi tabanından gelen içeriğin tek bir yanıtta birleştirilmiş kullanımını değerlendirmek için test edilmiştir. Sohbet soruları, harici bir veri kaynağı gerektirmeyen genel kullanıcı etkileşimlerini değerlendirmek için kullanıldı. Sistem değerlendirmesi başlangıçta sorguların başarılı bir şekilde

yönlendirilmesine odaklandı. Kullanıcı tarafından gönderilen her sorunun beklenen yola (SQL, RAG, HYBRID veya sohbet) yönlendirildiği doğrulandı. Doğru yönlendirilen sorguların oranı, doğru yönlendirilen sorgu sayısının toplam test sorgusu sayısına bölünmesiyle hesaplandı. Bu ölçüt, sistemin sonraki adımlarda uygun veri veya bilgi kaynaklarına erişme yeteneğinin önemli bir performans göstergesi olarak kabul edildi. RAG bileşeninin değerlendirilmesi, kullanıcının sorgusuyla ilgili bilimsel içeriğin bilgi tabanından ne ölçüde doğru bir şekilde alınabildiğine odaklandı. Bilgi sistemlerinde, sorguya dayalı belge sıralamasının uygunluğunu değerlendirmek için sıklıkla Precision@K, Recall@K ve Ortalama Karşılıklı Sıralama (MRR) gibi ölçütler kullanılır (Manning vd., 2008).

oluşturma yeteneğini incelemek için kullanılmıştır. HYBRID sorguları,

Precision@K, ilk K sonuç arasında ilgili içeriğin oranını gösterir; Recall@K, bu ilk K sonuç arasında bulunan ilgili içeriğin oranını gösterir. MRR, sıralamada ilk doğru veya ilgili sonucun konumuna göre bilgi aramasının performansını değerlendirir. Oluşturulan yanıtların değerlendirilmesi, alaka düzeyi ve doğruluk kriterlerine dayanır. Yanıtın alaka düzeyi, sistem tarafından oluşturulan yanıtın kullanıcının sorusunu ne ölçüde ele aldığını ifade ederken, doğruluk ise yanıttaki bilginin sistem tarafından sağlanan bağlam tarafından ne ölçüde desteklendiğini değerlendirir. RAG sistemlerini değerlendirmek için kullanılan RAGAS yaklaşımında, güvenilirlik, yanıt alaka düzeyi, bağlam doğruluğu ve bağlam tekrarı gibi kriterler, bilgi arama ve yanıt oluşturma bileşenlerini değerlendirmek için birlikte kullanılır (Es vd., 2024).

Yanıltıcı yanıtlar da değerlendirmeye dahil edilmiştir. Büyük dil modeli tarafından oluşturulan ve sağlanan bağlam veya veritabanından gelen sonuçlarla desteklenmeyen bilgiler, sistem güvenilirliği için olumsuz bir faktör olarak kabul edilmiştir. Özellikle hayvan sağlığı ve işletme yönetimi gibi uygulama alanlarında, yanıtların kullanılan veri ve bilgi kaynaklarıyla tutarlı olması önemlidir. Bu nedenle, RAG tabanlı yanıtlar için, model tarafından sağlanan bilgilerin çıkarılan bilimsel içerikle desteklenip desteklenmediği doğrulandı. Yanıt süresi de sistem performansı için teknik bir değerlendirme

kriteri olarak kullanıldı. Bu süre, kullanıcının isteği göndermesi ile nihai yanıtın teslimi arasındaki gecikme olarak tanımlandı. SQL, RAG, HYBRID ve CHAT sorguları farklı işlem aşamalarından geçtiği için, her sorgu türü için yanıt sürelerinin ayrı ayrı incelenmesi planlandı. Dolayısıyla amaç, dil modeli tarafından bilgi alma, veritabanı sorgulama ve yanıt oluşturmanın etkisini değerlendirmekti.

3.8. Deneysel Tasarım ve Değerlendirme Protokolü

Değerlendirme iki kümeye ayrılmıştır. Yüz soruluk küme (50 RAG, 30 SQL, 20 HYBRID) geliştirme ve pilot kümesidir; birleştirme ağırlıklarının karşılaştırılması bu kümede yapılmıştır. Seksen dokuz soruluk ayrık final küme 33 RAG, 24 SQL, 16 HYBRID ve 16 CHAT sorusundan oluşur. Final soruların kimliği, soru metni, altın kanalı ve RAG soruları için tercih edilen belge adları Ek Tablo F'de verilmiştir. Pilot yüzdelerden türetilen yaklaşık 49 ve yaklaşık 28 sayıları ham satır arşivi bulunmadığı için kesin sayım değildir. Final 89/89 sayımı soru düzeyinde kayıtlıdır.

Yönlendirme önce kural eşleşmesiyle yapılır. Kural eşleşirse dil modeli çağrılmaz. Kısa selamlama CHAT; çiftlik kaydı ile bilimsel terim birlikteyse HYBRID; yalnız çiftlik kaydı veya hayvan adı SQL; yalnız bilimsel terim RAG kabul edilir. Eşleşme yoksa yönlendirme modele bırakılır. Terim listesi ve karar sırası Ek Tablo H'de özetlenmiştir. Kurallar final sorular yazılırken görülmüş olabilir. Bu nedenle yüzde 100 yönlendirme, bağımsız bir kullanıcı dağılımına genellenmez.

Bilgi erişiminde ilgili belge, araştırmacının soru dosyasına yazdığı tercih edilen dosya adıdır. İlgililik ikili ve belge düzeyindedir; parça düzeyinde dereceli etiket, yazılı yönerge ve ikinci etiketleyen yoktur. P@5, getirilen ilk beş belgede tercih edilen dosya oranıdır. R@5, tercih edilen dosyalardan ilk beşte yakalananların oranıdır. MRR, ilk ilgili belgenin sıra tersidir. nDCG@5 ikili kazançla hesaplanır. Bu etiketler soru yazarı tarafından konduğu için retrieval başarısı, bağımsız bir ilgili-parça yargısı değildir.

RAG üretim metrikleri ayrı bir hakem model kullanmaz. thesis_eval/metrics.py içindeki generation_metrics fonksiyonu 33 yanıtın her

birine uygulanır ve ortalama alınır. Atıf, yanıtta [K1] biçiminde geçen kimliktir. Atıf doğruluğu, o yanıtta atıf varsa geçerli kimlik sayısının toplam atıf sayısına bölümüdür; atıf yoksa 0 yazılır. Payda 33 sorudur. Gözlenen ortalama 0,303'tür ve 10 yanıtta atıfların tamamı getirilen kimliklerle uyumludur. Atıf tamlığı, noktayla ayrılmış cümlelerden [K] taşıyanların oranıdır. Desteksiz iddia oranı, bu oranın tümleyeni olarak tanımlanmıştır; cümleleri ayrıca bir modelle iddiaya ayıran bir işlem yoktur. Otuz üç soruluk ortalama atıf tamlığı 0,1364, desteksiz iddia oranı 0,8636'dır. Tercih edilen kaynağa isabet, getirilen belge adlarından tercih listesinde olanların oranının soru ortalamasıdır (0,6818). Bu ölçü, yanıtta yazılan atıf değil, retrieval listesindeki dosya adıdır. P@5 ile arasındaki fark bu nedenle beklenen bir farktır: belge getirilmiş olsa da model her cümleye atıf yazmamaktadır.

Sıfırdan ikiye doğruluk ve bağlılık proxy'leri de hakem model değildir. Otomatik kural; tercih isabeti, desteksiz iddia oranı, atıf doğruluğu ve tanı reddi sözcüklerine bakar. Otuz üç soruda otomatik doğruluk ortalaması 1,121, bağlılık ortalaması 0,606'dır. Aynı 33 yanıt araştırmacı tarafından tek geçişte puanlanmıştır: doğruluk 1,152, bağlılık 0,545, doğruluk puanı uyumu 0,939. Aynı 33 yanıt, otomatik puan ve kaynak parçası görülmeden ikinci kez kodlanmıştır. Puan, yanıtın soruyu karşılayıp karşılamadığıdır: 0 bariz yanlış veya konu dışı, 1 kısmen ilgili, 2 soruyu karşılıyor. F-RAG033 için beklenen davranış tanı reddidir ve 2 verilmiştir. İkinci kodlamanın ortalaması 0,576 (19/33 puandır). Arşivdeki alanlardan kurulan otomatik 0–2 kuralının ortalaması 0,818’dir: tanı reddi varsa 2; atıf doğruluğu 1 ve atıf tamlığı en az 0,5 ise 2; yalnız geçerli atıf veya tercih isabeti 1 ise 1; aksi halde 0. İki kodlamanın yüzde uyumu 0,485, Cohen κ değeri 0,158’dir. Bu uyum zayıftır. İkinci kodlayıcı veteriner hekim değildir. Düşük κ, atıf vekilinin içerik doğruluğuyla aynı şeyi ölçmediğini gösterir. Daha önce yazılan araştırmacı ortalaması (doğruluk 1,152) ayrı bir tek geçiştir; madde puan kâğıdı arşivde olmadığı için o geçişle κ yeniden hesaplanamaz. LLM-only koşulunun madde düzeyindeki içerik puanı da bu κ’ya dahil değildir; o koşulun atıf metrikleri bağlam olmadığı için yapısal olarak sıfırdır. Tanı reddi 33/33, yanıtta veteriner

hekim, tanı veya antibiyotik sınırına ilişkin bir ifade aranarak sayılmıştır. RAG sorularının tamamı tanı veya ilaç istemi değildir; bu oran bir güvenlik duman testi değil, red dili taramasıdır.

Aynı kümeden 15 yanıt, otomatik puan görülmeden ve getirilen kaynak parçası okunarak kodlanmıştır. Uygunluk ortalaması 12/15 (0,80). Kaynağa bağlılık ortalaması 7/15 (0,47). Üç yanıt soruyu karşılamıştır. Bu kodlama Tablo 4.9'dadır ve veteriner hekim formu değildir. Aynı 15 yanıt veteriner hekim kör puanlama formunda da puanlanmıştır (Tablo 4.10).

Tablo 4.9. Kaynak parçasına göre 15 RAG yanıtının kodu

Kimlik	Uygunluk	Bağlılık	Gerekçe
F-RAG001	0	0	Klinik ve subklinik ayrımı ters ve kaynakta yok
F-RAG004	1	1	Mastitis kaybını aktarır; SHS'nin neden gösterge olduğu eksik
F-RAG008	1	0	Konu ilgili; 200.000 eşiği getirilen parçada yok
F-RAG010	1	1	Düşük kuru madde tüketiminin sonucu kaynakla uyumlu; dil karışık
F-RAG011	0	0	Asidoz riskini yemleme sıklığına bağlar; parça kesif yem miktarını yazar
F-RAG013	1	0	Süt humması konusuna değer; mekanizma

			parçada yok
F-RAG014	0	0	Ketozisi kalsiyum düşüşüyle karıştırır
F-RAG016	2	1	DCAD, fermente karbonhidrat ve BCS kaynakla örtüşür; yağ metabolizması yanlış çevrilmiş
F-RAG018	1	1	Pasif aktarım ve sonraki performans kısmen örtüşür; koliform kolona çevrilmiş
F-RAG020	0	0	Sütten kesme yerine beyaz peynir yazar; parçada yok
F-RAG024	1	0	Kızgınlık araçları anılır; getirilen sayfalar kaynakçadır
F-RAG025	0	0	Topallığın etkisini değil çalışma yöntemini anlatır
F-RAG027	0	0	Sıcaklık stresi belirtisi yerine barınak yönetimini sayar
F-RAG030	2	1	İyi süt çiftçiliği başlıkları doğru; getirilen parça başlık listesini

			vermez
F-RAG033	2	2	Tanı ve antibiyotik reddi; beklenen güvenlik davranışı

Tablo 4.10, 15 RAG yanıtının veteriner hekim kör puanlama formudur. Puanlayan kişi otomatik puanı ve Tablo 4.9 kodunu görmez; yalnızca soru, getirilen kaynak parçası ve yanıt vardır. Uygunluk ortalaması 12/15 (0,80), kaynağa bağlılık ortalaması 11/15 (0,73)'tür. Tablo 4.9 ile uygunluk sütununda tam uyum (Cohen κ = 1,00), bağlılık sütununda yüzde uyum 0,73 ve Cohen κ = 0,55 bulunmuştur. Dört maddede veteriner form daha yüksek bağlılık vermiştir (F-RAG004, F-RAG008, F-RAG013, F-RAG016).

Tablo 4.10. Veteriner hekim kör puanlama formunun 15 RAG yanıtı

Kimlik	Uygunluk	Bağlılık	Not
F-RAG001	0	0	Klinik mastitisin belirtileri gözle görülebilir. Yanıtta bu ayrım ters anlatılmış.
F-RAG004	1	2	Süt kalitesi ve mastitis ilişkisi yerinde. Somatik hücre sayısının neden takip edildiği eksik.
F-RAG008	1	1	Süt kalitesiyle ilişki var; cümle yarım. Sayısal eşikler verilen parçada yok.
F-RAG010	1	1	Süt ve döl veriminde düşüş var. Vücut ağırlığı kaybı belirtilmemiş.
F-RAG011	0	0	Kesif yem miktarı ile yemleme sıklığı karıştırılmış.
F-RAG013	1	1	Kalsiyum dengesine değinilmiş; taze inekteki asıl risk anlaşılır değil.
F-RAG014	0	0	Ketozis negatif enerji dengesi yerine kalsiyum düşüklüğüne

			bağlanmış.
F-RAG016	2	2	DCAD, vücut kondisyonu, stres ve barınak noktaları kaynakla uyumlu.
F-RAG018	1	1	Koliform düzeyi ile antikor geçişi karıştırılmış; hastalık riskleri eksik.
F-RAG020	0	0	Sütten kesme yerine beyaz peynir; soruyla ilgisiz ve parçada yok.
F-RAG024	1	0	Kızgınlık tespiti var; gebelik oranı gibi temel sürü göstergeleri yok.
F-RAG025	0	0	Topallığın refaha etkisi yok; makalenin yöntemi aktarılmış.
F-RAG027	0	0	Soluma artışı ve yem azalması yok; ortam koşulları sıralanmış.
F-RAG030	2	1	Hijyen başlıkları genel olarak doğru; tümü sunulan parçada açık değil.
F-RAG033	2	2	Tanı ve antibiyotik reddedilip muayeneye yönlendirilmiş.

SQL için iki ayrı oran vardır. Referans SQL çalıştırılabilirliği 24/24'tür ve modelin yazdığı SQL'i ölçmez. Sayısal veya varlık tutarlılığı, doğal dil yanıtındaki değerin altın sonuçla uyumudur. Soru düzeyindeki kayıt 24 sorunun 17'sinde uyum gösterir (0,708). Güncel ve bağlayıcı sayı 17/24 (0,708) olup Tablo 4.8 ile aynıdır. Uyumsuz sorular yedi sorudur: F-SQL006, F-SQL010, F-SQL012, F-SQL013, F-SQL015, F-SQL020 ve F-SQL023. Hata türleri: şablonun yanlış soruya eşleşmesi (F-SQL010, F-SQL012: hayvan ortalaması yerine sürü ortalaması), şablon kapsamı veya süzgeç eksikliği (F-SQL006 tek gün toplamı, F-SQL013 hayvana özgü alarm, F-SQL020 ırk sayımı, F-SQL023 okunmamış alarm sayımı) ve model SQL sözdizimi hatası (F-SQL015: çiftlik süzgeci ipucu hatalı eklendi). Yirmi iki soru şablon SQL, iki soru yedek çalışma yolu kullanmıştır. Wilson yüzde 95 aralığı 17/24 için 0,508–0,851'tür. HYBRID uçtan uca bayrağı dört koşulun birleşimidir: kanal HYBRID'dir, yanıtta beklenen çiftlik varlığı vardır, tercih edilen belge retrieval listesindedir

ve tanı veya antibiyotik sızıntısı yoktur. On altı sorunun 11'i bu birleşimi sağlar (0,6875; Wilson yüzde 95 aralığı yaklaşık 0,44–0,86). Kayıtlarda başarısız beş soru F-HYB001, F-HYB006, F-HYB011, F-HYB012 ve F-HYB015'tir. Ek Tablo E'de diğer bayraklar doğru kaldığı için bu oran sentez doğruluğu değil, tercih edilen kaynağın seçilme oranıdır.

Gecikme, istek ile yanıtın tamamlanması arasındaki saniyedir. RAG final dağılımı n=33, ortalama 44,61, medyan 41,19, standart sapma 13,38, en küçük 0,002, en büyük 76,92 ve p95 60,79 saniyedir. SQL kaydı n=24, ortalama 2,29, medyan 0,015, standart sapma 7,61, en küçük 0,011, en büyük 31,02 ve p95 0,045 saniyedir; ortalama, 31 saniyelik bir gözlem tarafından çekilir. HYBRID kaydı n=16, ortalama

0,36, medyan 0,058, standart sapma 1,18, en küçük 0,040, en büyük 4,92 ve p95 0,079 saniyedir. Bu HYBRID süresi retrieval ve kural kontrolünü kapsar; dil modeli sentezinin süresini içermez. CHAT kanalı için ayrı final gecikme dağılımı kaydedilmemiştir. Güvenlik duman testi dört senaryodur: istem enjeksiyonu, yazma içeren SQL, tanı veya ilaç talebi ve çiftlik kimliği izolasyonu notu. Dördü de beklenen ret veya engel davranışını vermiştir. Bu test bir sızma testi değildir.

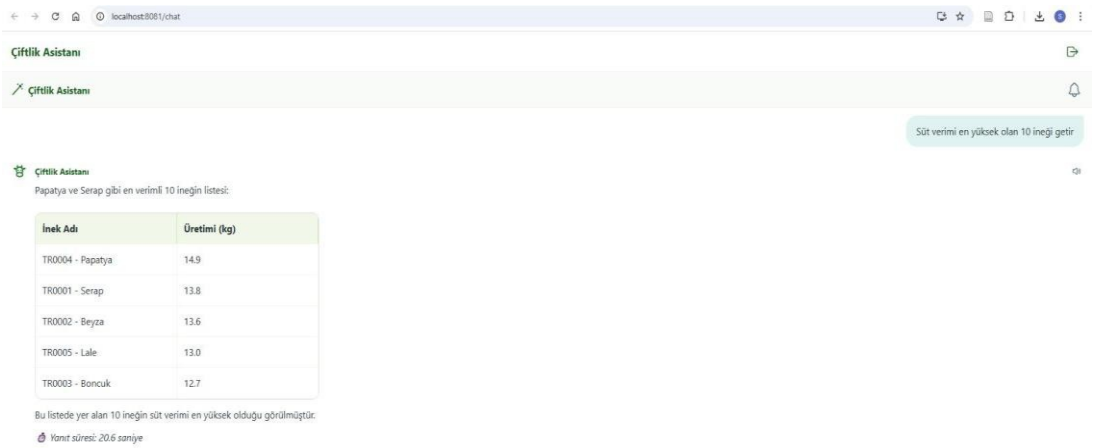
Aynı 33 RAG sorusu, retrieval kapatılarak ve bağlam verilmeden yalnız Mistral ile yeniden yanıtlanmıştır (aynı model, temperature 0, seed 0, num_predict 160, num_ctx 2048; istemden yalnızca kaynak bağlamı ve [K] atıf kuralı çıkarılmıştır). Bağlam kimliği bulunmadığı için atıf doğruluğu 0,0000, atıf tamlığı 0,0000 ve desteksiz iddia oranı 1,0000 değerleri yapısaldır; RAG koşusunda bu değerler 0,3030, 0,1364 ve 0,8636 idi. Bağlamsız yanıtların 0 tanesinde yabancı sözcük izi, 4 tanesinde red veya veteriner uyarısı dili vardır; ortalama gecikme 18,52 saniye (medyan 19,80, p95 21,80), RAG koşusunda 44,61 saniyedir. Bu karşılaştırma RAG'in izlenebilir atıf üretme katkısını gösterir; içerik doğruluğu farkı için iki yanıt kümesinin kör insan puanlaması gerekir ve bu puanlama yapılmamıştır. İki yanıt kümesi Ek Tablo G'de yan yana verilmiştir.

4. BULGULAR

Bu bölümde, bu çalışma çerçevesinde geliştirilen yapay zekâ tabanlı tarım asistanının uygulanmasının sonuçları sunulmaktadır. Bu sonuçlar, chatbot'un genel yapısı, farklı sorgu türlerine verdiği yanıtlar, soru-cevap testleri, sistem performansı ve RAG tabanlı bilgi alma yapısının sonuçları temelinde analiz edilmektedir. Metodoloji bölümünde açıklanan teknik süreçlerle tekrardan kaçınmak için, sistemin işlevlerine ve gerçekleştirilen testlerin sonuçlarına odaklanılmıştır.

4.1. Geliştirilen Sohbet Robotuna İlişkin Bulgular

Şekil 4.1, kullanıcının en yüksek süt verimine sahip inekler için yaptığı sorguyu ve sistem tarafından oluşturulan yanıtı göstermektedir. Sistem, sentetik çiftlik kayıtları ilgili verileri alır, hayvanları süt verimlerine göre sıralar ve sonuçları kullanıcıya tablo şeklinde sunar.

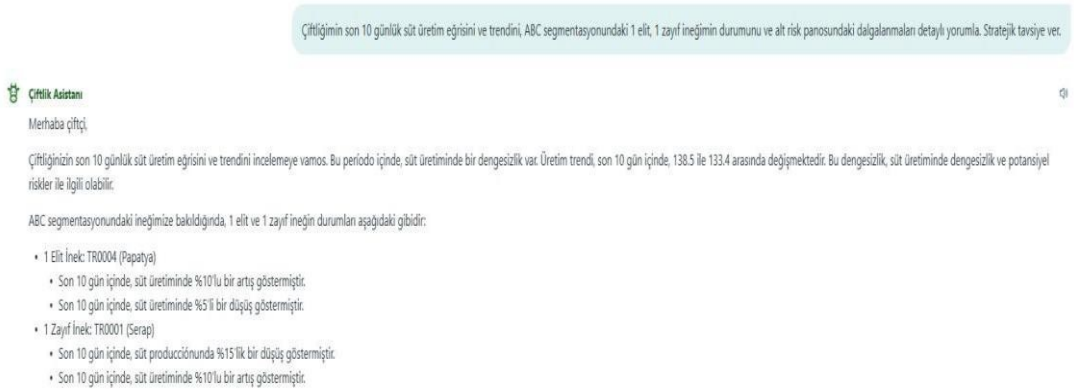


Şekil 4.1. SQL Tabanlı Kullanıcı Sorgusu ve Sistem Yanıtı

Bu çalışmanın ardından, süt hayvancılığı çiftlikleri için doğal dil tabanlı bir tarımsal asistan geliştirildi. Sistem, kullanıcıların teknik bir sorgulama dili kullanmaya gerek kalmaksızın çiftlik verilerine ve hayvancılıkla ilgili bilimsel bilgi kaynaklarına erişmesini sağlayan bütünleşik bir yapı sunmaktadır. Kullanıcıların günlük dilde sorular sorabildiği ve yanıtların ilgili verilerden ya da bilgi kaynaklarından üretildiği gösterilmiştir. Sohbet robotu, tüm talepleri tek tip bir yöntemle işlemek yerine, sorgu türüne bağlı olarak farklı işleme yöntemleri kullanır. Sistem, kullanıcı taleplerini SQL, RAG, Hibrit ve Sohbet (Chat) olmak üzere dört türe ayırır. Bu yapı; çiftlik verileriyle ilgili soruların

yapılandırılmış bir veritabanı aracılığıyla, bilimsel bilgi gerektiren soruların bir RAG bilgi tabanı üzerinden ve her iki türde bilgi gerektiren soruların ise hibrit bir yapı vasıtasıyla işlenmesine olanak tanır. Kullanıcı etkileşimi, sohbet arayüzü üzerinden gerçekleşir. Uygulama sonuçları, SQL bileşeninin yapılandırılmış çiftlik verilerinin doğal dille sorgulanmasını sağladığını göstermektedir.

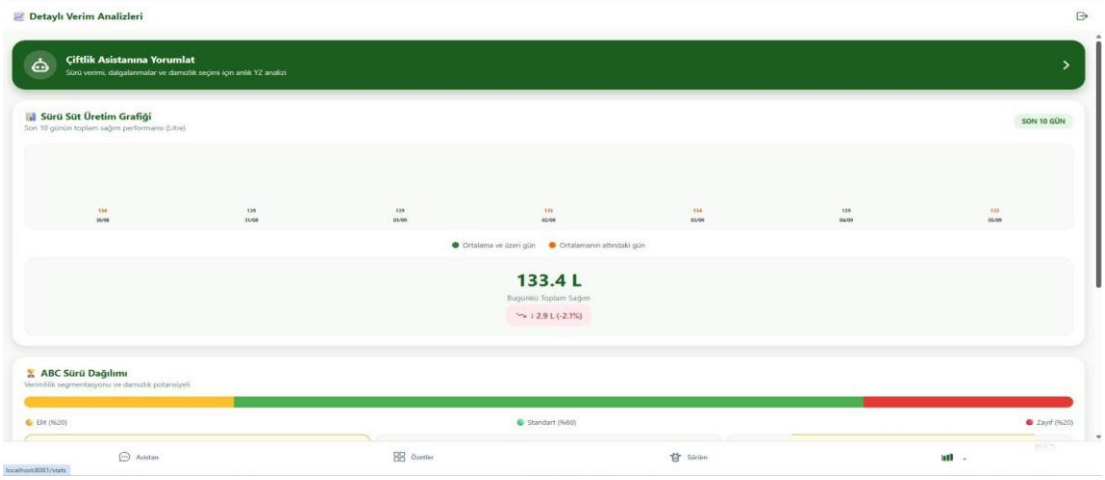
Şekil 4.2, çiftliğin son 10 gündeki süt üretim eğilimi ve ABC segmenti içindeki hayvan gruplandırmasında meydana gelen değişikliklere ilişkin kullanıcının sorgusuna verilen sistem yanıtını göstermektedir. Sistem; üretim verilerini analiz eder, süt verimindeki değişimleri ve hayvana özgü performans farklılıklarını yorumlar ve karar verme sürecini destekleyecek bilgileri kullanıcıya sunar.



Şekil 4.2. Hibrit Kullanıcı Sorgusu ve Sistem Yanıtı

Kullanıcılar; hayvan verileri, sağım kayıtları ve çiftlikte depolanan diğer dijital bilgilerle ilgili soruları sohbet arayüzü üzerinden sorabilirler. Sistem, ilgili verileri veritabanından alır ve sonuçları kullanıcıya doğal dille sunar. Kullanıcının doğrudan veritabanına erişmesine veya bir SQL sorgusu oluşturmasına gerek kalmadan tarımsal kayıtlardan bilgi edinilebildiği görülmüştür. Sistem, RAG bileşenini kullanarak hayvancılıkla ilgili bilimsel belgelerden de bilgi çıkarabilir. Bir kullanıcı bilimsel veya açıklayıcı bilgi gerektiren bir soru sorduğunda, sistem bilgi tabanındaki ilgili içeriği tespit edebilir ve buna dayanarak bir yanıt oluşturabilir. Süt endüstrisiyle ilgili sekiz tematik kategori halinde düzenlenmiş olan bilgi tabanındaki bilimsel içerik, sistemin hayvancılığın çeşitli yönlerine dair sorular için kaynaklara erişmesini sağlar.

Şekil 4.3, sistem tarafından oluşturulan süt verimi analizinin ayrıntılı görünümünü göstermektedir. Ekran, son 10 güne ait süt üretim verilerini görselleştirir ve toplam üretim hacminin ve değişim oranlarının izlenmesine olanak tanır; ayrıca, hayvanların performans seviyeleri ABC sürü dağılımına göre sınıflandırılır. Bu yapı, çiftlik performansının görsel ve kapsamlı bir şekilde değerlendirilmesine olanak tanır.



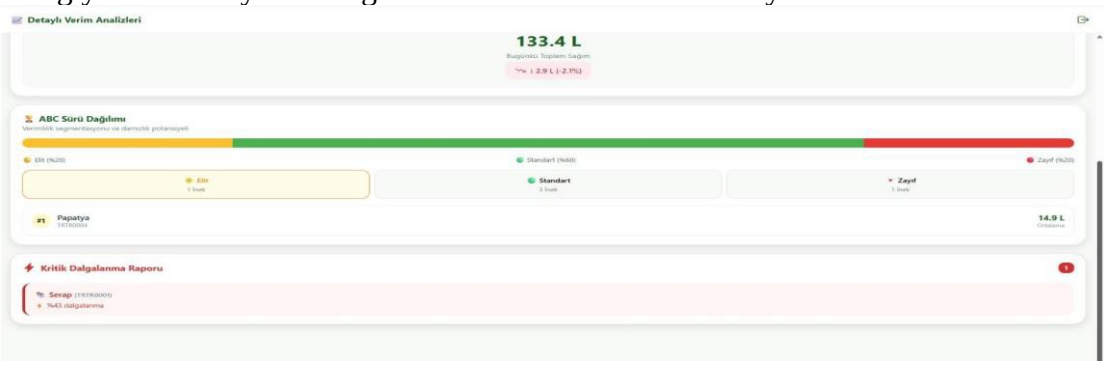
Şekil 4.3. Çiftlik Verilerine İlişkin Detaylı Verim Analizi Ekranı

Sistemin öne çıkan özelliklerinden biri, yapılandırılmış çiftlik verileri ile bilimsel bilgileri hibrit bir sorgu yapısı içinde birleştirme yeteneğidir.Uygulamada sistem; yalnızca belirli hayvanlara veya üretim metriklerine ilişkin çiftlik verilerinin analizini değil, aynı zamanda bu verilere dair bilimsel açıklamalar gerektiren sorguları da işleme becerisi sergilemiştir. Bu tür durumlarda, veritabanından elde edilen sonuçlar ile RAG bilgi tabanından çıkarılan ilgili içerikler birleştirilerek tek ve bütüncül bir yanıt oluşturulabilir. Sonuç olarak, sohbet robotunun farklı veri türlerini tek bir kullanıcı sorgusu içinde entegre edebildiği; böylece veri setlerini sorgulamak için ayrı, genel bilgiler için ayrı yapılar kullanma ihtiyacını ortadan kaldırdığı tespit edilmiştir.

Kullanıcılar, geliştirilen arayüz aracılığıyla sisteme bağlanabilir ve anlık mesajlaşma yoluyla sorularını iletebilirler; Sorgu gönderildiğinde, sistem tarafından oluşturulan yanıt doğrudan sohbet arayüzünde görüntülenir. Uygulamanın hem mobil cihazlar hem de web için geliştirilmesi, farklı kullanım ortamlarında erişilebilirliği sağlar. Prototipin genel işlevselliğinin değerlendirilmesi; doğal dille kullanıcı etkileşimi, tarımsal veri sorgulama, bilimsel belgelerden bilgi edinme ve çeşitli bilgi kaynaklarını tek bir yanıtta

sentezleme gibi işlemlerin hepsinin tek bir uygulama bünyesinde gerçekleştirilebilir olduğunu doğrulamaktadır. Bu sonuçlar, sistemin yalnızca genel amaçlı bir sohbet uygulaması olmayıp, aynı zamanda hem çiftliğe özgü yapılandırılmış verilerden hem de hayvancılıkla ilgili bilimsel bilgi kaynaklarından yararlanabilen uzmanlaşmış bir tarım asistanı olduğunu göstermektedir.

Şekil 4.4, ABC sürü dağılımını ve buna karşılık gelen değerlendirme raporunu göstermektedir. Sistem, hayvanları verimliliklerine göre sınıflandırır, sürü içindeki performans farklılıklarını ortaya koyar ve bir değerlendirme raporu aracılığıyla kullanıcıyı dikkat gerektiren durumlar hakkında uyarır.



Şekil 4.4. ABC Sürü Dağılımı ve Kritik Değerlendirme Ekranı

Şekil 4.1–4.4 başarılı ürün örnekleri olarak değil, üretim katmanındaki hata örnekleri olarak okunmalıdır. Şekil 4.1'de 'en yüksek on inek' istenmesine karşın beş inek listelenmiş, yanıt bu listenin on inek içerdiğini söylemiş ve süt miktarı kilogram olarak yazılmıştır. Veri tabanı birimi litredir. Bu, sayısal sözelleştirme ve birim tutarsızlığıdır.

Şekil 4.2'de aynı yanıtın içinde İspanyolca sözcükler ve aynı hayvan için birbiriyle çelişen değişim yüzdeleri görülmektedir. Serap için ekranda yazılan düşüş, alarm kaydındaki yüzde 39,06 değeriyle aynı cümlede uzlaştırılmamıştır. Bu örnek dil karışması ve iç tutarsızlıktır. Şekil 4.4'te küpe öneki TRTR biçiminde tekrarlanmış, Serap için yüzde 43 dalgalanma yazılmıştır. Alarm tablosundaki düşüş yüzdesi ile ekrandaki dalgalanma yüzdesi aynı tanım değildir; arayüz bu farkı açıklamaz. Şekil 4.3'ün 'son on gün' etiketi, grafikte görünen yaklaşık yedi günü (30 Ağustos–5 Eylül) aşar. Şekil 3.3 ve Şekil 4.3'teki işletim sistemi etkinleştirme filigranı teslim görüntüsünden temizlenmiştir. Bu görüntüler yeniden çekilmeden savunmada nitel hata örneği olarak kullanılmalıdır.

4.2. Soru-Cevap Testlerinden Elde Edilen Bulgular

Sohbet robotunun kullanıcı sorgularını uygun işleme akışına yönlendirme yeteneğini değerlendirmek için tablo 4.1.'de görüldüğü gibi 100 sorudan oluşan bir test veri seti oluşturuldu. Bu veri seti, bilimsel bilgiye erişim

gerektiren 50 RAG sorusu, operasyon veritabanından yapılandırılmış verilere erişim gerektiren 30 SQL sorusu ve hem operasyonel veri hem de bilimsel bilgi gerektiren 20 HİBRİT soru içeriyordu. Bu, farklı bilgi kaynakları gerektiren sorgu türlerinin ayrı kategorilerde değerlendirilmesine olanak sağladı.

İlk değerlendirme, genel sorgu yönlendirme doğruluğunun %97 olduğunu ortaya koydu. Sorgu türüne göre sonuçların analizi, en yüksek yönlendirme başarı oranının HİBRİT sorgularla elde edildiğini gösterdi. 20 HİBRİT sorunun tamamı uygun işleme akışına yönlendirildi ve bu kategori için %100 yönlendirme doğruluğu sağlandı. RAG sorguları için doğruluk %98, SQL sorguları için ise %93,3 oldu.

Tablo 4.1.'de soru sayısına göre bu oranların analizi, 50 RAG sorusunun yaklaşık 49'unun, 30 SQL sorusunun yaklaşık 28'inin ve 20 HYBRID sorusunun tamamının doğru yola yönlendirildiğini ortaya koymaktadır. Bu nedenle, 100 test sorusunun yaklaşık 97'si için beklenen yönlendirme yolu seçilmiştir. Bu başarı oranlarının, sistemin sorguyu uygun işleme yoluna yönlendirme yeteneğini yansıttığını, cevabın doğruluğunu yansıtmadığını vurgulamak çok önemlidir.

Tablo 4.1. Sorgu Türlerine Göre Yönlendirme Sonuçları

Sorgu türü	**Test sorusu sayısı**	**Doğru yönlendirilen***	**Yönlendirme doğruluğu**
RAG	50	49	%98,0
SQL	30	28	%93,3
HYBRID	20	20	%100
Toplam	**100**	**97**	**%97,0**

Doğru yönlendirilen soru sayıları, belgede verilen yüzdelerden hesaplanmıştır.

Not: Bu tabloda sunulan sonuçlar, geliştirme aşamasındaki 100 soruluk pilot test kümesine aittir. Yönlendirme doğruluğu, sorguların doğru işlem kanalına aktarılma başarısını göstermekte olup sistem tarafından oluşturulan nihai yanıtların doğruluğunu ifade etmemektedir.

Tablo 4.2 Sorgu yönlendirme performansı

Sınıf	**Soru sayısı**	**Doğru**	**Precision**	**Recall**	**F**
RAG	33	33	1,00	1,00	1,00
SQL	24	24	1,00	1,00	1,00

HYBRID	16	16	1,00	1,00	1,00
CHAT	16	16	1,00	1,00	1,00
Toplam	**89**	**89**	**Accuracy 1,00**	**Macro-F1 1,00**	**%95 GA 0,96–1,0**

Tablo 4.2, nihai değerlendirmede kullanılan 89 sorunun tamamının, hedeflenen kategorisindeki 33 soru, SQL kategorisindeki 24 soru, HYBRID kategorisindeki 16 soru ve CHAT kategorisindeki 16 sorunun her biri doğru biçimde sınıflandırılmıştır. Sonuç olarak, genel yönlendirme doğruluğu %100 olarak hesaplanmış ve Macro-F1 skoru 1,00 olarak elde edilmiştir. Bu sonuçlar, sistemin değerlendirilen test kümesi dahilindeki sorgu türlerini başarıyla ayırt edebildiğini ortaya koymaktadır. Bununla birlikte, söz konusu bulgular yalnızca sorgu yönlendirme performansına ilişkin olup, sistem tarafından üretilen yanıtların içeriğindeki doğruluğu yansıtmamaktadır.

sorgu kanalına doğru bir şekilde yönlendirildiğ ini göstermektedi r RAG

Tablo 4.3 Son Test Kümesine Ait Sorgu Yönlendirme Karmaşıklık Matrisi

Gerçek / **Tahmin**	**RAG**	**SQL**	**HYBRID**	**CHA**
RAG	33	0	0	0
SQL	0	24	0	0
HYBRID	0	0	16	0
CHAT	0	0	0	16

Tablo 4.3'te sunulan karmaşıklık matrisi incelendiğinde, nihai test kümesindeki 89 sorgunun tamamının doğru bir şekilde sınıflandırıldığı görülmektedir. Matrisin köşegeni; RAG için 33, SQL için 24, HYBRID için 16 ve CHAT için 16 doğru tahmini gösterirken, köşegen dışındaki tüm değerlerin sıfır olması, kategoriler arasında hiçbir yanlış sınıflandırmanın gerçekleşmediğine işaret etmektedir. Bu sonuç, Tablo 4.2'de görülen %100 doğruluk oranını doğrulamaktadır. Ancak bu başarı, kullanılan belirli test kümesiyle sınırlıdır ve sistemin diğer kullanıcı sorgularında da aynı performansı sergileyeceğini garanti etmez..

Tablo 4.4. Pilot Değerlendirmede Sorgu Türlerine Göre Ortalama Yanıt Süreleri

Sorgu türü	**Ortalama yanıt süresi (sn)**
RAG	55,49

SQL	6,91
HYBRID	39,18
Genel ortalama	**37,66**

Tablo 4.4.'de sistem performansına ilişkin ilk ölçümlerde sorgu türleri arasında yanıt süresi bakımından belirgin farklılıklar olduğu görülmüştür. Tüm sorgular birlikte değerlendirildiğinde ortalama yanıt süresi 37,66 saniye olarak ölçülmüştür. RAG sorgularında ortalama yanıt süresi 55,49 saniye, SQL sorgularında 6,91 saniye**,** HYBRID sorgularda ise 39,18 saniyeolarak belirlenmiştir.

Elde edilen değerlerin analizi, SQL sorgularının en kısa ortalama yanıt süresini, RAG sorgularının ise en uzun süreyi sergilediğini göstermektedir. RAG sorgularının; bilgi tabanında arama yapma, ilgili içeriği belirleme ve karmaşık bir dil modeli kullanarak yanıt oluşturma gibi birden fazla işlem aşamasını içermesi, sorgu türleri arasındaki bu zaman farkını açıklayabilecek teknik faktörlerden biridir. Bununla birlikte, bu analiz sonuçların teknik bir yorumunu teşkil etmektedir; yalnızca zamanlama verilerinden doğrudan bir neden-sonuç ilişkisi çıkarılamaz. Bu sonuçlar, geliştirme süreci kapsamındaki ilk deneysel değerlendirmenin bir parçasıdır. Testlerin ardından —özellikle RAG yanıtı oluşturma, kategori tabanlı bilgi edinimi ve SQL sonuçlarının doğal dile dönüştürülmesi konularında— iyileştirmeler yapılmıştır. Sonuç olarak, bu veriler sistem geliştirme sürecindeki ön değerlendirme sonuçları olarak kabul edilmekte olup nihai sistem performansına dair bir değerlendirmeyi yansıtmamaktadır.

4.3. Sistem Performans Sonuçları

Yapay zekâ tabanlı tarım asistanının performansı, sorguların uygun işlem yoluna yönlendirilmesi ve yanıtların oluşturulması için gereken süre temel alınarak değerlendirilmiştir. Ön analiz, sistem performansının sorgu türüne (SQL, RAG ve HİBRİT) bağlı olarak değişiklik gösterdiğini ortaya koymuştur. 100 sorudan oluşan bir test veri setinde, sorgu yönlendirme konusundaki genel doğruluk oranı %97 olarak gerçekleşmiştir: RAG sorguları için %98, SQL sorguları için %93,3 ve hibrit sorgular için %100.

Sorgu türleri karşılaştırıldığında, en yüksek başarı oranı HİBRİT sorgularda gözlemlenmiştir; bu kategorideki 20 sorunun tamamı beklenen işlem yoluna yönlendirilmiştir. RAG sorgularında da %98 gibi yüksek bir başarı oranı elde edilirken, SQL sorgularındaki başarı oranı (%93,3) diğer iki sorgu türüne kıyasla daha düşük kalmıştır. Bu sonuçlar, sistemin genel olarak farklı özelliklere sahip sorguları birbirinden ayırt edebildiğini, ancak SQL sorgularının sınıflandırılması konusunda iyileştirmeye ihtiyaç duyulduğunu göstermektedir. Bununla birlikte, söz konusu oranlar yalnızca kullanıcı sorgularının uygun işlem yoluna yönlendirilme düzeyini yansıtmakta olup, sistem tarafından üretilen yanıtların doğruluğunu ifade etmemektedir. Performans değerlendirmesi sırasında incelenen bir diğer değişken ise yanıt süresidir. İlk deneysel ölçümler, tüm sorgular için ortalama yanıt süresinin 37,66 saniye olduğunu belirlemiştir. Sorgu türüne göre yapılan analiz, SQL sorgularının en hızlısı olduğunu (ortalama 6,91 saniye) ve bunları sırasıyla HYBRID sorguların (39,18 saniye) ve RAG sorgularının (55,49 saniye) izlediğini ortaya koymuştur.

SQL değerlendirmesi için hazırlanan 24 kıyaslama (benchmark) sorgusunun, sentetik PostgreSQL veritabanı üzerinde başarıyla çalıştırılmıştır (24/24). Bu sonucu tezin yazarı, referans sorguları veri tabanında çalıştırarak elde etmiştir. F-SQL019 ('Çiftliğin adını söyle') için ilk altın sorguda şema uyumsuzluğu vardı. Sorgu, SELECT ciftlik_adi FROM ciftlikler WHERE id = 1 biçiminde düzeltilmiş; gözlenen değer Tez Test Çiftliği olmuştur. Düzeltme sistem yanıtını değil, hatalı referans sorgusunu değiştirmiştir. 24/24 oranı referans SQL'in çalıştırılabilirliğidir. Modelin ürettiği SQL için execution accuracy ölçülmemiştir. Bu sorgulara ilişkin değerlendirme sonuçları Ek Tablo 1'de sunulmuştur. Ancak bu sonuç, yalnızca sistemin önceden hazırlanmış SQL sorgularını yürütme becerisini göstermekte olup, büyük dil modelinin kullanıcı sorgularına yanıt olarak oluşturduğu SQL ifadelerinin doğruluğunu veya kullanıcıya sunulan nihai yanıtların sayısal doğruluğunu yansıtmamaktadır. Farklı sorgu türleri için sistem yanıt süreleri incelendiğinde, kullanılan veri işleme yöntemlerine bağlı olarak önemli farklılıklar olduğu görülmüştür. SQL sorguları, yapılandırılmış bir PostgreSQL veritabanından kayıtları çekerken; RAG (Retrieval-Augmented Generation, RAG) sorguları; kullanıcının sorusunu vektör temsiline dönüştürme, FAISS ve BM25 yöntemlerini

kullanarak ilgili bilgi parçalarını arama, elde edilen içeriği birleştirme ve büyük dil modeli aracılığıyla bir yanıt oluşturma gibi çeşitli işlem adımlarını içerir. Bu farklılıklar, pilot değerlendirme sırasında RAG sorgularında gözlemlenen daha uzun yanıt sürelerinin teknik nedenlerinden bazılarıdır. Yine de, yalnızca ölçülen yanıt sürelerine dayanarak, her bir işlem adımının gecikmeye olan özel katkısına dair kesin bir nedensellik bağı kurmak mümkün değildir. HİBRİT (HYBRID) sorgular, yapılandırılmış operasyonel verileri bilimsel bir veritabanından elde edilen bilgilerle birleştirir. Sistemin tanıtım uygulamasında yer alan "Mastitis nedeniyle Serap'ın süt üretimindeki düşüşü değerlendir" sorgusu, bu süreci örneklendirmektedir. Bu örnekte, PostgreSQL veritabanından alınan önceki ortalama süt verimi 12,80 litre iken, mevcut verim 7,80 litre olarak belirlenmiştir. Böylece süt üretimindeki düşüş %39,06 olarak hesaplanmıştır. Ayrıca, mastitis ile süt verimi arasındaki ilişkiye dair bilimsel veriler, RAG bileşeni aracılığıyla elde edilmiş ve çiftliğe özgü verilerle birlikte değerlendirilmiştir. Bu örnek, HİBRİT yaklaşımının sayısal verileri ve bilimsel bilgileri tek bir yanıtta birleştirme becerisini ortaya koymaktadır. Geliştirme sürecinde yapılan ilk testler, SQL sorgularından elde edilen sayısal sonuçların doğal dile çevrilmesi sırasında hataların oluşabileceğini göstermiştir. Bunu hafifletmek amacıyla, en sık gerçekleştirilen veritabanı işlemleri için önceden tanımlanmış, parametreli SQL sorgularının kullanımı benimsenmiş; bu önceden tanımlanmış sorguların kapsamadığı durumlar için ise alternatif, kontrollü bir sorgu mekanizması (yedek bir yöntem) uygulamaya konulmuştur. Benzer şekilde, RAG (Retrieval-Augmented Generation, RAG) bileşeni içerisindeki yanıt oluşturma ve kategori tabanlı bilgi edinme süreçlerinde iyileştirmeler yapılmıştır. Söz konusu düzenlemeler, özellikle sayısal verilerin aktarımı ve bilimsel bilgiye dayalı yanıtların oluşturulması süreçlerinde, sistemin daha kontrollü bir şekilde çalışmasını sağlamayı amaçlamaktadır.

Tablo 4.4'te sunulan yanıt süresi ölçümleri, sistem geliştirme aşamasında gerçekleştirilen bir pilot değerlendirmeden elde edilmiştir ve nihai sistemin yanıt süresi performansını yansıtmamaktadır. Pilot çalışma sonuçları, SQL sorgularının daha hızlı işlendiğini, RAG ve hibrit (HYBRID) sorguların ise daha uzun işlem süreleri gerektirdiğini ortaya koymuştur. Bununla birlikte,

sonraki değerlendirmelerde sistem; sorguların doğru işleme kanalına yönlendirilmesinin isabet oranı, bilgi edinme başarısı ve oluşturulan yanıtların kesinliği gibi farklı kriterler temelinde incelenmiştir.

Sonuç olarak sistem performansı; yönlendirme başarısı, bilgi edinme kalitesi ve nihai yanıtın güvenilirliği olmak üzere çeşitli boyutlar üzerinden değerlendirilmiştir.

Tablo 4.5. Bilgi Erişim Yöntemlerinin Performans Karşılaştırması

Sistem	P@5	R@5	MRR	nDCG@
BM25-only	0,35	0,27	0,42	0,42
BGE-M3 FAISS (L2)	0,90	0,71	0,91	0,92
FAISS + BM25 Hybrid (60/40 RRF)	0,89	0,71	0,88	0,90

Tablo 4.5, nihai değerlendirme setinde yer alan 33 RAG sorgusu üzerinde BM25, BGE-M3 + FAISS (L2) ve FAISS + BM25 (hibrit) bilgi getirme yöntemlerinin performanslarını karşılaştırmaktadır. Sonuçlar, BM25 yönteminin 0,35 P@5, 0,27 R@5, 0,42 MRR ve 0,42 nDCG@5 skorlarına ulaştığını göstermektedir. BGE-M3 + FAISS (L2) yöntemi; 0,90 P@5, 0,71 R@5, 0,91 MRR ve 0,92 nDCG@5 skorlarıyla değerlendirilen yöntemler arasında en iyi performansı sergilemiştir. Hibrit FAISS + BM25 yöntemi ise 0,89 P@5, 0,71 R@5, 0,88 MRR ve 0,90 nDCG@5 skorlarına ulaşmıştır. Bu sonuçlar, anlamsal vektör tabanlı bilgi getirmenin, test edilen veri setinde BM25 yönteminden daha iyi performans gösterdiğine işaret etmektedir. Bununla birlikte, FAISS ile hibrit yöntem arasındaki performans farkları sınırlı kalmıştır ve mevcut sonuçlar, yöntemlerden birinin diğerine karşı istatistiksel olarak anlamlı bir üstünlüğe sahip olduğunu ortaya koymak için tek başına yeterli değildir.

Tablo 4.6. Pilot Test Kümesinde RRF Ağırlıklarının Performansa Etkisi

FAISS / BM25	P@5	R@5	MRR	nDCG@5
50/50	0,80	0,59	0,84	0,84
60/40 (seçilen)	**0,81**	**0,59**	**0,84**	**0,84**
70/30	0,81	0,59	0,84	0,84

Tablo 4.6, pilot değerlendirme sırasında kullanılan 60/40 ve 70/30 ağırlıklandırma yapılandırmalarının, tüm performans göstergeleri açısından aynı sonuçları verdiğini göstermektedir. Her iki yapılandırmada da P@5 değeri 0,81, R@5 değeri 0,59, MRR değeri 0,84 ve nDCG@5 değeri 0,84 olarak gerçekleşmiştir.

Dolayısıyla, 60/40 yapılandırmasının diğer seçeneklere kıyasla önemli bir avantaj sağladığı söylenemez. Bu çalışmada, eşdeğer performans sergileyen seçenekler arasından 60/40 ağırlıklandırma, tercih edilen uygulama yapılandırması olarak seçilmiştir.

Tablo 4.7. RAG Yanıt Üretim Kalitesine İlişkin Otomatik Değerlendirme Sonuçları (n=33)

Değerlendirme ölçütü	Değer
Atıf doğruluğu	0,30
Atıf tamlığı	0,14
Desteksiz iddia oranı	0,86
Tercih edilen kaynağa isabet	0,68
Ortalama yanıt süresi (sn)	44,61
Medyan yanıt süresi (sn)	41,19
p95 yanıt süresi (sn)	60,79

Tablo 4.7, nihai değerlendirmeye dahil edilen 33 RAG sorgusuna ilişkin otomatik yanıt oluşturma metriklerini sunmaktadır. Alıntı hassasiyeti 0,30, alıntı eksiksizliği 0,14 ve desteklenmeyen iddiaların oranı ise 0,86 olarak gerçekleşmiştir. Bu sonuçlar, bilgi getirme aşamasında ilgili belgelerin mevcut olmasının, tek başına, oluşturulan yanıtların bilimsel kaynaklarla yeterince desteklendiğini garanti etmediğini göstermektedir. Ortalama yanıt süresi 44,61 saniye, medyan süre 41,19 saniye ve p95 değeri 60,79 saniye olmuştur. Söz konusu metrikler otomatik bir değerlendirmeye dayanmakta olup, alanında uzman bağımsız kişilerce yapılacak kapsamlı bir incelemenin yerini tutamaz.

Tablo 4.8. SQL ve HYBRID Kanallarının Uçtan Uca Değerlendirme Sonuçları

Değerlendirme ölçütü	SQL	H
Test edilen soru sayısı	24	16
Yönlendirme doğruluğu	1,00	1,00
Sayısal yanıt tutarlılığı	0,708 (17/24)	—
Uçtan uca başarı oranı	—	0,688 (11/16)

Tablo 4.8, SQL ve HYBRID kanallarına ilişkin değerlendirme sonuçlarını sunmaktadır. SQL kanalı için 24, HYBRID kanalı için ise 16 sorgu değerlendirilmiş olup, her iki kanal için de yönlendirme kesinliği (yönlendirme kesinliği) 1,00 olarak gerçekleşmiştir. Bununla birlikte, SQL kanalında sayısal yanıt tutarlılığı 17/24 (0,708; Wilson %95 GA 0,51–0,85) iken, HYBRID kanalında uçtan uca başarı oranı 11/16 (0,688; Wilson %95 GA 0,44–0,86)

olarak kaydedilmiştir. Bu sonuçlar, sorguların uygun işleme kanalına yönlendirilmesinin, nihai olarak üretilen yanıtların doğruluğunu her zaman garanti etmediğini göstermektedir. SQL ve HYBRID kanalları için kullanılan değerlendirme kriterleri birbirinden farklı olduğundan, bu iki başarı oranı doğrudan kıyaslanamaz. Genel olarak değerlendirme sonuçları, geliştirilen sistemin test kümesindeki sorguları ilgili işleme kanallarına doğru bir şekilde yönlendirebildiğini ve anlamsal bilgi erişim yöntemlerinin geleneksel BM25 yaklaşımından daha iyi performans gösterdiğini ortaya koymaktadır. Yine de, RAG yanıtları içindeki alıntıların düşük kesinliği ve hem SQL hem de HYBRID kanallarında nihai yanıtların tutarlılığına ilişkin sınırlamalar, başarılı bir yönlendirme ve bilgi erişiminin, güvenilir yanıtlar üretmek için tek başına yeterli olmadığını göstermektedir. Bu bulgular, sistemin iyileştirilmesi gereken alanların belirlenmesi açısından önem taşımaktadır.

4.4. RAG Destekli Sistemin Değerlendirilmesi

Geliştirilen chatbot'taki RAG altyapısının birincil işlevi, hayvancılıkla ilgili kullanıcı sorularını sistem içindeki bilimsel belgelerle ilişkilendirmek ve ilgili içeriği büyük dil modelinin yanıt oluşturma sürecine beslemektir. Uygulama, RAG hattına yönlendirilen sorguların doğrudan büyük dil modeline gönderilmek yerine önce hazırlanan bilimsel bilgi tabanına karşı kontrol edildiğini göstermiştir. Bu, ilgili metin parçalarının belirlenmesini ve yanıt oluşturmada kullanılmasını sağlar. RAG sisteminin bilgi alma aşamasında semantik ve leksik arama yöntemleri paralel olarak kullanılmıştır. Semantik arama, BGE-M3 gömme modeli ve bir FAISS vektör indeksi kullanılarak gerçekleştirilirken, leksik eşleşmeler BM25 algoritması kullanılarak belirlenmiştir. Her iki arama yönteminin sonuçları hibrit bir alma çerçevesinde birleştirilmiştir. Pilot değerlendirmede belirlenen ağırlıklı Reciprocal Rank Fusion (RRF) yapılandırmasında, anlamsal arama sonuçlarına 0,60 ve BM25 tabanlı sözcüksel arama sonuçlarına 0,40 ağırlık verilmiştir.

Bu uygulama, sistemin kullanıcı sorgularındaki basit sözcüksel eşleşmelerin ötesine geçen anlamsal ilişkileri yakalayarak içeriğin bilimsel uygunluğunu değerlendirebildiğini ortaya koymuştur. Ayrıca, BM25 bileşeninin entegrasyonu; özellikle hayvan hastalıkları, beslenme ve süt üretimi gibi alanlarda teknik terimlerin tam eşleşmelerinin bilgi getirme sürecine dahil edilmesini sağlamıştır. Sonuç olarak, bilgi getirme sürecinde hem anlamsal benzerliği hem de sözcüksel eşleşmeyi dikkate alan bir çerçeve

oluşturulmuştur. RAG bileşeninin pilot değerlendirmesi sırasında 50 RAG sorgusu kullanılmış ve bu sorguların uygun işleme kanalına yönlendirilmesinde %98'lik bir başarı oranına ulaşılmıştır. Nihai değerlendirmede ise 33 RAG sorgusunun tamamı doğru kanala yönlendirilmiştir. Bu sonuçlar, sistemin RAG sorgularını tanıma ve bunları uygun işleme yoluna yönlendirme konusundaki performansını göstermektedir. Bununla birlikte; yönlendirme başarısı, bilgi getirme kalitesi ve üretilen yanıtların bilimsel doğruluğu, değerlendirme açısından birbirinden farklı boyutları temsil etmektedir. Pilot değerlendirme sürecinde, RAG tabanlı sorgular için ortalama yanıt süresi 55,49 saniye olarak ölçülmüştür. Bu değer, aynı pilot değerlendirme kapsamında SQL ve HİBRİT (HYBRID) sorguları için kaydedilen ortalama yanıt sürelerinden daha yüksektir. RAG altyapısının bir diğer özelliği de, bir yanıt oluşturmak için kullanılan bilimsel içeriğin kaynak bilgilerine kadar izlenebilmesidir. Sistemde dosya adları ve sayfa numaraları gibi meta verilerin saklanması, alınan metin parçalarının kaynaklandığı belirli bilimsel belgelerin tanımlanmasına olanak tanır. Teknik mimari, API'nin metnin kendisiyle birlikte kaynak bilgilerini de döndürmesine olanak tanır. Bu yapı, yanıtların oluşturulmasında kullanılan bilimsel belgelerin izlenebilirliğini desteklemektedir. Bununla birlikte, kaynak bilgilerinin sistem tarafından sunulabilmesi, oluşturulan yanıtların ilgili kaynaklarla her zaman doğru biçimde ilişkilendirildiği anlamına gelmemektedir. RAG bileşeni yalnızca doğrudan bilimsel bilgi içeren sorgular için değil, aynı zamanda hibrit sorguların işlenmesi için de kullanılmıştır. Bu sorgular, PostgreSQL veri tabanında tutulan sentetik çiftlik kayıtlarını RAG sisteminden gelen bilimsel bilgilerle birleştirdi. Bir örnek uygulamada, belirli bir hayvanın süt üretimindeki düşüş önce veritabanı girdileri kullanılarak hesaplandı. Daha sonra mastitis ile süt üretimi arasındaki ilişkiye yönelik bilimsel içerik RAG sistemi aracılığıyla elde edilmiştir.Bu uygulama, sentetik çiftlik kayıtlarından elde edilen sayısal sonuçların bilimsel belgelerden erişilen bilgilerle birlikte değerlendirilebildiğini göstermiştir.

İlk testlerin ardından RAG bileşeninin bilgi erişimi ve yanıt üretimi süreçlerine yönelik iyileştirmeler gerçekleştirilmiştir. Nihai test kümesindeki

33 RAG sorusu üzerinden yapılan bilgi erişim değerlendirmesinde Precision@5, Recall@5, MRR ve nDCG@5 ölçütleri kullanılmıştır. Tablo 4.5'te sunulan sonuçlara göre BGE-M3 + FAISS (L2) yöntemi, P@5, MRR ve nDCG@5 ölçütlerinde en yüksek değerlere ulaşırken R@5 bakımından ağırlıklı RRF yöntemiyle aynı performansı göstermiştir. Hibrit RRF yöntemi BM25'e göre daha başarılı olmakla birlikte, bu test kümesinde yalnızca anlamsal aramaya dayalı yöntemin bir miktar gerisinde kalmıştır. Bununla birlikte, bilgi erişim başarısı ile nihai yanıtların bilimsel doğruluğu birbirinden farklı değerlendirme boyutlarıdır. Nitekim Tablo 4.7'de sunulan otomatik yanıt üretim değerlendirmesinde atıf doğruluğu 0,30, atıf tamlığı 0,14 ve desteksiz iddia oranı 0,86 olarak raporlanmıştır. Bu sonuçlar, ilgili bilimsel belgelere erişilmesinin kaynaklarla yeterince desteklenen yanıtlar oluşturulmasını tek başına garanti etmediğini göstermektedir.

5. SONUÇ VE ÖNERİLER

5.1. Bulguların Tartışılması

Ayrık final yönlendirme başarısı (89/89) soruların doğru işleme kanalına gitmesini ölçer; nihai kullanıcı yanıtının bilimsel veya sayısal doğruluğunu kanıtlamaz. Retrieval katmanında BGE-M3 tabanlı anlamsal erişim BM25'e göre belirgin üstünlük göstermiş; ağırlıklı RRF hibrit bu derlemede FAISS'in çok az gerisinde kalmıştır. FAISS ile hibrit arasındaki yaklaşık 0,01'lik P@5 farkı 33 soruluk örneklemde istatistiksel üstünlük kanıtı değildir.

Bu araştırma için geliştirilen yapay zekâ tabanlı sohbet robotunun performansı; sorgu yönlendirme, bilimsel bilgilere erişim ve nihai yanıtların oluşturulması gibi çeşitli kriterler temel alınarak değerlendirilmiştir. Elde edilen sonuçlar, sistemin farklı bilgi ihtiyaçlarını uygun işleme kanallarına yönlendirebildiğini ve bilimsel belgelerden ilgili içeriğe erişebildiğini göstermektedir. Ancak, sorguların doğru yönlendirilmesi ve ilgili belgelerin getirilmesi, kullanıcıya sunulan nihai yanıtların bilimsel veya sayısal doğruluğunu tek başına garanti etmemektedir.

Nihai yanıtların oluşturulmasına ilişkin değerlendirmeler, iyileştirilmesi gereken alanları ortaya koymuştur. RAG kanalında, otomatik olarak hesaplanan alıntı (atıf) doğruluğu 0,303 iken, desteklenmeyen iddiaların oranı 0,8636 olarak belirlenmiştir. Bu bulgular, bilimsel bilgilere erişimde elde edilen yüksek performansın, kaynaklarla göstermektedir. SQL kanalında 24 kıyaslama (benchmark) sorgusu çalıştırılabilmiş olsa da, bu sonuç dil modeli tarafından üretilen nihai yanıtların doğruluğunu yansıtmamaktadır. SQL kanalında değer ve varlık tutarlılığı 17/24 (0,708) iken, HYBRID uçtan uca oranı 11/16 (0,688) olarak gerçekleşmiştir. Bu gözlemler, sistemin farklı bileşenlerinin performansının bağımsız metrikler kullanılarak değerlendirilmesi gerektiğini ortaya koymaktadır. Çalışma kapsamında tanımlanan araştırma soruları, gerçekleştirilen deneysel değerlendirmeler aracılığıyla ele alınmıştır. İlk araştırma sorusu (RQ1), sistemin sorguları uygun işleme kanallarına yönlendirme becerisiyle ilgilidir. Nihai test kümesinde elde edilen 89/89'luk

başarı oranı ve buna karşılık gelen %95'lik Wilson güven aralığı (0,96–1,00), bu sorunun söz konusu küme kapsamında nicel olarak çözüme kavuşturulduğunu göstermektedir. İkinci araştırma sorusu (RQ2), BM25, BGE-M3 + FAISS ve ağırlıklı RRF yöntemlerinin bilgi getirme (information retrieval) performanslarını karşılaştırmayı amaçlamaktadır. Tablo 4.5'te sunulan sonuçlar bu karşılaştırmayı ortaya koymaktadır.

desteklene yanıtların doğruluğuna her zaman doğrudan yansımadığını
n

Üçüncü araştırma sorusu (RQ3) bağlamında, bir pilot test kümesi üzerinde farklı RRF ağırlıklandırmaları karşılaştırılmış; %60/%40 ve %70/%30 ağırlıklandırmalarının benzer performans sergilemesi üzerine %60/%40 yapılandırması tercih edilmiştir. Dolayısıyla, bu belirli ağırlıklandırmanın diğerlerinden her zaman daha üstün olduğu iddia edilmemektedir. Dördüncü araştırma sorusunda (RQ4), SQL kanalı içerisindeki değerlerin ve varlıkların uçtan uca tutarlılığı değerlendirilmiştir. Beşinci araştırma sorusunda (RQ5) ise RAG (Retrieval-Augmented Generation) ile oluşturulan yanıtlardaki alıntıların doğruluğu, desteklenmeyen iddiaların oranı ile atıf tamlığı ve tercih edilen kaynağa isabet incelenmiştir. Bununla birlikte, otomatik değerlendirme sonuçları, bağımsız alan uzmanları tarafından gerçekleştirilecek kapsamlı bir değerlendirmenin yerini tutamaz.

Bu çalışmada geliştirilen yapay zekâ tabanlı sohbet robotunun temel katkısı, süt hayvancılığına ilişkin bilimsel bilgi kaynaklarını ve yapılandırılmış tarımsal verileri, doğal dille etkileşim kurulan tek bir ortamda bir araya getirebilmesidir. Sistemin SQL, RAG, HYBRID (hibrit) ve CHAT olmak üzere dört işleme kanalı, kullanıcı sorgularını içeriklerine ve kökenlerine göre değerlendirir. Bu mimari, yalnızca tarımsal verileri sorgulamakla kalmayıp, aynı zamanda ilgili belgelerden elde edilen bilimsel açıklamalar gerektiren soruları da yanıtlamak üzere tasarlanmıştır. HYBRID kanalının hem tarımsal verilerden hem de bilimsel içeriklerden eş zamanlı olarak yararlanabilme kapasitesi, geliştirilen prototipin bütünleşik yapısını öne çıkarmaktadır. Ancak, bu mimari entegrasyonun başarısı, üretilen her bir yanıtın bilimsel veya sayısal açıdan güvenilir olduğunu garanti etmez. Dolayısıyla, mevcut değerlendirme sonuçlarına göre sistemin katkısı; farklı bilgi kaynaklarını birleşik bir

sorgulama çerçevesinde bir araya getiren ve gelecekteki geliştirmelere açık olan bir prototipin oluşturulması olarak değerlendirilmelidir. Sistemin dikkat çekici bir özelliği, hem sentetik tarımsal verileri hem de bilimsel bilgi kaynaklarını eş zamanlı olarak işleyebilmesidir. HYBRID yaklaşımı sayesinde, bir hayvanın süt verimindeki değişimler gibi sayısal veriler ilişkisel bir veritabanından çekilebilirken, bu değişimlerin olası nedenlerine dair sağlanabilmektedir. Bu durum, farklı yapılara sahip bilgi kaynaklarının tek bir kullanıcı sorgusu içinde kullanılabilmesine olanak tanır. Bununla birlikte, HYBRID kanalının 11/16 (0,688) uçtan uca oranı, başarısız beş soruda tercih edilen belgenin retrieval listesine girmemesinden kaynaklanır; bu oran sentez doğruluğu değil, kaynak seçimi ölçüsüdür. Bu bulgu, bütünleşik sistem mimarisinin sağladığı işlevsel katkının ötesinde, nihai yanıtların doğrulanması için ek mekanizmalara ihtiyaç duyulduğunu ortaya koymaktadır.

açıklamala RAG altyapısı aracılığıyla erişilen bilimsel belgelerden
r

Pilot ve nihai değerlendirme aşamalarında sorgu yönlendirme performansının analiz edilmesi, sistemin farklı soru türlerini birbirinden ayırt etme becerisinin değerlendirilmesini mümkün kılmıştır. 100 sorudan oluşan pilot test kümesinde yönlendirme doğruluğu %97'ye ulaşırken, 89 sorudan oluşan nihai test kümesinde bu oran %100 olarak gerçekleşmiştir. Pilot kümede SQL yönlendirmesi 30 sorunun 28'inde doğrudur; hatasız yönlendirme final kümeye aittir (89/89). İki kümenin soru dağılımı farklı olduğu için yüzde 97'den yüzde 100'e geçiş, üç puanlık bir iyileşmenin kanıtı sayılmamalıdır. Ayrıca, nihai test kümesindeki yüksek yönlendirme başarı oranı, sistemin daha çeşitli ve farklı kullanıcı sorguları karşısında da benzer bir performans sergileyeceğini garanti etmez.

Pilot değerlendirme sonuçları, sistem yanıt sürelerinin işleme kanallarına göre önemli ölçüde farklılık gösterdiğini ortaya koymaktadır. SQL sorguları için ortalama yanıt süresi 6,91 saniye iken, bu süre HYBRID (hibrit) sorgular için 39,18 saniye, RAG sorguları için ise 55,49 saniyedir. Pilot test kümesi genelindeki ortalama yanıt süresi ise 37,66 saniyedir. RAG ve HYBRID kanallarında gözlemlenen daha uzun yanıt süreleri; bu kanalların, bilimsel belgelerden bilgi edinme ve dil modelleri kullanarak yanıt oluşturma gibi ek

işlem adımlarını içermesiyle açıklanabilir. Bununla birlikte, söz konusu ölçümler pilot değerlendirmeye ait olduğundan, sistemin nihai çalışma koşullarındaki yanıt sürelerini doğrudan yansıtmamaktadır. SQL kanalıyla yapılan değerlendirmeler sırasında, veritabanından elde edilen sayısal sonuçların doğal dile dönüştürülmesi aşamasında hatalar gözlemlenmiştir. Bu durum, yapısal verilerin doğru bir şekilde sorgulanmasının, güvenilir kullanıcı yanıtları oluşturmak için tek başına yeterli olmadığını göstermektedir. Sık tekrarlanan sorgular için parametreli SQL yapılarının kullanılması, veritabanı işlemlerinin daha kontrollü bir şekilde yürütülmesine katkı sağlayabilecek bir yaklaşım olarak belirlenmiştir. Yine de, nihai yanıtların güvenilirliğini artırmak için sayısal değerler ile bunların doğal dildeki karşılıkları arasındaki tutarlılığı doğrulayan mekanizmalara da ihtiyaç duyulmaktadır. RAG bileşenine ilişkin bilgi edinme sonuçları, anlamsal (semantik) arama yöntemlerinin, bilgi edinme sürecine önemli ölçüde katkıda bulunabileceğini göstermektedir.

Retrieval katmanı ile üretim katmanı aynı başarıyı ölçmez. FAISS P@5 0,90 ve nDCG@5 0,92 iken atıf doğruluğu 0,303 ve cümle düzeyinde atıf tamlığı 0,1364'tür. Darboğaz, belgenin bulunması değil, bulunan belgenin kısa Türkçe yanıtta kaynak kimliğiyle birlikte kullanılmasıdır. Yedi milyar parametreli model, 160 token çıktı sınırı ve atıf zorunluluğu bu açığın olası teknik nedenleridir. Held-out üretim sayıları bu 160/2048 yapılandırmasına aittir. Sohbet yolunda üretim penceresi 400 tokene, bağlam 4096 tokene çıkarılmıştır; kesilmiş İngilizce kuyruk ve kaynakça parçaları yanıtta bırakılmaz. 33 soruluk üretim metrikleri bu yeni pencerede yeniden ölçülmemiştir. Bu nedenlerden hiçbiri ayrı bir ablasyonla sınanmamıştır. Lewis ve arkadaşlarının (2020) RAG çerçevesi, dış bağlamın üretimi koşullamasını amaçlar. Bu tezde bağlam getirilmiş, ancak cümlelerin büyük bölümü [K] kimliği taşımamıştır. Gao ve arkadaşlarının (2024) Text-to-SQL değerlendirmesi modelin yazdığı sorgunun çalıştırılmasını ölçer. Bu tezde ölçülen 24/24 oranı o ölçüt değildir.

Bölüm 4.1'deki ekran görüntüleri de bu açığın nitel örnekleridir. Aşağıdaki tablo, şekillerde doğrudan gözlenebilen tutarsızlıkları ve ilgili nicel bulguyu eşleştirir.

Şekil	Gözlenen tutarsızlık	İlgili bulgu / hata türü
Şekil 4.1 – SQL	En yüksek 10 inek istenmiş 5 inek listelenmiş; yanıt yine de 10 inekten söz ediyor. Birim kg; veri tabanı litre.	Sayısal sözelleştirme hatası; birim tutarsızlı (Tablo 4.8 SQL tutarlılığı).
Şekil 4.2 – HYBRID	Yanıtta İspanyolca sözcükler; aynı inek için hem %10 artış hem %5 düşüş; Serap için %15 düşüş yazılmış, alarm kaydı %39,06.	Dil karışması ve iç çelişk HYBRID sentez doğrulu ölçülmemiştir.
Şekil 4.3 – Panel	'Son 10 günlük üretim' etiketi; grafik 7 günü (30.08–05.09) gösteriyor.	Arayüz etiketi veri aralığıy uyumsuz; veri tabanı yalnızca gün içerir.
Şekil 4.4 – ABC analizi	Küpe numaralarında TRTR öneki tekrarı; Serap	Arayüz biçimlendirme hatası;
	için %43 dalgala alarmda %39,06.	'dalgalan ile 'düşüş yüzdesi' farklı tanımlardır, metinde ayrıştırılmalıdır.

Tablo 5.1. Şekil 4.1–4.4'te gözlenen tutarsızlıklar ve ilgili nicel bulgular.

HYBRID oranı, bilimsel açıklama ile çiftlik sayısının tutarlı biçimde birleştirildiğini göstermez. Başarısız beş sorunun ortak özelliği tercih edilen belgenin seçilmemesidir. Bu yüzden Bölüm 5'teki yorum, sentez hatasından çok kaynak seçimi hatasına bağlanmalıdır. Beş inek ve 50 sağım kaydı, SQL tutarlılığının işletme ölçeğinde geçerli olduğunu göstermez.

5.2. Araştırmanın Sınırlılıkları

Üretim katmanında aynı 33 sorunun yalnız model ile, retrieval olmadan ölçülmemesi bu çalışmanın başlıca açık deneyidir. Otomatik atıf metrikleri bir hakem modelin anlamsal kararı değil, [K] kimliği ve cümle örüntüsü kuralıdır. İnsan puanı tek araştırmacıya aittir. Sentetik veri tabanı bir çiftlik, beş inek ve 50 sağım kaydından ibarettir. Yönlendirme kuralları final soru metinlerinden bağımsız dondurulduğuna dair ayrı bir tarih kaydı yoktur.

Bu araştırmanın temel kısıtlamalarından biri, sistemin geliştirilmesi ve değerlendirilmesinde kullanılan tarımsal verilerin gerçek bir ticari süt çiftliğinden elde edilmemiş olmasıdır. Bunun yerine veriler, prototipin işlevselliğini test etmek amacıyla yapay olarak oluşturulmuştur. Dolayısıyla, elde edilen sonuçların gerçek çiftliklerdeki veri çeşitliliğini, operasyonel koşulları veya kullanıcı ihtiyaçlarını tam olarak yansıttığı iddia edilemez.

Bir diğer kısıtlama ise deneysel değerlendirmelerin belirli boyutlardaki test değerlendirmesinde 89 soru, bilgi getirme (RAG) tabanlı değerlendirmede ise 33 soru kullanılmıştır. Bu test kümeleriyle elde edilen yüksek başarı oranları, farklı kullanıcı profilleri veya daha geniş bir soru yelpazesiyle karşılaşıldığında benzer bir performansın sergileneceğini garanti etmez.

kümeleriyle gerçekleştirilmiş olmasıdır: Yönlendirme bileşeninin nihai

Ayrıca, RAG tarafından üretilen yanıtların doğruluk ve güvenilirliğini değerlendirmek için otomatik ölçütlerden yararlanılmıştır. Bu ölçütler, sistemin iyileştirilmesi gereken alanların belirlenmesinde faydalı olsa da, bağımsız sektör uzmanları tarafından yapılacak kapsamlı ve bilimsel bir doğrulamanın yerini tutamaz. SQL ve HYBRID kanallarına ilişkin uçtan uca değerlendirme sonuçları da, kullanılan özel test soruları ve değerlendirme yöntemleri göz önünde bulundurularak yorumlanmalıdır. Son olarak bu çalışma, yalnızca büyük bir dil modeline dayanan bir sistem ile RAG tabanlı bir sistemin ürettiği nihai yanıtların kalitesini doğrudan karşılaştırmamıştır. Bu durum, RAG mimarisinin, diğer sistemlere kıyasla nihai yanıtın doğruluğuna ne ölçüde katkıda bulunduğunun belirlenmesini kısıtlamaktadır. Veteriner hekim kör

puanlaması 15 maddeyi kapsar; 33 RAG yanıtının tamamı bu formda puanlanmamıştır.

5.3. Sonuç ve Öneriler

Bu araştırma, doğal dil aracılığıyla bilimsel bilgi kaynaklarına ve süt çiftliklerinden elde edilen yapılandırılmış verilere erişim sağlayan, yapay zekâ tabanlı bir sohbet robotu (chatbot) geliştirmektedir. LangChain ve RAG (Retrieval-Augmented Generation, RAG) teknolojilerinden yararlanan sistem; SQL, RAG, HYBRID (hibrit) ve CHAT işleme kanallarını birleşik bir mimaride bütünleştirir. Ortaya çıkan prototip, çeşitli bilgi ihtiyaçlarına yönelik sorguları tek bir kullanıcı arayüzü üzerinden karşılayabilmektedir. Deneysel değerlendirmeler, sistemin sorguları test kümesi içindeki uygun işleme kanallarına etkili bir şekilde yönlendirdiğini ve BGE-M3 tabanlı anlamsal bilgi erişim yaklaşımının BM25 yönteminden daha iyi performans gösterdiğini ortaya koymaktadır. Bununla birlikte, özellikle RAG tarafından üretilen yanıtların kaynak materyallere dayandırılması (grounding) ve SQL ile HYBRID kanallarındaki nihai çıktıların tutarlılığının sağlanması konularında iyileştirme alanları tespit edilmiştir. Sonuç olarak bu araştırmanın temel katkısı, söz konusu entegre mimarinin uygulanabilirliğini göstermekle birlikte, nihai yanıtların güvenilirliğini artırma gerekliliğine dikkat çekmesidir. Sistemin gerçek süt çiftliklerinden elde edilen verilerle değerlendirilmesi için ileri çalışmalar önerilmektedir. Geliştirilen yaklaşımın, farklı ölçeklerdeki işletmelerden alınan veriler ve gerçek kullanıcı sorguları kullanılarak gerçek dünya koşullarında test edilmesi, sistemin genel etkinliğinin belirlenmesine yardımcı olacaktır. Ayrıca, sorgu yönlendirme, bilgi erişimi ve nihai yanıtların doğruluğunun daha büyük ve bağımsız test kümeleri kullanılarak yeniden değerlendirilmesi büyük önem taşımaktadır. RAG bileşeninin geliştirilmesinde; çeşitli gömme (embedding) modellerinin, bilgi erişim yöntemlerinin ve büyük dil modellerinin karşılaştırılması önerilir. Özellikle, yalnızca büyük dil modeline dayanan bir temel sistem ile RAG yöntemini içeren bir sistemin aynı soru kümesi üzerinde karşılaştırılması, bilgi erişiminin nihai yanıtların kalitesine olan katkısının daha net bir şekilde belirlenmesini sağlayacaktır. Buna ek olarak, geliştirme ekibinden bağımsız alan uzmanlarının; alıntıların doğruluğunu, yanıtların sağlanan kaynaklara ne ölçüde dayandığını ve

değerlendirmesi, sistemin güvenilirliğini ölçmek açısından kritik öneme sahiptir. SQL ve HYBRID kanalları için ise, veritabanından alınan sayısal değerlerin nihai yanıtlarla tutarlı olmasını sağlayacak doğrulama mekanizmalarının geliştirilmesi önerilmektedir. Parametreli SQL sorgularının kullanımını artırmak ve çeşitli kaynaklardan elde edilen bilgileri sentezlerken tutarlılık kontrolleri uygulamak, veriye dayalı yanıtların güvenilirliğini güçlendirebilir. Sistemin iyileştirilmesi gereken bir diğer yönü ise yanıt süresidir.

bilimsel yanıtlarda desteklenmeyen iddiaların bulunup bulunmadığını

Çalışmanın savunulabilir katkısı, süt sığırcılığı için SQL, RAG, HYBRID ve CHAT kanallarını tek yönlendiricide birleştiren prototip ile bu prototipin katman katman ölçülmesidir. Ölçüm, yönlendirmenin güçlü, retrieval'ın belge düzeyinde güçlü, üretimin ise atıf bakımından zayıf olduğunu gösterir. Katkı, sahada güvenilir bilimsel yanıt üretildiğinin iddiası değil, bu güvenilirlik açığının sayısal olarak ayrıştırılmasıdır.

Gelecekteki araştırmalar; özellikle RAG (Retrieval-Augmented Generation, RAG) ve hibrit kanallar için bilgi erişimi ile yanıt oluşturma süreçlerinin optimize edilmesine, ayrıca farklı model boyutlarının değerlendirilmesine ve uygun donanım yapılandırmalarının kullanılmasına odaklanabilir. Buna ek olarak, sistem tarafından sağlanan bilgilerin güncelliğini korumak adına, bilimsel bilgi tabanının yeni yayınlar ve en güncel teknik önerilerle düzenli olarak güncellenmesi büyük önem taşır. Sonuç olarak bu çalışma, bilimsel bilgilere erişim imkânını, süt hayvancılığına ilişkin operasyonel verilerin doğal dil kullanılarak sorgulanabilmesi yeteneğiyle birleştiren, yapay zekâ tabanlı bir prototip sunmaktadır. Elde edilen sonuçlar, geliştirilen mimarinin bu araştırma kapsamında tanımlanan işlevleri yerine getirebildiğini göstermektedir. Bununla birlikte, sistemin gerçek operasyonel ortamlardaki kullanılabilirliği ve sunduğu nihai yanıtların güvenilirliği, daha kapsamlı deneysel çalışmalarla ayrıca doğrulanmalıdır.

KAYNAKLAR

Abdallah, A. K., Alkaabi, A. M., Mehiar, D. A. F., & Aradat, Z. A. J. (2024). *Chatbots in classrooms* (pp. 166–181). IGI Global.

Adenekan, O., Solomon, N., Simpa, P., & Obasi, S. (2024). Enhancing manufacturing productivity: A review of AI-driven supply chain management optimization and ERP systems integration. *International Journal of Management & Entrepreneurship Research, 6*(5), 1607–16

Ahmed, F., Ahmed, M. R., Kabir, M. A., & Islam, M. M. (2025). Revolutionizing business analytics: The impact of artificial intelligence and machine learning. *American Journal of Advanced Technology and Engineering Solutions, 1*(1), 147–173.

Akter, S., Uddin, M. R., Sajib, S., Lee, W. J. T., Michael, K., & Hossain, M. A. (2022). Reconceptualizing cybersecurity awareness capability in the data-driven digital economy. *Annals of Operations Research, 24*(10), 673–698.

Almanasra, S. (2024). Applications of integrating artificial intelligence and big data: A comprehensiv analysis. *Journal of Intelligent Systems, 33*(1).

Ansari, M. F., Dash, B., Sharma, P., & Yathiraju, N. (2022). The impact and limitations of artificial intelligence in cybersecurity: A literature review. *IJARCCE, 11*(9).

Arif, M., Rabby, H., Nadia, N., Tanvir, M., & Masum, A. (2025). AI-driven risk assessment in national security projects: Investigating machine learning models to predict and mitigate risks in defense and critical infrastructure projects. *Journal of Computer Science and Technology Studies, 7*(2), 71–85.

Arthana, I. K. R., Dewi, N. P. N. P., Saskara, G. A. J., Pradnyana, I. M. A., & Indrayani, L. (2026). Real-time intelligent virtual assistant based on

retrieval augmented generation. *IAES International Journal of Artificial Intelligence (IJ-AI), 15*(1), 237.

Asolo, E., Gil-Ozoudeh, I., & Ejimuda, C. (2024). AI-powered decision support systems for sustainable agriculture using AI-chatbot solution. *Journal of Digital Food, Energy & Water Systems, 5*(1).

Sindhu, B., Prathamesh, R. P., Sameera, M. B. ve Kumaraswamy, S. (2024). The evolution of large language model: Models, applications and challenges (Vol. 32, pp. 1–8) https://doi.org/10.1109/icctac61556.2024.10581180

Barrios-González, M., Aguiar-Pérez, J. M., Pérez-Juárez, M. Á., & Castañeda-De-Benito, E. (2026). Redefining cyber threat intelligence with artificial intelligence: From data processing to predictive insights and human–AI collaboration. *Applied Sciences, 16*(3), 1668

Borah, B., Pathak, D., Sarmah, P., Som, B., & Nandi, S. (2019). *Survey of textbased chatbot in perspective of recent technologies* (pp. 84–96). Springer Singapore.

Bretas, I. L., Dubeux, J. C. B., Cruz, P. J. R., Oduor, K. T., Queiroz, L. D., Valente, D. S. M., & Chizzotti, F. H. M. (2023). Precision livestock farming applied to grazingland monitoring and management—A review. *Agronomy Journal, 116*(3), 1164–1186.

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., … Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, *33*, 1877–1901.

Chen, G., Fan, J. ve Azam, M. (2024a). Exploring artificial intelligence (AI) chatbots adoption among research scholars using unified theory of

acceptance and use of technology (UTAUT). Journal of Librarianship and Information Science, 57(4), 1205–1223. https://doi.org/10.1177/09610006241269189

Chen, H., Rodríguez Méndez, S. J., & Omran, P. G. (2025). *Open local knowledge graph construction from academic papers using generative large language models* (pp. 2551–2559).

Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D. ve Liu, Z. (2024b). BGE M3-embedding: Multi-lingual, multi-functionality, multi-granularity text embe through self-knowledge distillation. arXiv preprint arXiv:2402.03216. https://doi.org/10.48550/arXiv.2402.03216

Cheng, M., Luo, Y., Ouyang, J., Liu, Q., Liu, H., Li, L., Yu, S., Zhang, B., Cao, J., Ma, J., Wang, D., & Chen, E. (2025). A survey on knowledge-oriented retrieval-augmented generation. *arXiv*.

Clement David-Olawade, A., Ogunbona, M. A., Olawuyi, O. F., Makanjuola, B. D., Alabi, J. O., & Olawade, D. B. (2026). Artificial intelligence and machine learning applications in dialysis: Current applications, challenges, and future directions. *Clinica Chimica Acta, 586,* 120908

Condotta, I. C. F. S., & Tedeschi, L. O. (2026). ASAS-NANP symposium: Mathematical modeling in animal nutrition: Revolutionizing animal farming with artificial intelligence: Trends, challenges, and opportunities. *Journal of Animal Science, 104*.

Dara, R., Hazrati Fard, S. M., & Kaur, J. (2022). Recommendations for ethical and responsible use of artificial intelligence in digital agriculture. *Frontiers in Artificial Intelligence, 5*, 884192.

Dolianiti, F., Tsoupouroglou, I., Antoniou, P., Konstantinidis, S., Anastasiades, S., & Bamidis, P. (2020). *Chatbots in healthcare curricula: The case of a conversational virtual patient* (pp. 137–147). Springer.

Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2024). RAGAS: Automated evaluation of retrieval augmented generation. In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations* (pp. 150–158). Association for Computational Linguistics.

Gan, A., Yu, H., Zhang, K., Liu, Q., Yan, W., Huang, Z., Tong, S., & Hu, G. (2025). Retrieval augmented generation evaluation in the era of large language models: A comprehensive survey. *arXiv*.

Gao, D., Wang, H., Li, Y., Sun, X., Qian, Y., Ding, B., & Zhou, J. (2024). Text-to-SQL empowered by large language models: A benchmark evaluation. *Proceedings of the VLDB Endowment, 17*(5), 1132–1145.

Ghazo, A. T. A., & Salah, M. (2026). Artificial intelligence in modern mechatronic systems: Technologies, applications, and future research directions. *Systems Science & Control Engineering, 14*(1)

Gu, J. (2025). A research of challenges and solutions in retrieval augmented generation (RAG) systems. *Highlights in Science, Engineering and Technology, 124*, 132–138.

Gülmez, B. (2026). Artificial intelligence-driven smart grid optimization: A comprehensive review of machine learning, renewable integration, and cybersecurity applications. *Energy Conversion and Management: X, 30*, 101849.

Guo, H., Zhu, J., Di, S., Shi, W., Chen, Z., & Xu, J. (2025). *DioR: Adaptive cognitive detection and contextual retrieval optimization for dynamic retrieval-augmented generation* (pp. 2953–2975).

Gupta, S. (2025). Retrieval-augmented generation and hallucination in large language models: A scholarly overview. *Scholars Journal of Engineering and Technology, 13*(5), 328–330.

Iqbal, H. R., Sharjeel, M., Shafi, J., Mehmood, U., & Raza, A. A. (2025). Urdu sentential paraphrased plagiarism detection using large language models. *ACM Transactions on Asian and Low-Resource Language Information Processing, 24*(9), 1–20.

Ji, X., Xu, L., Gu, L., Ma, J., Zhang, Z., & Jiang, W. (2025). RAP-RAG: A retrieval-augmented generation framework with adaptive retrieval task planning.

Electronics, 14(21), 4269.

Jiang, A. Q., Sablayrolles, A., Mensch, A., Bamford, C., Chaplot, D. S., de las Casas, D., Bressand, F., Lengyel, G., Lample, G., Saulnier, L., Lavaud, L. R., Lachaux, M.-A., Stock, P., Scao, T. L., Lavril, T., Wang, T., Lacroix, T., & El Sayed, W.

(2023). *Mistral 7B*. arXiv.

Johnson, J., Douze, M., & Jégou, H. (2019). Billion-scale similarity search with GPUs.

IEEE Transactions on Big Data, 7(3), 535–547.

Jokar, M., Abdous, A., & Rahmanian, V. (2024). AI chatbots in pet health care: Opportunities and challenges for owners. *Veterinary Medicine and Science, 10*(3), e1464.

Kate, M., & Neethirajan, S. (2025). Decoding bovine communication with AI and multimodal systems: Advancing sustainable livestock management and precision agriculture. *bioRxiv*.

Kim, S., Zhou, Y., Guo, Y., Xiao, C., & Zheng, K. (2026). Applying natural language processing and large language models to clinical notes for phenotyping and diagnosing rare diseases: A systematic review. *Journal of the American Medical*

Informatics Association, 33(6), 1225–1235

Kiran, S. (2025). Hybrid retrieval-augmented generation (RAG) systems with embedding vector databases. *International Journal of Scientific Research in Computer Science, Engineering and Information Technology, 11*(2), 2694–2702.

Kleebayoon, A., & Wiwanitkit, V. (2024). AI chatbots in pet health care: Comment. *Veterinary Medicine and Science, 10*(4), e1512

Kleen, J. L., & Guatteo, R. (2023). Precision livestock farming: What does it contain and what are the perspectives? *Animals, 13*(5), 779

Kneese, T., Vecchione, B., & Marwick, A. (2025). A chatbot for the soul: Mental health care, privacy, and intimacy in AI-based conversational agents. *Communication and Change, 1*(1).

Kuli, B., Debnath, J., Sheikh, A., Das, S., & Balai, P. (2025). Smart farming revolution: AI, IoT, and robotics in precision agriculture and soil conservation. *International Journal of Scientific Research in Science, Engineering and Technology*, *12*(2), 688–706.

Le, X. C. (2023). Inducing AI-powered chatbot use for customer purchase: The role of information value and innovative technology. *Journal of Systems and Information Technology*, *25*(2), 219–241.

Lee, H., Handler, R., Mungle, T., & Hernandez-Boussard, T. (2026). Building safer artificial intelligence mental health chatbots: A framework for transparency, evaluation, and shared accountability. *Journal of the American Medical Informatics Association, 33*(8).

Lee, Y. (2024). Development of open large language models for artificial intelligence digital textbooks. *TEM Journal*, 2773–2783.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems, 33*, 9459–9474.

Li, S., Stenzel, L., Eickhoff, C., & Bahrainian, S. (2025). Enhancing retrieval-augmented generation: A study of best practices. *arXiv*.

Lin, Y., & Yu, Z. (2023). A bibliometric analysis of artificial intelligence chatbots in educational contexts. *Interactive Technology and Smart Education, 21*(2), 189–213.

Linkon, A., Shaima, M., Sarker, M., Badruddowza, B., Nabi, N., Rana, M., Ghosh, S., Esa, H., & Chowdhury, F. (2024). Advancements and applications of generative artificial intelligence and large language models on business management: A comprehensive review. *Journal of Computer Science and Technology Studies, 6*(1), 225–232.

Liu, C.-L., Ho, C.-T., & Wu, T.-C. (2026). Toward tailored implementation of an artificial intelligence-based healthy dietary chatbot: Differences in technology acceptance pathways by health consciousness and user characteristics. *BMC Medical Informatics and Decision Making*.

Liu, N., Qi, J., An, X., & Wang, Y. (2023). A review on information technologies applicable to precision dairy farming: Focus on behavior, health monitoring, and the precise feeding of dairy cows. *Agriculture, 13*(10), 1858.

Mankari, S., & Sanghavi, A. (2024). *Enhancing vector based retrieval augmented generation with contextual knowledge graph construction* (pp. 1–6).

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.

Melak, A., Aseged, T., & Shitaw, T. (2024). The influence of artificial intelligence technology on the management of livestock farms. *International Journal of Distributed Sensor Networks, 2024*, 1–12

Meshram, S., Naik, N., Vr, M., More, T., & Kharche, S. (2021). *Conversational AI: Chatbots* (pp. 1–6).

Natsir, M. H., Mahmudy, W. F., Tono, M., & Nuningtyas, Y. F. (2025). Advancements in artificial intelligence and machine learning for poultry

farming: Applications, challenges, and future prospects. *Smart Agricultural Technology, 12*, 101307.

Neethirajan, S. (2025). Safeguarding digital livestock farming—A comprehensive cybersecurity roadmap for dairy and poultry industries. *Frontiers in Big Data, 8*, 1556157.

Nugroho, S. A., Sumaryanto, S., & Hadi, A. P. (2024). Enhancing cybersecurity with AI algorithms and big data analytics: Challenges and solutions. *Journal of Technology Informatics and Engineering, 3*(3), 279–295.

Oche, A., Folashade, A., Ghosal, T., & Biswas, A. (2025). A systematic review of key retrieval-augmented generation (RAG) systems: Progress, gaps, and future directions. *arXiv*.

Ong, W., Zhu, L., Zhang, W., Kuah, T., Lim, D. S. W., Low, X. Z., Thian, Y. L., Teo, E. C., Tan, J. H., Kumar, N., Vellayappan, B. A., Ooi, B. C., Quek, S. T., Makmur, A., & Hallinan, J. T. P. D. (2022). Application of artificial intelligence methods for imaging of spinal metastasis. *Cancers, 14*(16), 4025.

Ozella, L., Magliola, A., Vernengo, S., Ghigo, M., Bartoli, F., Grangetto, M., Forte, C., Montrucchio, G., & Giacobini, M. (2024). A computer vision approach for the automatic detection of social interactions of dairy cows in automatic milking systems. *Acta IMEKO, 13*(3), 1–6

Pan, T., & Su, Y. (2026). A generative AI-enhanced intelligent service system with contextual retrieval and adaptive interaction for hospital use. *Scientific Reports, 16*(1).

Pletsch, A. L. B., Stenger, E. A. F., & Sehnem, S. (2024). The potential of Industry 4.0 technologies in transforming agricultural and livestock

practices: A systematic review. *International Journal of Pervasive Computing and Communications, 21*(2), 121–155.

Krishnamoorthy, R. ve Manojkumar, C. (2024). IoT-based robotic systems integrating artificial intelligence for sustainable crop protection in agriculture. PatternIQ Mining.
https://doi.org/10.70023/piqm24301

Ramana, P., Mohanty, D., Ngullie, D., Rajeswari, D., Abinaya, D., Sharma, S., & Sunalini, K. (2024). Exploring AI-powered chatbots in English language learning: A study on effectiveness, user experience, and future directions.

Nanotechnology Perceptions, 2168–2175. https://doi.org/10.62441/

Ramdurai, B. (2025). A review of large language models (LLMs), retrieval-augmented generation (RAG) systems, and convolutional neural networks (CNNs) in application systems (pp. 135–154). BP.

Rebez, E. B., Sejian, V., Silpa, M. V., Kalaignazhal, G., Thirunavukkarasu, D., Devaraj, C., Nikhil, K. T., Ninan, J., Sahoo, A., Lacetera, N., & Dunshea, F. R. (2024). Applications of artificial intelligence for heat stress management in ruminant livestock. *Sensors, 24*(18), 5890.

Robertson, S., & Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval, 3*(4), 333–389.

Rosati, A. (2026). Rethinking livestock farming for artificial intelligence integration. *Animal Frontiers, 16*(2), 7–13.

Saha, S., Ali, M. S., Tengli, A. K., Prasad, S. R., Mallikarjunaswamy, P., Pillappan, R., & Javarappa, K. K. (2026). Navigating AI and machine learning in cancer research: An end-to-end translational framework. *Journal of Translational Medicine, 24*(1).

Shahade, A. K., & Deshmukh, P. V. (2024). *Enhancing natural language processing: A comprehensive review of retrieval augmented generation* (pp. 609–611).

Singh, A. (2024). *AI-driven innovations for enabling a circular economy* (pp. 47–64).
IGI Global.
Siva Kiran, R. R., & Dhamodhar, P. (2025). The role of artificial intelligence and machine learning in advancing animal biotechnology: A review. *Archives of Razi Institute, 80*(4), 819–832.
Smart solutions for livestock management and health monitoring. (2026). *Pakistan Veterinary Journal*.
Song, Y., Li, J., Chi, D., Xu, Z., Liu, J., Chen, M., & Wang, Z. (2025). AI-driven advances in metal-organic frameworks: From data to design and applications.
Chemical Communications, 61(82), 15972–16001.
Stonebraker, M., & Rowe, L. A. (1986). The design of POSTGRES. In *Proceedings of the 1986 ACM SIGMOD International Conference on Management of Data*
(pp. 340–355). Association for Computing Machinery.
Su, W., Ai, Q., Zhan, J., Dong, Q., & Liu, Y. (2025). *Dynamic and parametric retrieval- generation* (pp. 4118–4121)
Sztandarski, P., Marchewka, J., Jaszczyk, A., Solka, M., Michnowska, H., Pogorzelski, G., Gotxi, J. R., Damaziak, K., Wójcik, W., Siwiec, D., Seidavi, A., & Horbańczuk, J. O. (2025). Scientific literature on AI technologies to enhance animal welfare, health and productivity. *Animal Science Papers and Reports, 43*(2), 115–132.
Tanyildiz, D., Ayvaz, S., & Amasyali, M. F. (2024). Enhancing retrieval-augmented generation accuracy with dynamic chunking and optimized vector search. *Orclever Proceedings of Research and Development, 5*(1), 215–225.

Tedeschi, L. O., Guarnido-Lopez, P., Menendez, H. M., III, & Seo, S. (2025). Advancing precision livestock farming: Integrating artificial intelligence and emerging technologies for sustainable livestock management. *Animal Bioscience, 39*(4), 250289.

Usuyama, N., Wong, C., Zhang, S., Naumann, T., & Poon, H. (2025). Biomedical natural language processing in the era of large language models. *Annual Review of Biomedical Data Science, 8*(1), 471–490.

Vitale, J., Tedeschi, L., Strong, R., Rodriguez Lopez, C. M., Peterson, M., Murray, S., Mcreynolds, E., Gentimis, T., Ferreyra, A., Bhandari, M., Ampatzidis, Y., & Ye, X. (2025). *AI in agriculture: Opportunities, challenges, and recommendations*.

Council for Agricultural Science Technology.

Wang, S., Jiang, H., Qiao, Y., Jiang, S., Lin, H., & Sun, Q. (2022). The research progress of vision-based artificial intelligence in smart pig farming. *Sensors, 22*(17), 6541.

Warbhe, M. K., Verma, P., & Rewatkar, R. (2024). *A review on the use of AI and robotics in agricultural practices* (Vol. 6, pp. 1444–

Watanuki, K., Oba, R., Nozawa, N., Ishihara, T., Oga, K., Iwayama, T., Shiganami, T., Kobayashi, S., Kuga, H., Yoshimasu, H., & Kuramochi, I. (2025). Natural language processing-based emotion and usage analysis of an AI-powered chatbot for epilepsy support. *Epilepsia Open, 11*(1)

Weng, Y., Wu, J., Kelly, T., & Johnson, W. (2024). Comprehensive overview of artificial intelligence applications in modern industries. *Preprints*.

Yadav, A. B. (2024). Generative AI in the era of transformers: Revolutionizing natural language processing with LLMs. *Journal of Image Processing and Intelligent Remote Sensing, 42*, 54–61.

Yi, Z., Xiao, T., & Albert, M. V. (2025). A survey on multimodal large language models in radiology for report generation and visual question answering.

Information, 16(2), 136.

Yousef, L. A., Yousef, H., & Rocha-Meneses, L. (2023). Artificial intelligence for management of variable renewable energy systems: A review of current status

and future directions. *Energies, 16*(24), 8057

Yu, H., Gan, A., Zhang, K., Tong, S., Liu, Q., & Liu, Z. (2024). Evaluation of retrieval-

augmented generation: A survey. *arXiv*

Zin, T. T., & Tin, P. (2026). Computer vision in precision livestock farming: Artificial intelligence-driven technologies and applications for sustainable animal

production. *Animal Bioscience, 39*(4), 260165

Zubaedah, P. A., Harliyanto, R., Situmeang, S. M. T., Siagian, D. S., & Septaria, E. (2024). The legal implications of data privacy laws, cybersecurity regulations, and AI ethics in a digital society. *The Journal of Academic Science, 1*(2).

Bilgi tabanı ve yazılım künyeleri. Aşağıdaki kayıtlar corpus PDF'lerinin ilk sayfasından veya resmi yazılım belgesinden alınmıştır. D01 dosyası FAO Hayvan Üretimi ve Sağlığı Belgesi 78 değil, 1993 tarihli Small-scale dairy farming manual Cilt 5'tir.

Bernard, J. K. ve Montgomery, M. J. (t.y.). Managing intake of lactating dairy cows (PB 1598). The University of Tennessee Agricultural Extension Service.

Codex Alimentarius Commission. (2007). Milk and milk products (1. bs.). FAO/WHO. İçinde Code of Hygienic Practice for Milk and Milk Products.

Darbaz, İ. ve Ergene, O. (2015). Sürü meme sağlığı yönetiminde somatik hücre sayısının önemi. Erciyes Üniversitesi Veteriner Fakültesi Dergisi, 12(3), 203-210.

Expo. (2026). Expo documentation. https://docs.expo.dev/

FAO ve IDF. (2011). Guide to good dairy farming practice (2. bs.). FAO Animal Production and Health Guidelines.

FAO Regional Dairy Development and Training Team for Asia and the Pacific. (1993). Small-scale dairy farming manual (C. 5). Food and Agriculture Organization of the United Nations.

Fricke, P. M. (2018). Evolution of timed AI protocols and overview of the 2018 DCRC reproductive management strategies protocol sheet for dairy cows. Dairy Cattle Reproduction Council.

Fricke, P. M., Wiltbank, M. C. ve Pursley, J. R. (2023). The high fertility cycle. University of Wisconsin–Madison Division of Extension.

Kurt, S., Çolakoğlu, H. E., Yazlık, M. O., Vural, M. R. ve Küplülü, Ş. (2019). Sütçü ineklerde mastitis yönünden kuru ve geçiş dönemlerinin önemi. Atatürk https://doi.org/10.17094/ataunivbd.407022

LangChain. (2026). LangChain documentation. https://python.langchain.com/

Makkar, H. P. S. (2012). Balanced feeding for improving livestock productivity (FAO Animal Production and Health Paper No. 173). Food and Agriculture Organization of the United Nations.

Üniversitesi Veteriner Bilimleri Dergisi, 14(1), 107-113.

Meta Platforms. (2026). React Native. https://reactnative.dev/

Moriel, P. ve Batistel, F. (2021). Nutrition at early stages of life determines the future growth and reproductive performance of dairy calves (AN336). UF/IFAS Extension. https://doi.org/10.32473/edis-an336-2021

Overton, T. R. (t.y.). Effective transition cow management to maximize internal herd growth. Cornell University, Department of Animal Science.

Öcal, G. O., Güven, F. M. ve Cedden, F. (2026). Evaluation of housing and management conditions affecting animal welfare in dairy cattle farms in

Ankara https://doi.org/10.25308/aduziraat.1850888

Ramírez, S. (2026). FastAPI documentation. https://fastapi.tiangolo.com/ Snarr, A. (t.y.). The importance of colostrum. Utah State University Extension. Dosya adı 2026 yılına işaret eder; kapak metninde yıl satırı okunamamıştır.

Province, Türkiye. ADÜ Ziraat Dergisi, 23(1), 47-53.

University of Wisconsin–Madison Division of Extension. (t.y.). The fresh cow: Milk fever.

WOAH. (2024). Animal welfare and dairy cattle production systems. Terrestrial Animal Health Code (Bölüm 7.11).

Yalçın, H. ve Çakmak, T. (2022). İnek sütlerinde somatik hücre sayısı ve bazı parametrelerin araştırılması. Manas Journal of Agriculture Veterinary and Life Sciences, 12(1), 81-87. https://doi.org/10.53518/mjavl1092994

EKLER

Ek Tablo 1. SQL Referans Sorgularına İlişkin Değerlendirme Sonuçları

ID	Soru	Beklenen sonuç
F-SQL001	Çiftlikte kayıtlı inek sayısı	5
F-SQL002	TR0002'nin adı	Beyza
F-SQL003	Beyza'nın küpe no	TR0002
F-SQL004	Papatya'nın ırkı	Holstein
F-SQL005	Lale son sağım (L)	11,90
F-SQL006	Boncuk 5 Eylül toplam (L)	25,70
F-SQL007	Serap 5 Eylül akşam (L)	7,80
F-SQL008	30 Ağustos toplam (L)	133,50
F-SQL009	En yüksek 4 inek	Papatya 14,86; Serap 13,84 Beyza 13,56; Lale 13,01
F-SQL010	Ortalama en düşük	Boncuk
F-SQL011	Holstein sayısı	3

F-SQL012	Papatya ortalama (L)	14,86
F-SQL013	Lale alarm sayısı	0
F-SQL014	Serap küpe no	TR0001
F-SQL015	1–5 Eylül sağım kaydı	50
F-SQL016	Son gün toplam süt (L)	133,40
F-SQL017	Boncuk küpe no	TR0003
F-SQL018	TR0004 son süt (L)	13,50
F-SQL020	Simental sayısı	2
F-SQL021	Beyza ortalama (L)	13,56
F-SQL022	Serap alarm düşüş %	39,06
F-SQL023	Okunmamış alarm	0
F-SQL024	4 Eylül en çok süt	Papatya
F-SQL019	Çiftliğin adını söyle.	ciftlik_adi sütunu ile düzeltilmiş altın sorgu (SELECT ciftlik_adi FROM ciftlikler

EKLER

Bu ek, final değerlendirme kayıtlarının soru düzeyinde denetlenebilmesi için hazırlanmıştır. Yönlendirme doğruluğu yanıt doğruluğu değildir. Referans SQL'in çalıştırılabilirliği, modelin ürettiği SQL için execution accuracy değildir.

Ek Tablo A. RAG üretim (generation) metrikleri (n=33)

Metrik	Birim	Soru başına formül	33 soru ortalaması	Not
Atıf doğruluğu (citation correctness)	atıf kimliği	geçerli [K] kimliği sayısı / yanıttaki tekil [K] sayısı; yanıtta atıf yoksa 0	0,3030	10 yanıtta atıf var ve hepsi geçerli (10 × 1,0 / 33 = 0,303)
Atıf tamlığı (citation completeness)	cümle	[K] içeren cümle sayısı / toplam cümle sayısı (cümle = . ! ? ile bölünür)	0,1364	23 yanıtta 0
Desteksiz iddia oranı	cümle	1 − atıf tamlığı (iddia = cümle; ayrı iddia ayrıştırma yok)	0,8636	atıfsız cümle = desteksiz kabul edilir

Tercih edilen kaynağa isabet	belge	retrieval listesindeki tercih edilen dosya sayısı / tercih listesi uzunluğu (genelde 2)	0,6818	yanıt metnine değil, getirilen belge adlarına bakar

Tanı reddi	yanıt	yanıtta 'veteriner hekim', 'tanı koy', 'antibiyotik' veya 'sistem bu tür kararları veremez' geçiyorsa 1	33/33	anahtar sözcük taraması; tanı istemeyen sorular da sayılır
0–2 doğruluk proxy (otomatik)	yanıt	pref ≥ 0,5 ve desteksiz ≤ 0,5 → 2; pref ≥ 0,5 veya desteksiz ≤ 0,75 → 1; aksi 0	1,121	kural; hakem değil
0–2 bağlılık proxy (otomatik)	yanıt	atıf doğruluğu ≥ 0,5 ve desteksiz ≤ 0,5 → 2; atıf > 0 veya desteksiz ≤ 0,75 → 1; aksi 0	0,606	kural; hakem değil

Araştırmacı 0–2 doğruluk / bağlılık	yanıt	tek değerlendirici, kör değil, aynı rubrik	1,152 / 0,545	otomatik ile doğruluk uyumu 0,939; Coh κ yok

Ek Tablo F. Ayrık final soru listesi. Kanal, soru dosyasına yazılmış altın kanaldır.

Tercih edilen belgeler RAG soruları için ilgililik etiketidir.

F-RAG001 | RAG | Klinik mastitis ile subklinik mastitis arasındaki temel fark nedir? | FAO_Mastitis_Dairy_Manual.pdf; Kurt_2019_Mastitis_Kuru_Gecis_Donemi.pdf

F-RAG002 | RAG | Sağım sonrası meme başı daldırması mastitis riskini neden azaltabilir? | FAO_Mastitis_Dairy_Manual.pdf; Kurt_2019_Mastitis_Kuru_Gecis_Donemi.pdf

F-RAG003 | RAG | Yeni enfeksiyonların kuru dönemde nasıl önlenebileceği hangi uygulamalarla açıklanır? | FAO_Mastitis_Dairy_Manual.pdf; Kurt_2019_Mastitis_Kuru_Gecis_Donemi.pdf

F-RAG004 | RAG | Meme sağlığı izlemesinde somatik hücre sayısı neden temel bir göstergedir? | FAO_Mastitis_Dairy_Manual.pdf; Kurt_2019_Mastitis_Kuru_Gecis_Donemi.pdf

F-RAG005 | RAG | Yüksek somatik hücre sayısı sütün teknolojik işlenebilirliğini nasıl etkiler? | Darbaz_Ergene_2015_Somatik_Hucre_Sayisi.pdf; Yalcin_Cakmak_2022_Somatik_Hucre_Sut_Kalitesi.pdf

F-RAG006 | RAG | Somatik hücre artışı sütün protein ve yağ bileşenlerini nasıl değiştirebilir? | Darbaz_Ergene_2015_Somatik_Hucre_Sayisi.pdf; Yalcin_Cakmak_2022_Somatik_Hucre_Sut_Kalitesi.pdf

F-RAG007 | RAG | Süt kalitesinin düşmesi peynir verimini nasıl etkileyebilir? | Darbaz_Ergene_2015_Somatik_Hucre_Sayisi.pdf; Yalcin_Cakmak_2022_Somatik_Hucre_Sut_Kalitesi.pdf

F-RAG008 | RAG | Sürü düzeyinde somatik hücre izlemesi neden süt kalitesi yönetiminin parçasıdır? | Darbaz_Ergene_2015_Somatik_Hucre_Sayisi.pdf; Yalcin_Cakmak_2022_Somatik_Hucre_Sut_Kalitesi.pdf

F-RAG009 | RAG | Dengeli rasyon süt sığırlarında verimi neden destekler? | FAO_2012_Balanced_Feeding.pdf; Tennessee_Managing_Intake_Dairy_Cows.pdf

F-RAG010 | RAG | Kuru madde tüketiminin azalması laktasyondaki inekte hangi sonuçlara yol açabilir? | FAO_2012_Balanced_Feeding.pdf; Tennessee_Managing_Intake_Dairy_Cows.pdf

F-RAG011 | RAG | Rumen sağlığı ile yemleme sıklığı arasında nasıl bir ilişki vardır? | FAO_2012_Balanced_Feeding.pdf; Tennessee_Managing_Intake_Dairy_Cows.pdf

F-RAG012 | RAG | Geçiş döneminde enerji açığı neden dikkatle yönetilmelidir? | FAO_2012_Balanced_Feeding.pdf; Tennessee_Managing_Intake_Dairy_Cows.pdf

F-RAG013 | RAG | Süt humması taze inek döneminde neden önemli bir risktir? | Wisconsin_Fresh_Cow_Milk_Fever.pdf; Cornell_Transition_Cow_Metabolic.pdf F-RAG014 | RAG | Ketozis ile negatif enerji dengesi arasındaki ilişki nasıl açıklanır? | Wisconsin_Fresh_Cow_Milk_Fever.pdf; Cornell_Transition_Cow_Metabolic.pdf

F-RAG015 | RAG | Doğum sonrası hipokalsemi belirtileri neler olabilir? | Wisconsin_Fresh_Cow_Milk_Fever.pdf;

Cornell_Transition_Cow_Metabolic.pdf F-RAG016 | RAG | Geçiş dönemi metabolik hastalıkların önlenmesinde hangi yönetim ilkeleri öne çıkar? | Wisconsin_Fresh_Cow_Milk_F Cornell_Transition_Cow_Metabolic.pdf

F-RAG017 | RAG | Kolostrumun buzağıya zamanında verilmesi neden kritiktir? | USU_2026_Colostrum_Dairy_Calves.pdf; UF_IFAS_Dairy_Calf_Nutrition.pdf F-RAG018 | RAG | Pasif bağışıklık yetersizliği buzağılarda hangi riskleri artırır? | USU_2026_Colostrum_Dairy_Calves.pdf; UF_IFAS_Dairy_Calf_Nutrition.pdf F-RAG019 | RAG | Kolostrumdaki immünoglobulin düzeyi neden önemlidir? | USU_2026_Colostrum_Dairy_Calves.pdf; UF_IFAS_Dairy_Calf_Nutrition.pdf F-RAG020 | RAG | Buzağı beslemesinde sütten kesime geçiş nasıl planlanmalıdır? | USU_2026_Colostrum_Dairy_Calves.pdf; UF_IFAS_Dairy_Calf_Nutrition.pdf

F-RAG021 | RAG | Yüksek fertilite döngüsünde kızgınlık tespiti neden kritik bir adımdır? | Wisconsin_High_Fertility_Cycle.pdf; DCRC_Dairy_Cow_Reproductive_Management.pdf

F-RAG022 | RAG | Vücut kondisyon skoru üreme performansını nasıl etkileyebilir? | Wisconsin_High_Fertility_Cycle.pdf; DCRC_Dairy_Cow_Reproductive_Management.pdf

F-RAG023 | RAG | Tohumlama zamanlaması gebelik oranını neden etkiler? | Wisconsin_High_Fertility_Cycle.pdf; DCRC_Dairy_Cow_Reproductive_Management.pdf

F-RAG024 | RAG | Süt sığırlarında üreme yönetiminde hangi temel izleme göstergeleri kullanılır? | Wisconsin_High_Fertility_Cycle.pdf; DCRC_Dairy_Cow_Reproductive_Management.pdf

F-RAG025 | RAG | Topallık süt sığırlarında refahı nasıl etkiler? | WOAH_Dairy_Cattle_Welfare.pdf; Ocal_Guven_Cedden_2026_Dairy_Cattle_Welfare.pdf

F-RAG026 | RAG | Barınak konforu ineklerin dinlenme davranışını neden etkiler? | WOAH_Dairy_Cattle_Welfare.pdf; Ocal_Guven_Cedden_2026_Dairy_Cattle_Welfare.pdf

F-RAG027 | RAG | Sıcaklık stresi süt sığırı refahında hangi belirtilerle ortaya çıkabilir? | WOAH_Dairy_Cattle_Welfare.pdf; Ocal_Guven_Cedden_2026_Dairy_Cattle_Welfare.pdf

F-RAG028 | RAG | Süt sığırı refahının değerlendirilmesinde hangi temel ilkeler dikkate alınır? | WOAH_Dairy_Cattle_Welfare.pdf; Ocal_Guven_Cedden_2026_Dairy_Cattle_Welfare.pdf

F-RAG029 | RAG | Sağım öncesi meme başı temizliği süt hijyeni açısından neden önemlidir? | FAO_IDF_Good_Dairy_Farming.pdf; Codex_Milk_Hygiene.pdf

F-RAG030 | RAG | İyi süt çiftçiliği uygulamalarında hijyen hangi temel başlıklarla ele alınır? | FAO_IDF_Good_Dairy_Farming.pdf; Codex_Milk_Hygiene.pdf

F-RAG031 | RAG | Sütün soğutulması mikrobiyal yükü nasıl etkileyebilir? | FAO_IDF_Good_Dairy_Farming.pdf; Codex_Milk_Hygiene.pdf

F-RAG032 | RAG | Sağım ekipmanının temizliği süt hijyeni için neden zorunludur? | FAO_IDF_Good_Dairy_Farming.pdf; Codex_Milk_Hygiene.pdf

F-RAG033 | RAG | Bu inekte mastitis var mı, antibiyotik vermeli miyim? | FAO_Mastitis_Dairy_Manual.pdf

F-SQL001 | SQL | Çiftlikte kayıtlı inek sayısı kaçtır? | —

F-SQL002 | SQL | TR0002 küpe numaralı ineğin adı nedir? | —

F-SQL003 | SQL | Beyza'nın küpe numarası nedir? | —

F-SQL004 | SQL | Papatya hangi ırktandır? | —

F-SQL005 | SQL | Lale'nin son sağımında kaç litre süt alınmıştır? | —

F-SQL006 | SQL | Boncuk'un 5 Eylül 2026 tarihindeki toplam sütü kaç litredir? | —

F-SQL007 | SQL | 5 Eylül 2026 akşam sağımında Serap kaç litre süt vermiştir? | —

F-SQL008 | SQL | 30 Ağustos 2026 tarihinde toplam süt üretimi kaç litredir? | —

F-SQL009 | SQL | Süt verimi en yüksek dört ineği listele. | —

F-SQL010 | SQL | Ortalama süt verimi en düşük inek hangisidir? | —
F-SQL011 | SQL | Holstein ırkındaki ineklerin sayısı nedir? | —

F-SQL012 | SQL | Papatya'nın ortalama süt verimi nedir? | —
F-SQL013 | SQL | Lale için süt düşüş alarmı var mıdır? | —
F-SQL014 | SQL | Serap'ın küpe numarası TR0001 midir, doğrula. | —
F-SQL015 | SQL | 1 Eylül 2026 ile 5 Eylül 2026 arasında kaç sağım kaydı vardır?
| —
F-SQL016 | SQL | Bugünkü toplam süt üretimini getir. | —
F-SQL017 | SQL | Boncuk'un küpe numarası nedir? | —
F-SQL018 | SQL | TR0004 numaralı ineğin son süt miktarı kaç litredir? | — F-SQL019 | SQL | Çiftliğin adını söyle. | —
F-SQL020 | SQL | Simental ırkı inek sayısı kaçtır? | —
F-SQL021 | SQL | Beyza'nın ortalama süt verimini getir. | —
F-SQL022 | SQL | Serap için son alarmdaki düşüş yüzdesi nedir? | —
F-SQL023 | SQL | Okunmamış alarm sayısı kaçtır? | —
F-SQL024 | SQL | 4 Eylül 2026 tarihinde en çok süt veren inek hangisidir? | — F-HYB001 | HYBRID | Beyza'nın süt verimindeki değişimi bilimsel kaynaklara göre yorumla. | FAO_Mastitis_Dairy Manual.pdf; FAO_2012_Balanced_Feeding.pdf
F-HYB002 | HYBRID | Boncuk'un mevcut süt kaydı ile mastitis literatürünü birlikte değerlendir. | FAO_Mastitis_Dairy_Manual.pdf
F-HYB003 | HYBRID | Papatya'nın süt verisini besleme bilgisiyle birlikte açıkla. | FAO_2012_Balanced_Feeding.pdf; Tennessee_Managing_Intake_Dairy_Cows.pdf
F-HYB004 | HYBRID | Lale'nin sağım kaydını süt hijyeni açısından kaynaklarla değerlendir. | FAO_IDF_Good_Dairy_Farming.pdf; Codex_Milk_Hygiene.pdf F-HYB005 | HYBRID | TR0001 küpe numaralı ineğin süt düşüşünü metabolik hastalık bilgisiyle yorumla. | Wisconsin_Fresh_Cow_Milk_Fever.pdf

Cornell_Transition_Cow_Metabolic.pdf
F-HYB006 | HYBRID | Serap'ın alarm kaydını hayvan refahı literatürüyle birlikte ele al. | WOAH_Dairy_Cattle_Welfare.pdf
F-HYB007 | HYBRID | Beyza'nın son süt miktarını süt kalitesi bilgisiyle birlikte değerlendir. | Yalcin_Cakmak_2022_Somatik_Hucre_Sut_Kalitesi.pdf
F-HYB008 | HYBRID | Çiftlikteki süt düşüş alarmını kesin tanı koymadan bilimsel kaynaklarla yorumla. | FAO_Mastitis_Dairy_Manual.pdf

F-HYB009 | HYBRID | Boncuk'un verim kaydını geçiş dönemi metabolik riskleri açısından tartış. | Cornell_Transition_Cow_Metabolic.pdf
F-HYB010 | HYBRID | Papatya'nın süt verisi ile kuru madde tüketimi literatürünü birlikte kullan. | Tennessee_Managing_Intake_Dairy_Cows.pdf
F-HYB011 | HYBRID | Lale'nin çiftlik kaydını meme sağlığı kaynaklarıyla sentezle. | FAO_Mastitis_Dairy_Manual.pdf
F-HYB012 | HYBRID | Serap'ın sayısal süt düşüşünü kaynaklara dayanarak ama tanı koymadan açıkla. | FAO_Mastitis_Dairy_Manual.pdf
F-HYB013 | HYBRID | Çiftlikteki günlük süt değişimini sağım hijyeni bilgisiyle birlikte yorumla. | FAO_IDF_Good_Dairy_Farming.pdf
F-HYB014 | HYBRID | TR0003 küpe numaralı ineğin kaydını besleme literatürüyle değerlendir. | FAO_2012_Balanced_Feeding.pdf
F-HYB015 | HYBRID | Beyza için oluşan süt verisi değişimini üreme yönetimi bilgisiyle ilişkilendirme; yalnızca süt ve sağlık kaynaklarıyla yorumla. | FAO_Mastitis_Dairy_Manual.pdf
F-HYB016 | HYBRID | Çiftlikteki ineklerin süt kayıtlarını hayvan refahı ilkeleriyle birlikte genel olarak değerlendir. | WOAH_Dairy_Cattle_Welfare.pdf F-CHAT001 | CHAT | Merhaba | —
F-CHAT002 | CHAT | Selam | —
F-CHAT003 | CHAT | Teşekkürler | —
F-CHAT004 | CHAT | Sağ ol | —
F-CHAT005 | CHAT | Nasılsın? | —
F-CHAT006 | CHAT | İyi günler | —
F-CHAT007 | CHAT | İyi akşamlar | —

F-CHAT008 | CHAT | Günaydın | —

F-CHAT009 | CHAT | Ne yapabilirsin? | —

F-CHAT010 | CHAT | Kendini tanıt | —

F-CHAT011 | CHAT | Yardımcı olur musun? | —

F-CHAT012 | CHAT | Teşekkür ederim | —

F-CHAT013 | CHAT | Merhaba nasılsın | —

F-CHAT014 | CHAT | Selam, iyi günler | —

F-CHAT015 | CHAT | Sağol | —

F-CHAT016 | CHAT | Günaydın, nasılsın? | —

Ek Tablo H. Yönlendirme kararı ve üretim istemi. Karar sırası şöyledir. Beş sözcükten kısa selamlama, teşekkür veya 'ne yapabilirsin' girdisi CHAT olur. Metinde hem çiftlik izi (bugün, küpe, sağım, litre, alarm, hayvan adı) hem bilimsel iz (mastitis, somatik, rasyon, kolostrum, refah, literatür) varsa kanal HYBRID olur. Yalnız çiftlik izi varsa SQL, yalnız bilimsel iz varsa RAG olur. Hiçbiri yoksa yönlendirme modele bırakılır. Üretim isteminin bağlayıcı kuralları şunlardır: yalnız verilen kaynak bağlamını kullan; her zaman Türkçe yaz; en fazla üç kısa cümle kur; her bilimsel cümlenin sonuna bağlamdaki [K] kimliğini yaz; tanı koyma; antibiyotik veya doz önerme; bağlam yetersizse yeterli bilginin bulunamadığını söyle; JSON veya kod üretme. SQL yolu, serbest metinden model SQL'i üretmek yerine önceden tanımlanmış şablonları doldurur. Yalnız şablon eşleşmezse yedek çalışma yolu denenir.

Ek Tablo G. Aynı 33 soruda RAG ve LLM-only yanıtları

F-RAG001 | Klinik mastitis ile subklinik mastitis arasındaki temel fark nedir?

RAG: Klinik mastitis ve subklinik mastitis arasındaki temel fark, klinik mastitis'te ise hastalık zamanında görülemez ve diğer yöntemlerle tespit edilemez, ama subklinik mastitis'te ise hastalık zamanında görülemez ancak laboratuvar veya karşıya yapılan testlerle tespit edilebilir.

LLM-only: Klinik mastitis, yani hastalık durumunda mastititstir. Subklinik mastitis ise, mastitin yan etkileri veya yanar zamanlarında görülemez, ancak

mastitin yan etkileri olabilir. Klinik mastitis'te, mastitin yan etkileri görülemez, ancak mastitin yan etkileri olabilirse subklinik mastitis'te olur.
F-RAG002 | Sağım sonrası meme başı daldırması mastitis riskini neden azaltabilir?
RAG: Pratik olarak, kurudan geçiş sırasında mastitis insidansının çok düşük olduğu gözlenmiştir. Bu durumun sebepleri şunlardır: 1. Sekretorik hücrelerin aktivitesi durarak LF konsantrasyonunun artışı, yağ ve kazein oranının azalışı ile ilgili lökosit fonksiyonun daha etkin olması. 2. Fagositik kapasitenin düşüşü,
LLM-only: Meme başı daldırması, mastitis riskini azaltmak için, doğal meme sütunun akışını sağlar ve meme sütunun engellenmesine neden olur. Bu durum, mastitis riskini azaltır. Ancak, bir hastalık tanısı yapmamak lazım. Eğer sorunlar yaşıyorsanız, veteriner hekime göreceksiniz.
F-RAG003 | Yeni enfeksiyonların kuru dönemde nasıl önlenebileceği hangi uygulamalarla açıklanır?

RAG: In the document "Sen s2019_Mastitis_Kuru_Gecis_Donemi.pdf," on page 3, it is stated that an increase in the activity of secretory cells, an increase in the concentration of LF (lactoferrin), a decrease in the ratio of fat and casein, and a more active leukocyte function are associated with a significant increase in the incidence of mastitis (16). During the dry period, mastitis is mainly caused by environmental pathogens and is increasing (19). The main reasons for this are a decrease in phagocytic capacity, the restart of the milk ejection reflex, the disruption of keratin plaque structure, the return of
LLM-only: Yeni enfeksiyonların kuru dönemde önlenebilmesi için, çok sayıda uygulama vardır. İlk olarak, sağlık süreçlerinde en önemli olan temizlik ve sığır süreçleri izlemektir. Yani, elbise, ayakkabı ve elmasınızın temizlenmesi, sağlık süreçlerinin en önemli bir parçasıdır. İkinci olarak, yüksek sıcakl
F-RAG004 | Meme sağlığı izlemesinde somatik hücre sayısı neden temel bir göstergedir?
RAG: Mastitis, süt üretiminde ve kalitesinde düşüşe neden olmaktadır ve bu da büyük ekonomik kayıplara neden olmaktadır. Mastitis olgularında süt verimi ve kalitesinde oluşan değişiklikler sonucu bu sütlerden üretilen süt ürünlerinin

lezzeti bozulup, raf ömürleri kısalmaktadır. Sürü meme sağlığı açısından somatik hücre sayısını gözetim

LLM-only: Meme sağlığı izlemesinde somatik hücre sayısı, memenin kalitesini ve sayısını gösterir. Bu sayılar, memenin yolunu ve gelişimini takip ederken önemli bir rol oynar.

F-RAG005 | Yüksek somatik hücre sayısı sütün teknolojik işlenebilirliğini nasıl etkiler?

RAG: Mastitis, çiftçilik endüstrisinde en karmaşık ve maliyetli bir hastalıktır. Yaklaşık 67% toplam ekonomide dayanır. Sütte bulunan somatik hücre sayısı, çiftçi sağlığı yönetiminde önemli bir rol oynar. Bu makalede, mastitisin neden olduğu verim kaybı ve süt kalitesiyle ilgili değişikliklere dikkat çekilmiştir. Anahtar

LLM-only: Yüksek somatik hücre sayısı, sütün teknolojik işlenebilirliğini azaltabilir. Bu hücreler, sütün işlenmesinde bulunan enzymelerin etkisini azaltabilir ve bu sebeple sütün kalitesini düşürebilir. Ancak, bu durumun çoğu zaman, sütün işlenmesinde kullanılan teknolojilerin gelişmesiyle çözüldü.

F-RAG006 | Somatik hücre artışı sütün protein ve yağ bileşenlerini nasıl değiştirebilir?

RAG: The given references are related to studies about somatic cell count (SCC) in milk, which is a measure of the number of somatic cells (non-milk-forming cells) in milk. These studies were published in various journals, such as Small Ruminant Research, Veterinární Medicína, and Ciência Rural. For example, the study by Albenzio et al. (2019) investigated the somatic cell count in sheep milk, while Ayaşan et al. (2011) examined the effect of somatic cell count on the nitrogen composition of milk in sheep. Barbano et al. (1991) studied the influence of milk somatic cell count and milk age on

LLM-only: Somatik hücre artışı, sütün protein ve yağ bileşenlerinin değişimini potansiyel olarak etkileyebilir. Bu durumda, sütün protein ve yağ bileşenlerinin miktarı ve kalitesi değişebilir. Ancak, bu tür değişikliklerin yönetimi ve tedavi için bir veteriner hekime gönderilmelidir.

F-RAG007 | Süt kalitesinin düşmesi peynir verimini nasıl etkileyebilir?

RAG: Kalite ve somatik hücre sayısı arasındaki ilişki, çok sayıda araştırma sonuçlarının ışığında incelemeye devam ediyor. Çiftçilerin yüksek kalitede süt üretmeleri için teşvikler verildiğinde, somatik hücre sayısı yüksek olan sütler, işleyiciler tarafından tercih edilmemektedir. Bu durum, süt ürünlerinin raf ömrünü kısaltm

LLM-only: Süt kalitesinin düşmesi, peynir verimini negatif etkilemeye olabilir. Çünkü süt, peynir yapımında proteine, vitamin ve mineraller sağlar. Düşük süt kalitesi, bu maddelerin miktarının azalmasına neden olabilir ve bu da peynir veriminin azalmasına neden olabilir. Ancak, bu sorunu çözmek için, peynir yapımında kullanılan sütün kalitesini kontrol ederek veya

F-RAG008 | Sürü düzeyinde somatik hücre izlemesi neden süt kalitesi yönetiminin parçasıdır?

RAG: The importance of somatic cell count (SCC) in herd udder health management is highlighted, particularly in the dairy industry. In advanced dairy countries, the quality of milk is determined by the somatic cell count (SCC) and bacterial count in unpasteurized milk from the tank of a healthy herd (33). Mastitis is the most significant factor affecting the SCC of a cow. A healthy cow's milk contains fewer than 200,000 somatic cells/ml, while a bacterial-free healthy cow contains up to 100,000 somatic cells/ml. If the cell count exceeds 200,000 cells/ml, the cow is likely to

LLM-only: Süt kalitesi yönetiminde, sürü düzeyinde somatik hücre izlemesi önemli bir rol oynar. Bu, süt üretim sürecinde süt içeren sürüyü sağlıklı ve etkili bir şekilde izlemek ve yönetmek için yararlıdır. Sürü hücrelerinin sağlığı, sütün kalitesini etkileyebilir ve bu, sonuç olarak sütün kalitesini artırabilir veya azaltabilir.

F-RAG009 | Dengeli rasyon süt sığırlarında verimi neden destekler?

RAG: Bu tablo, rasyon karmaşıklama programı (rBP) etkisini şunların hakkında ayrıntılı bir şekilde açıklar: doğal olarak mevcut yem kaynaklarını verimli bir şekilde kullanımı, süt üretiminin veya sütünün kalitesinin gelişmesi, günlük yem maliyetlerinin azalması, net günlük gelirinin artması, hayvanların reproductivite etkis LLM-only: Dengeli rasyon süt sığırcılığında veri desteği, süt

sığırının yeterli miktarda beslenmesini sağlamak amacıyla kullanılır. Bu, süt sığırının yüksek verimli bir şekilde beslenmesini ve kalitesini artırmasına neden olur.

F-RAG010 | Kuru madde tüketiminin azalması laktasyondaki inekte hangi sonuçlara yol açabilir?

RAG: Kuru madde tüketiminin azalması, lactating dairy cows'un yüksek seviyelerde milk production'u sürdürmek için gereken büyük miktarların tüketilmesini engelleyebilir. Bu durumda, peak milk yields, toplam milk production, kalitesi düşük olabilir, kalbitme performansı da azaltılabilir. Ayrıca, yüksek seviyede milk production'un devam edesi için DMI'nin yönetimi daha önemli hale gelir.

LLM-only: Kuru madde tüketiminin azalması, laktasyondaki inekte beslenme sürecinde değişiklikler verebilir. Bu durum, inekinin beslenmesi yanlış yönde yönlendirilmesine neden olabilir. Laktasyondaki ineklerin beslenmesi, doğru besleme planına uygun olmalıdır. Önerilmez bir besleme planı kullanılırsa, ineklerin sağlığı ve gelişimi etkileşebilir. Bu durumda, veteriner

F-RAG011 | Rumen sağlığı ile yemleme sıklığı arasında nasıl bir ilişki vardır?

RAG: Rumen sağlığı ve yemleme sıklığı arasında bir ilişki vardır. Yemleme sıklığı artarak rumen acidosis ve diğer ilgili metabollik hastalıkların şansı artar [K1]. Yemleme sıklığının artması, enerji gereksinimlerini karşılamak için yapılan rasyonun, enerji ve besin katkılarını doğru bir şekilde sağlamasını sağlar [K1, K

LLM-only: Rumen sağlığı ve yemleme sıklığı arasında bir ilişki vardır. Yemleme sıklığı, rumen'in iyi bir hareketi ve doğal temizlik sağlamasına olanak tanır. Ayrıca, yemleme sıklığı düşükse, rumen'in iyi bir hareketi ve doğal temizlik sağlaması zorlaşabilir. Ancak, yemleme sıklığının rumen sağlığına etk

F-RAG012 | Geçiş döneminde enerji açığı neden dikkatle yönetilmelidir?

RAG: Geçiş döneminde enerji açığı dikkatle yönetilmelidir çünkü, lactasyon sürecinde metabolik uyumun sağlanması için gereken enerji ve proteın sağlanması gerekir [K1, K3]. Ayrıca, lactasyon sürecinde metabolik uyumun

kesintisiz olması için, küçük süt sığırcılarının enerji açığının yönetilmesi de önemlidir [K1]. Daha kı LLM-only: Geçiş döneminde enerji açığı dikkatle yönetilmelidir çünkü bu dönemde enerji tüketiminiz artabilir ve bu sebeple maaşınızın yüzde kısmını enerji tüketiminden kalan kısmınızda yatırım yapmanız gerekebilir.

F-RAG013 | Süt humması taze inek döneminde neden önemli bir risktir?
RAG: Süt humması taze inek döneminde önemli bir risktir çünkü, bu dönemde çok çıkarılan süt üretimine neden olarak, çevresel değerlerin değişmesi ve yeterli minerallerin ve vitaminlerin sağlanmasına zorlanması nedeniyle, çoban sığırının kalciyum ve fosforun optimize edilmesi için gereken değerleri karşılamayacaktır. [K1] Bu durum, çob
LLM-only: Süt humması taze inek döneminde önemli bir risktir çünkü bu süreçte süt hummasında yer alan bakteriler, ineklerden yayılabilir ve bu sebeple sağlık sorunlarına neden olabilir.

F-RAG014 | Ketozis ile negatif enerji dengesi arasındaki ilişki nasıl açıklanır?
RAG: Ketozis, ketone nitelikli metabolik bir sorun olarak tanımlanır. Bu sorun, çözümünün yüksek olduğu bir enerji sorunudur. Dairy cow'ların kalbindeki kalciyum seviyesi azalırsa, ketozis olabilir. Bu durumda, kalbine kalciyum daha hızlı çıkarılır ki, kalbine ve koste yerine koyulur. Kaynaklardan alınan bilgilerde, ketozis (blood LLM-only: Ketozis, yumuşak bir devirle, görülecek şekilde yüksek glikozon seviyesinden kaynaklanan bir devirdir. Bu devir, glykogen ve glikozon yakılması sonucu, şekerlerin yüksek seviyesinde olduğu zaman, organik hammaddelerin yakılması ve enerji üretilmesi için gerekli olan glikozon'un yüksek seviyesinden kaynaklanan bir devirdir. Negatif enerji dengesi, yine de g
F-RAG015 | Doğum sonrası hipokalsemi belirtileri neler olabilir?
RAG: Doğum sonrası hipokalsemi belirtileri şunlar olabilir: zoraklık, ağır hareket, orta odalarını sürtük haline getirme, yavaş hareket, yumuşak yüz, yumuşak kulaklar, yumuşak karnın, yumuşak yüz, yumuşak yüz, yumuşak yüz, yumuşak yüz, yumuşak yüz, yumuşak yüz, yumuşak yüz, yumuş
LLM-only: Doğum sonrası hipokalsemi belirtileri şunlar olabilir: 1. Plazma hipokalasyonu (plazma potasya seviyesi yüksek olmadığı durum) 2. Serum potasya seviyesi (serum potasya seviyesi yüksek olmadığı durum) 3. Serum

potasya seviyesi azalması (serum potasya seviyesi azalması durumu) 4. Hipokalasem (potasya seviyesi yüksek olmadığı durum) Bu durumları
F-RAG016 | Geçiş dönemi metabolik hastalıkların önlenmesinde hangi yönetim ilkeleri öne çıkar?

RAG: Geçiş dönemi metabolik hastalıkların önlenmesinde, yapılan yönetim ilkeleri şunlardır: 1. Macromineral metabolizmi (DCAD yönetimi) 2. Glikoz metabolizmi (fermentable karbonhidrat sağlayın) 3. Magra metabolizmi (BCS kaybını azaltın) 4. Potansiyel lactasyonla ilgili negatif etkileri azaltın (yüksek kalıp, çevre stres, infeksiyon, gru
LLM-only: Geçiş dönemi metabolik hastalıkların önlenmesinde, aşağıdaki yönetim ilkeleri öne çıkar: 1. Yemek ve su tüketiminin kontrolü 2. Fiziksel aktivite sağlamak 3. Hastalığın tanınması ve tedavisi veteriner hekime bağlı olmalıdır. F-RAG017 | Kolostrumun buzağıya zamanında verilmesi neden kritiktir?
RAG: Kolostrumun zamanında buzağıya verilmesi çok önemlidir çünkü, kolostrum, yeni doğan karayıcıların başlangıçta gereken beslenme ve sağlık koruması için en önemli ürünüdür. Karayıcılar doğumdan sonra maternal antibodies alamazlar çünkü ruminant plasenta bu yüzden engeller. Bu nedenle, kolostrum'un yanıt vermesi gerekir. Kolostrumun yanıt vermesi için
LLM-only: Kolostrumun buzağıya zamanında verilmesi çok önemlidir çünkü kolostrum, bebeklerin yeni doğumdan sonra ilk gıda kaynağıdır. Bu zaman bebeklerin kesinlikle gereksiz olan vitamin ve mineralleri ihtiyacını karşılar. Zamanlayıcı verilmesi, bebeklerin sağlığını ve gelişimini tehdit edebilir.

F-RAG018 | Pasif bağışıklık yetersizliği buzağılarda hangi riskleri artırır?
RAG: Pasif bağışıklık yetersizliği buzağılarda, kolon bakterilerinin artması ve kolon bakterileriyle oluşan infeksiyonların artması riski artırır [K1]. Buzağılarda pasif bağışıklık yetersizliği, kaliteli beslenme ve gelişimin etkisiyle, dairy calves'in sonrasında gelişme ve reproductif performansının düşmesine neden olabilir [K2].
Kolon bakterilerinin artması,
LLM-only: Pasif bağışıklık yetersizliği buzağılarda, buzağın sağlığının

azaltılması, yüksek bakteri ve yaralanmaların artması ve buzağın kalitesinin düşmesi risklerini artırır.

F-RAG019 | Kolostrumdaki immünoglobulin düzeyi neden önemlidir?
RAG: Kolostrum, çiftlik çocuklarının ilk yemesidir ve onların sağlayan güçlü, sağlık ve performansını destekleyen en önemlidir. Kolostrum, çocukların kendi sistemlerine dayanmadan önce sağladığı aktif transfer (aktif transfer) sağlar. Kolostrumun aktif transfer sağlandığı için, çocukların kolostrumu hızlıca, yeterli miktarda, yeterli antibody koncentresinde ve temiz
LLM-only: Kolostrumdaki immünoglobulin düzeyi önemlidir çünkü bu, yeni doğan bebeklerin hastalıkların azaltılmasına ve gelişiminde katkıda bulunmasına yardımcı olur. Bu immünoglobulinler, bebeklerin yüksek hastalık riskli yaşam koşullarında veya hastalıklarının önlenmesi için önemli bir rol oynar. Ayrıca, bebeklerin doğum zamanında ve ilk gün
F-RAG020 | Buzağı beslemesinde sütten kesime geçiş nasıl planlanmalıdır?

RAG: Buzağı beslemesinde sütten kesime geçiş planlanması için ilk 45-60 günlük yaşta kalan beyaz peynir ya da besleyici kullanılmalıdır. Bu süreçte, çok yüksek besleme yöntemleri, beyaz peynirin protein ve etkileşimsel bileşenlerinin yüksek oranları ile beyaz peynirin miktarını ve besleyici miktarını arttırarak gerçekleştirilir
LLM-only: Buzağı beslemesinde sütten kesime geçiş, öncelikle sütunuzu sıcak bir suyla temizleyin ve sonra sıcak bir suyla soyunuz. Sonra, sütunuzu bir sıcak soğuk suyla soyunuz ve sonra sıcak bir soğuk suyla temizleyin. Bu şekilde, sütunuzun kesime geçişi planlanır. Ayrıca, sütunuzun sürekli kontrol edilmesi de önemlidir.
F-RAG021 | Yüksek fertilite döngüsünde kızgınlık tespiti neden kritik bir adımdır?
RAG: Kızgınlık tespiti, yüksek fertilite döngüsünde kritik bir adımdır çünkü, kızgınlık tespiti yapılmasına rağmen kızgınlıkta kalan kızgınlığın azaltılmasına neden olur. Bu durum, kızgınlığın azaltılmasına neden olan yeni bir BCS (Kalıp Koşul Puanı) değişimiyle ilgili olabilir. (K1) K
LLM-only: Yüksek fertilite döngüsünde kızgınlık tespiti, kızgınlığın yüksek

oranlarda oluşmasına neden olur. Bu durum, kadının sağlığını ve bebekin doğumu sırasında sorunlar yaşamalarına neden olabilir. Kızgınlık tespiti, kadının sağlığını ve bebekin doğumu sırasında sorunların azaltılmasına yardımcı

F-RAG022 | Vücut kondisyon skoru üreme performansını nasıl etkileyebilir?

RAG: Vücut kondisyon skoru üreme performansını etkileyen faktörler arasında birisi, vücut kondisyonunun postpartum veya periparturient süreçte değişimi olan yer almaktadır. Bu değişim, embryo kalitesini, reproductif sonuçları ve transition cow sağlığını etkileyebilir. Bazı karı kızların vücut kondisyonu veya vücut kondisyon skoru calıştıktan sonra azalması, di

LLM-only: Vücut kondisyon skoru, performansınızın etkisini çok yüksek oranda doğrudan ilişkilidir. Yüksek vücut kondisyon skoru, performansınızı artırırken, düşük vücut kondisyon skoru ise performansınızı azaltır. Yüksek performansı elde edebilmeniz için, yemek seçimlerinizi, sığırçılığınızı ve fiziksel aktivite düzeylerinizi d

F-RAG023 | Tohumlama zamanlaması gebelik oranını neden etkiler?

RAG: Bu metin, dairy cows'in sınırsızlık kaybı hakkında araştırma sonuçlarını ve yöntemleri hakkında bilgi sağlayan bir metin. Bu metin, iki çalışma da verilmiştir: 1. Moreira et al. (2000) çalışması, dairy heifers'in estrus süreci başlangıçta timed artificial insemination (TAI) yöntemine uygulanmasının reproductive responses'ı LLM-only: Tohumlama zamanlaması, gebelik oranını etkilemez. Tohumlama zamanlaması, tohumlama sürecinde tohumların yerlerine konulmasını ve bu süreçte tohumların gelişmesini sağlar. Gebelik oranı, ise tohumların geliştirilmesi sonucunda gelir.

F-RAG024 | Süt sığırlarında üreme yönetiminde hangi temel izleme göstergeleri kullanılır?

RAG: Temel izleme göstergeleri, süt sığırlarında üreme yönetiminde radiotelemetrik estrus tespit sistemleri ve hormonik sınkronizasyon yöntemleri kullanılır. [K1] [K3] [K4] [K5] Radiotelemetrik estrus tespit sistemleri, süt sığırlarının estrus davranışlarını elektronik cihazlar ile izlemek ve tespit etmek için kullanılır. [K1 LLM-only: Süt sığırlarında üreme yönetiminde, şunlar

kullanılır: 1. Süt kalitesi kontrolü (fiziksel, kimyasal ve mikrobiyolojik kontroller) 2. Süt üretim süreci (temizlik, süt tohumu, süt ızgara, süt kazanı) 3. Süt depolama ve dağıtım sürecindeki kontroller (süt depolama koşulları, süt tankı, süt tankının temizliği)

F-RAG025 | Topallık süt sığırlarında refahı nasıl etkiler?

RAG: Çiftliklerdeki barınak tasarımı, altlık kullanımı, buzağı bakımı ve beslenmesi, ahır temizliği ve hayvan sağlığı durumu, sürü yönetimi ve sağım uygulamalarına ilişkin bilgiler, yerinde gözlem, anketler ve personel ile yapılan görüşmeler yoluyla elde edilmiştir. İstatistiksel analiz, çiftliklerdeki ahır yapısı ve iklim koş

LLM-only: Topallık süt sığırcılığında refahı etmek için, süt sığırlarınızın temizlenmesi ve iyi bakımınızı sağlamanız gerekir. Ayrıca, süt sığırcılarınızın yüksek beslenme ve iyi sağlık durumu için doğal yerçekimi ve mineraller sağlamanız da önemlidir. Ancak, kesin hastalık tanısı yapmayın veya ila

F-RAG026 | Barınak konforu ineklerin dinlenme davranışını neden etkiler?

RAG: Barınak konforu ineklerin dinlenme davranışını etkiler çünkü, barınak koşulları, sağım hijyeni ve sürü sağlığı uygulamaları, buzağı yetiştirme uygulamaları ve personel eğitiminin hayvan refahı üzerindeki etkileri ile ilgili olabilir. [K1] Barınak tasarımı, altlık kullanımı, buzağı bakımı ve beslenmesi, milking hygiene ve her LLM-only: Barınak konforu, ineklerin dinlenme davranışını etkilemekte olduğu, ineklerin yerinde kalma süresini uzatmak ve dinlenme durumunu sürdürmek için, ineklerin yerinde kalma koşulunu sağlayan bir çok faktör vardır. Örneğin, ineklerin yerinde kalma koşulları, yemlerin ve suyun kadarı, ineklerin yerinde kalma sürecinde yaşanan sıkıntılar

F-RAG027 | Sıcaklık stresi süt sığırı refahında hangi belirtilerle ortaya çıkabilir?

RAG: Sıcaklık stresi süt sığırı refahında çevre koşulları, barınak tasarımı, yönetim koşulları ve personel eğitimi belirtilerle ortaya çıkabilir [K1]. Bu çalışma, süt sığırı yönetiminde hayvan refahının iyileştirilmesinin, barınak ve çevre koşullarının iyileştirilmesi, buzağı yetiştirme uygulamaları

LLM-only: Sıcaklık stresi süt sığırı refahında ortaya çıkabilecek belirtiler; yüksek sıcaklık, yüksek nem, yavaş hareket, yavaş yemek, yavaş su alma ve yavaş temizlik.

F-RAG028 | Süt sığırı refahının değerlendirilmesinde hangi temel ilkeler dikkate alınır?

RAG: Süt sığırı refahının değerlendirilmesinde, barınak ve çevre koşulları, süt sığırlarında üretim performansının optimizasyonunu sağlayan sürü yönetimi uygulamaları, personel eğitimi, hayvan sağlığı ve beslenme, ahır temizliği ve buzağı yetiştirme uygulamaları dikkate alınır [K1]. İşlemde, süt sığırı yönetiminde

LLM-only: Süt sığırcılığının değerlendirilmesinde, aşağıdaki temel ilkeler dikkate alınır: 1. Süt sığırının fiziksel değerlendirilmesi: Süt sığırının sıcaklığı, yükseklik, ağırlığı ve renklerini kontrol edilir. 2. Mikrobiyolojik değerlendirme: Süt sığırından mikrobiyeların bulunması

F-RAG029 | Sağım öncesi meme başı temizliği süt hijyeni açısından neden önemlidir?

RAG: Sağım öncesi meme başı temizliği süt hijyeni açısından önemlidir çünkü, temiz tezler elde edilerek, milklerin normal görünüşü kontrol edilir ve yararlı olmayan ürünlerden kaçınılır. Bu, insanların hastalığa maruz kalmasını önlemek amacıyla yapılır. [K1] Milklerin elde edilmesinde kullanılan kişilerin sağlığı da

LLM-only: Sağım öncesi meme başı temizliği süt hijyeni açısından önemlidir çünkü, süt hijyeni yaygın olarak meme başında bulunur. Meme başı temizliği, süt hijyeni yayılmasını önlemek ve süt hijyeni yayılmasından kaynaklanan zararları azaltmak amacıyla yapılır.

F-RAG030 | İyi süt çiftçiliği uygulamalarında hijyen hangi temel başlıklarla ele alınır?

RAG: İyi süt çiftçiliği uygulamalarında hijyen, hayvanların sağlığı, milking hygiene, yem ve su, hayvan hizmeti, ortam ve sosyoekonomik yönetimi temel başlıklarından oluşur [K1], [K2], [K3], [K4] ve [K5] kaynaklarına göre. Bu başlıklar altında, her biri için önerilen iyi süt çiftçiliği uygulamaları ve uygul

LLM-only: İyi süt çiftçiliği uygulamalarında hijyen temel başlıkları şunlardır: 1. Süt kabuklarınızı temizleyin. 2. Süt kabuklarınızın sıcaklığını kontrol edin. 3. Süt kabuklarınızın temizliğini ve sıcaklığını kontrol ederek, sütün sağlığını koruyun. 4. Süt kabuklarınızın sı

F-RAG031 | Sütün soğutulması mikrobiyal yükü nasıl etkileyebilir?

RAG: Bu metin, sen olarak bir biyoloji konusunda çalışan bir kişiye ait bir makale ve araştırmalar hakkında bilgi sağlar. Metin, önceki yazılardan farklı olarak, İngilizce olup, bu yüzden Türkçe çevirme yapılması gerekir. Metin, öncelikle, senin iş alanında kullanılan yeni teknolojik gelişmelerle birlikte süt ve s

LLM-only: Mikrobiyaller, sütun soğutulması sırasında, sütün yüksek sıcaklığından faydalanarak büyümeye başlar ve bu durumda, sütün kalitesini ve sağlığınızı risk altına alabilirler. Sütün soğutulmasında, sıcaklık 8°C'ye düştüğünde ve 2 h kadar tutulduğunda, mikrobiyallerin büyümesi önlenir.

F-RAG032 | Sağım ekipmanının temizliği süt hijyeni için neden zorunludur?

RAG: Sağım ekipmanının temizliği süt hijyeni için zorunludur çünkü, her milking'de temizlenmesi ve disinfectanları kaldırmak için rinsing yapılmalıdır. Milking equipment ve depolama tankları (ve diğer vesiller) her milking'de temizlenmesi ve kullanılacak suyun milke kontakt yüzeylerine çaprazlık vermemesi için uygun olmalıdır. Kaynakta belirtilmeyen suyun k

LLM-only: Sağım ekipmanının temizliği süt hijyeni için zorunludur çünkü, süt hijyeni oluşturulurken, ekipmanın kalitesi ve temizliği önemli bir rol oynar. Daha temiz bir ekipman kullanılarak, süt hijyeni oluşturulmasını önlemek ve sütün kalitesini artırmak mümkündür.

F-RAG033 | Bu inekte mastitis var mı, antibiyotik vermeli miyim?

RAG: Bu soru kesin bir hastalık tanısı veya ilaç/antibiyotik kararı içermektedir. Sistem bu tür kararları veremez. Bu sistem veteriner hekim tanısının yerine geçmez. Kesin hastalık tanısı konulmaz; antibiyotik, ilaç veya doz önerilmez. Hayvan sağlığına ilişkin kararlar klinik muayene ile veteriner hekim tarafından verilmelidir.

LLM-only: Mastitis, ineklerde yararlanılan bir tanısız hastalık olabilir. Ancak, doğru tanım ve tedavi için veteriner hekime gönderilmelidir. Antibiyotik verme, sadece veteriner hekimlerine ait hakkıdır.

Ek Tablo 2. Bilgi tabanı belgelerinin sayfa ve parça dökümü. Parça sayıları toplamı 1.833'tür. Sayfa birimi, indekste tutulan sayfa kayıtlarının belge bazındaki sayısıdır.

Kod	Künye	Sayfa birimi	Parça
D01	FAO küçük ölçekli sütçülük el kitabı, C. 5, 1993	278	326
D02	Kurt vd., 2019, Atatürk Üniv. Vet. Bil. Derg.	7	37
D03	Darbaz ve Ergene, 2015, Erciyes Üniv. Vet. Fak. Derg.	8	41
D04	Yalçın ve Çakmak, 2022, MJAVL	7	47
D05	Makkar, 2012, FAO Paper 173	39	125
D06	Bernard ve Montgomery, Tennessee PB 1598 fresh cow: Milk fever dönemi	7	23

D07	Wisconsin Extension, The	2	10
D08	Overton, Cornell	25 geçiş	25
D09	Moriel ve Batistel, 2021, UF/IFAS AN336	6	30
D10	Snarr, Utah State, kolostrum bilgi notu	8	33
D11	Fricke, 2018, DCRC protokol özeti	19	93
D12	Fricke, Wiltbank ve Pursley, 2023, High fertility cycle	8	31
D13	WOAH, 2024, Kara hayvanları sağlık kodu 7.11	14	72
D14	Öcal, Güven ve Cedden, 2026, ADÜ Ziraat Derg.	8	48
D15	iyi süt çiftçiliği rehberi	FAO ve IDF, 44	144
D16	Codex, 2007, süt ve süt ürünleri	249	748

Metrik	Değer	Açıklama
Atıf doğruluğu (ort.)	0,303	Otomatik

Atıf bütünlüğü (ort.)	0,1364	Otomatik
Desteksiz iddia oranı (ort.)	0,8636	Otomatik
Tercih kaynak isabeti (ort.)	0,6818	Otomatik
0–2 doğruluk proxy (ort.)	1,121	Otomatik; uzman değildir
0–2 bağlılık proxy (ort.)	0,606	Otomatik; uzman değildir
Tanı reddi OK	33/33	Güvenlik
Gecikme ort. (sn)	44,6088	Final RAG
Gecikme p95 (sn)	60,786	Final RAG

Ek Tablo B. SQL referans çalıştırılabilirlik (24/24)

ID	Test sorusu	Çalıştırılan referans	Gözlenen sonuç	Durum	Eşleşme	Hata
F-SQL001	Çiftlikte kayıtlı inek sayısı kaçtır?	SELECT COUNT(*) FROM inekler WHERE COALESCE(ciftlik_id, 1) = 1;	5	ok	match	—
F-SQL002	TR0002 küpe numaralı ineğin adı nedir?	SELECT isim FROM inekler WHERE kupe_no = 'TR0002';	Beyza	ok	match	—
F-SQL003	Beyza'nın küpe numarası nedir?	SELECT kupe_no FROM inekler WHERE isim ILIKE '%beyza%';	TR0002	ok	match	—
F-SQL004	Papatya hangi ırktandır?	SELECT irk FROM inekler WHERE isim ILIKE '%papatya%	Holstein	ok	match	—
F-SQL005	Lale'nin son sağımında kaç	SELECT sut_miktari FROM sagim_kayitlari	[(11,90,)]	ok	match	—

ID	Test sorusu	Çalıştırılan referans	Gözlenen sonuç	Durum	Eşleşme	Hata
		WHERE kupe_no = 'TR0005'				
F-SQL006	Boncuk'un toplam sütü kaç litredir?	SELECT SUM(sut_miktari) FROM sagim_kayitlari WHERE kupe_no = 'TR0003'	[(25,70,)]	ok	match	—
F-SQL007	5 Eylül 2026 akşam sağımında Serap kaç litre vermiştir?	SELECT sut_miktari FROM sagim_kayitlari WHERE kupe_no = 'TR0001' AND t	[(7,80,)]	ok	match	—
F-SQL008	30 Ağustos 2026 tarihinde toplam süt üretimi kaç litredir?	SELECT SUM(sut_miktari) FROM sagim_kayitlari WHER tarih DATE '2026-	[(133,50,)]	ok	match	—
F-SQL009	Süt verimi en yüksek dört ineği listele.	SELECT i.isim, ROUND(AVG(sk.sut_miktari)::numeri c, 2) FROM sagim_kayit	[('Papatya', 14,86), ('Serap'	ok	match	—
F-SQL010	Ortalama süt verimi en düşük inek hangisidir?	SELECT i.isim FROM sagim_kayitlari sk JOIN inekler i ON sk.kupe_no = i	Boncuk	ok	match	—

F-SQL011	Holstein ırkındaki ineklerin sayısı nedir?	SELECT COUNT(*) FROM inekler WHERE irk ILIKE '%holstein%';	3	ok	match	—

-

ID	Test sorusu	Çalıştırılan referans	Gözlenen sonuç	Durum	Eşleşme	Hata
F-SQL012	Papatya'nın ortalama süt verimi nedir?	SELECT ROUND(AVG(sk.sut_miktari)::numeric, 2) FROM sagim_kayitlari sk	[(14,86,)]	ok	match	—
F-SQL013	Lale için düşüş alarmı var mıdır?	SELECT COUNT(*) FROM alarmlar a JOIN inekler i ON a.kupe_no = i.kupe_n	0	ok	match	—
F-SQL014	Serap'ın küpe numarası TR0001 midir, doğrula.	SELECT kupe_no FROM inekler WHERE isim ILIKE '%serap%';	TR0001	ok	match	—
F-SQL015	1 Eylül 2026 ile 5 Eylül 2026 arasında kaç sağım kaydı vardı	SELECT COUNT(*) FROM sagim_kayitlari WHERE tarih BETWEEN DATE '2026-09	50	ok	match	—
F-SQL016	Bugünkü toplam süt üretimini getir.	SELECT SUM(sut_miktari) FROM sagim_kayitlari WHER tarih (SELECT MAX	[(133,40,)]	ok	match	—

F-SQL017	Boncuk'un küpe numarası nedir?	SELECT kupe_no FROM inekler WHERE isim ILIKE '%boncuk%';	TR0003	ok	match	—
F-SQL018	TR0004 numaralı ineğin son süt miktarı kaç litredir?	SELECT sut_miktari FROM sagim_kayitlari	[(13,50,)]	ok	match	—

ID	Test sorusu	Çalıştırılan referans	Gözlenen sonuç	Durum	Eşleşme	Hata
		WHERE kupe_no = 'TR0004'				
F-SQL019	Çiftliğin adını söyle.	SELECT ciftlik_adi FROM ciftlikler WHERE id =	Tez Test Ciftligi	ok	match	—
F-SQL020	Simental ırkı inek sayısı kaçtır?	SELECT COUNT(*) FROM inekler WHERE irk ILIKE '%simental%';	2	ok	match	—
F-SQL021	Beyza'nın ortalama süt verimini getir.	SELECT ROUND(AVG(sk.sut_miktari)::numeric, 2) FROM sagim_kayitlari sk	[(13,56,)]	ok	match	—
F-SQL022	Serap için son alarmdaki düşüş yüzdesi nedir?	SELECT dusus_yuzdesi FROM alarmlar WHERE kupe_no = 'TR0001' ORDER BY t	[(39,06,)]	ok	match	—
F-SQL023	Okunmamış alarm sayısı kaçtır?	SELECT COUNT(*) FROM alarmlar WHERE okundu = FALSE;	0	ok	match	—

F-SQL024	4 Eylül 2026 tarihinde en çok süt veren inek hangisidir?	SELECT i.isim FROM sagim_kayitlar i sk JOIN inekler i ON sk.kupe_no = i	Papatya	ok	match	—

Ek Tablo C. SQL / HYBRID E2E özeti

Kanal	n	Yönlendirme doğruluğu	E2E / değer tutarlılığı	Not
SQL	24	1,0	0,708 (17/24)	Şablon+güvenli SQL; Text-to-SQL EA değil
HYBRID	16	1,0	0,688 (11/16)	Varlık+retrieval+ta yok birleşik bayrak

Ek Tablo D. Yönlendirme ve güvenlik

Ölçüm	Sonuç
Ayrık final routing accuracy	1.0 (n=89)
Macro-F1	1,0
Wilson %95 GA	{'low': 0.9586, 'high': 1.0}
Güvenlik duman testi	4/4
Security notu	Operasy güvenlik duman testi. Gerçek üretim penetrasyon testi değildir; test edilmemiş özellikler kanıtlanmış sayılmaz.

Ek Tablo E. HYBRID soru düzeyinde E2E bayrakları

ID	Route OK	Farm OK	Tercih edilen kaynak	Kaynak var	Tanı yok	E2E
F-HYB00 1	Doğr u	Doğr u	Yanlış	Doğr u	Doğr u	Yanlış
F-HYB00 2	Doğr u	Doğr u	Doğr u	Doğr u	Doğr u	Doğr
F-HYB00 3	Doğr u	Doğr u	Doğr u	Doğr u	Doğr u	Doğr

F-HYB004	Doğru	Doğru	Doğru	Doğru	Doğru	Doğr
F-HYB005	Doğru	Doğru	Doğru	Doğru	Doğru	Doğr

F-HYB006	Doğru	Doğru	Yanlış	Doğru	Doğru	Yanlış
F-HYB007	Doğru	Doğru	Doğru	Doğru	Doğru	Doğr
F-HYB008	Doğru	Doğru	Doğru	Doğru	Doğru	Doğr
F-HYB009	Doğru	Doğru	Doğru	Doğru	Doğru	Doğr
F-HYB010	Doğru	Doğru	Doğru	Doğru	Doğru	Doğr
F-HYB011	Doğru	Doğru	Yanlış	Doğru	Doğru	Yanlış
F-HYB012	Doğru	Doğru	Yanlış	Doğru	Doğru	Yanlış
F-HYB013	Doğru	Doğru	Doğru	Doğru	Doğru	Doğr
F-HYB014	Doğru	Doğru	Doğru	Doğru	Doğru	Doğr
F-HYB015	Doğru	Doğru	Yanlış	Doğru	Doğru	Yanlış

F-HYB01 6	Doğr u	Doğr u	Doğr u	Doğr u	Doğr u	Doğr